



MÉMOIRE DE RECHERCHE

Département des Sciences du Langage

M2 Linguistique, Informatique et Technologies du Langage (LITL)

Étude de la sous-spécification des têtes transdisciplinaires de segments des titres d'articles scientifiques

Damien GOUTEUX

Sous la direction de Mme Josette Rebeyrolle et M. Ludovic Tanguy

2018 – 2019

Résumé	6
Introduction	7
I. Exploration du corpus à la lumière de l'état de l'art	12
I.1 Origine et prétraitements des données	12
I.1.1 Récupération des données	12
I.1.2 Étiquetage et analyse syntaxique en dépendances	13
I.1.3 Segmentation des titres	14
I.1.4 Sélection de la tête des segments	14
A. Titres avec un segment et une tête	16
B. Titres avec un segment et deux têtes	16
C. Titres avec un segment ayant une tête suivie d'un segment sans tête	17
D. Titres avec un segment sans tête suivi d'un segment avec tête	17
E. Titres avec un segment avec tête suivi d'un segment avec tête	17
F. Algorithme de sélection de tête de segment	17
I.2 Constitution d'un corpus de travail représentatif	17
I.2.1 Sélection selon la structure des titres	18
I.2.2 Sélection selon la nature des têtes	18
A) Répartition des natures des têtes	18
B) La nature nominale des titres	20
I.2.3 Un corpus de travail représentatif du matériau de base	21
I.3 Structures semblables des domaines et têtes spécifiques	22
I.3.1 Variations de la structure en fonction du domaine	22
I.3.2 Têtes spécifiques à un domaine	24
A) Définition et principe de sélection	24
B) Corrections de Talismane	25
C) Évaluation des résultats	27
II. Têtes transdisciplinaires et NSS dans notre corpus	31
II.1 Sélection des têtes transdisciplinaires	31
II.1.1 Principe de sélection	31
II.1.2 Résultats et évaluations du résultat	31

II.1.3 Études des têtes selon leurs segments et la structure segmentale du titre	32
II.2 Noms sous-spécifiés et constructions spécificationnelles	33
II.2.1 Définitions des noms sous-spécifiés	33
II.2.2 Les constructions spécificationnelles classiques	35
A) Définitions des CS	35
B) Nature et fonction du contenu spécifiant dans les CS classiques	37
CS-I, CS-II, CS-III, CS-IV, CS-V et CS-VI : NSS [(, ce être) être] proposition en que ou de	37
CS-VIII et CS-IX : NN [, ce] être syntagme nominal	38
CS-VII : NSS de syntagme nominal	38
II.2.3 Recherche des CS classiques dans notre corpus	40
A) Constructions avec une proposition subordonnée conjonctive CS-I, CS-III et CS-V	41
B) Constructions avec une proposition subordonnée infinitive CS-II, CS-IV et CS-VI	41
C) CS avec verbe copule et syntagme nominal, CS-VIII et CS-IX	43
D) CS avec un syntagme prépositionnel-nominal, CS-VII	44
II.3 Schémas récurrents d'emploi des têtes transdisciplinaires	44
II.3.1 Recherche de schémas d'emplois des têtes transdisciplinarité	44
A) Recherche de la CS-VII, NSS de NC	Erreur ! Signet non défini.
B) Schémas récurrents d'emplois des têtes transdisciplinaires	45
II.3.2 Nature de l'emploi	Erreur ! Signet non défini.
II.3.3 Transdisciplinarité des schémas	Erreur ! Signet non défini.
III. Discussion sur nos résultats, limites et perspectives	56
III.1 Éléments de discussion	56
Limite de l'analyse en dépendance automatique de Talismane	56
Limitations des têtes spécifiques aux domaines	56
Têtes transdisciplinaires	57
Listes de NSS	57
Opérationnalisation des NSS	Erreur ! Signet non défini.
Conclusion	56
Bibliographie	59
A1. Distance des domaines de par leurs têtes spécifiques	67

A2. Combinaisons des têtes de titres bisegmentaux	68
A3. Liste des têtes transdisciplinaires	70
A4. Étiquettes utilisées par Talismane et HAL	74
A4.1 Catégories morphosyntaxiques de Talismane	74
A4.2 Code des 27 domaines de HAL retenus	75
A5. Éléments techniques	77
A5.A Présentation de l'API de requêtage de notre corpus	77
A5.B Description de nos données informatiques	77
A5.C Analyse de 100 titres traités par Talismane	78
A6. Index des tableaux	84

Résumé

Nous étudions les têtes transdisciplinaires des titres de publications scientifiques : des têtes très fréquentes dans de nombreux domaines scientifiques. Nous rapprochons ces têtes transdisciplinaires des noms employés de façon sous-spécifiée : des noms dont la carence sémantique est comblée par le contexte, nom et contexte étant reliés par une construction spécificationnelle. Pour mener à bien ce rapprochement, nous étudions les schémas récurrents dans lesquels s'insèrent les têtes transdisciplinaires des titres. Nous étudions ces schémas pour les rapprocher des constructions spécificationnelles déjà relevées dans la littérature. Ce rapprochement syntaxique et fonctionnel nous permet de dresser une liste de têtes transdisciplinaires s'employant le plus souvent de façon sous-spécifiées. Enfin, nous mettons en rapport les têtes et les schémas avec les différents domaines scientifiques.

Mots-clés : titre, tête, schéma, patron, nom porteur, emploi sous-spécifié, sous-spécification, construction spécificationnelle, contenu spécifiant, publication, article, domaine, discipline.

Introduction

Un titre de document scientifique est un énoncé singulier d'une importance cruciale. D'une part, il s'agit d'un texte très court d'une dizaine de mots. D'autre part, il constitue le premier contact entre un document et ses lecteurs et, dans 92 % des cas, le seul : le lecteur ne lira ni le résumé ni l'article après avoir lu le titre (Mabe et Amin, 2002). C'est sur la lecture du titre seul, indépendamment du document titré, que le chercheur fait son tri parmi la littérature scientifique (Goodman et al., 2001). La production scientifique augmente constamment en doublant tous les 12 ans (Stix, cité dans Salager-Meyer et al. 2013). Ce tri effectué sur la lecture du titre soulève la question de l'information qu'il contient et les mots et les structures utilisés pour convoier cette information. Cet intérêt s'est traduit par de nombreux articles sur les titres en anglais, mais les titres en français ont été moins étudiés. On peut néanmoins citer les travaux de Ho-Dac et al. (2001), Rebeyrolle et al. (2009) et Tanguy et Rebeyrolle (à paraître).

Nous prenons en compte dans notre travail le titre uniquement dans sa fonction informationnelle, considérant, comme Haggan (2004) et Hartley (2005), qu'elle est la plus importante. Cette dimension est également plus facile à analyser que la fonction d'attraction qui peut considérablement obscurcir le sens d'un titre (Hartley, 2005) ou faire appel à des notions complexes pour le traitement automatique des langues comme l'humour (Sagi et Yechiam, 2008 ; Subotic et Mukherjee, 2014).

La majorité de la littérature sur les titres traitant de titres d'articles de journaux scientifiques, notre travail se limite à ce type de publication et aux publications dont les titres sont construits de manière similaire : chapitres d'ouvrages collectifs et communications ou posters dans des congrès ou des conférences.

Nous devons en premier lieu revenir sur notre travail, effectué durant la première année de master, sur les titres de publications scientifiques en français. Nous avons étudié trois schémas lexico-syntaxiques fréquents dans un corpus de titres de publications scientifiques. Un schéma est défini par une séquence de tokens qui peut comporter des choix entre plusieurs tokens **A | B**, des tokens optionnels **[A]** et des répétitions de tokens **A^{i,j}**. Un token de schéma peut être une classe grammaticale (nom - N, adjectif qualificatif - ADJ, préposition - P, conjonction de coordination CC...), un sous-ensemble d'une classe (nom commun - NC), un lemme (*et*) ou un signe de ponctuation comme le double point ou le point-virgule. À une définition de schéma correspond une à plusieurs réalisations. Par exemple, le schéma défini par **[DET] NC ADJ** a pour réalisations la séquence d'un déterminant suivi d'un nom commun suivi d'un adjectif qualificatif ou la séquence d'un nom commun suivi d'un adjectif qualificatif.

Une séquence de tokens dans un titre, mots ou signes de ponctuation, correspond à un schéma lorsque la séquence du titre se conforme à une des réalisations possibles définies par le schéma. Ainsi le titre *Villes durables et changement climatique* correspond, entre autres, aux deux schémas **NC ADJ CC NC ADJ** et **NC ADJ et NC ADJ**. Le premier schéma n'utilise que des classes grammaticales comme tokens, alors que le second utilise comme tokens quatre classes grammaticales et un lemme, *et*. La séquence *union parfaite ou mariage impossible* correspond au premier schéma mais pas au second : *ou* peut être

associé à **CC** mais pas à **et**. Pour les deux schémas, leur premier token, **NC**, est associé au mot *Villes* pour le premier exemple et à *union* pour le second.

Les trois schémas étudiés dans notre travail précédent ne correspondaient à chaque fois qu'à une partie du titre et non à son ensemble : un titre était sélectionné s'il contenait une séquence correspondant à un de nos schémas, mise en gras dans les exemples qui suivent. Nous donnons ci-dessous une description et une définition pour ces trois schémas.

- Description Un double point suivi d'un syntagme nominal dont le nom est complété par un syntagme prépositionnel
 - Définition : **NC P NC**
 - Exemple (1) La société face au pouvoir dans le roman arabe moderne : **la voie religieuse comme alternative**
- Description Un double point suivi d'un syntagme prépositionnel dont le nom est complété par un syntagme prépositionnel
 - Définition : **P NC P NC**
 - Exemple (2) Couper les seins des femmes : **du supplice à la monstruosité**
- Description Un double point suivi d'un syntagme nominal constitué de deux noms coordonnés
 - Définition : **NC CC NC**
 - Exemple (3) La Fée Électricité : **espoirs et craintes** de la modernité

Les définitions sont données dans leurs formes minimales. Nous ne représentons pas la possibilité d'avoir des déterminants et des adjectifs qualificatifs pour les noms de chaque schéma dans des définitions étendues de ceux-ci, mais, par souci de simplification, nous écartons ces possibilités ici.

Nous disposons d'un corpus de 85 500 titres en français de différents types de publications scientifiques, dont les plus nombreux étaient les articles, les communications et les chapitres d'ouvrage, issus d'un grand nombre de domaines scientifiques (voir la partie I.1.1 Récupération des données qui reprend la méthode de constitution de ce premier corpus pour établir notre corpus de travail de cette année). Le premier schéma couvrait 50 % des titres, le deuxième 5 % et le dernier 10 %, soit une couverture totale de 65 % de notre corpus. Nous avons ensuite étudié les noms et les couples de noms les plus fréquents qui peuplaient ces schémas. Nous avons constaté l'utilisation récurrente et transdisciplinaire de noms abstraits, dont les onze plus fréquents étaient :

- *étude, cas, approche, analyse, application, pratique, exemple, enjeu, perspective, modélisation, limite.*

Tous ces noms sont abstraits, ils ne dénotent pas un objet tangible du monde réel, et liés au domaine scientifique : on les retrouve tous, sauf *enjeu*, dans le lexique transdisciplinaire des écrits scientifiques (LTES) décrit par Tutin (2008). Par ailleurs, nous avons remarqué une similitude lexicale avec une liste de noms employés de façon très fréquente dans le discours académique (Flowerdew et Forest, 2015, p. 1) avec un contenu sémantique très faible spécifié par le contexte. Nous parlerons pour désigner cet emploi, en reprenant la terminologie de Legallois (2008), de noms sous-spécifiés (NSS). La question initiale est donc de savoir si nos noms seraient des NSS.

Deux difficultés apparaissent déjà : les NSS sont une classe considérée comme ouverte (Flowerdew et Forest, 2015, p. 12 ; Schmid, 2000, p. 4) et une classe d'emploi, non d'une nature lexicale (Flowerdew et Forest, 2015, p. 7 ; Schmid, 2000, p. 13). On ne peut donc déterminer s'il s'agit d'un NSS qu'en fonction de son contexte où il est relié à un contenu qui le spécifie. La liaison entre le contenu spécifiant et le NSS se fait via une construction spécificationnelle (CS). Les deux constructions spécificationnelles les plus fréquemment étudiées, notamment par Schmid (2000, p. 22) pour l'anglais et transposées par Legallois (2008, p. 2) en français, sont :

CS-I. **NSS** + *être* + proposition subordonnée conjonctive commençant par *que* :

Le **problème** est que je n'avais pas d'argent.

CS-II. **NSS** + *être* + proposition subordonnée infinitive commençant par *de* :

Le **problème** est de ne pas avoir d'argent.

La question se pose de savoir si on retrouve nos noms dans de telles constructions dans les titres. Si le verbe *être* est optionnel pour Schmid (2000, p. 22), il n'en reste pas moins que la proposition doit contenir un verbe, conjugué dans le cas d'une proposition subordonnée conjonctive ou à l'infinitif pour une proposition subordonnée infinitive. Or, de nombreux travaux (Leech, 2000 ; Haggan, 2004 ; Soler, 2007 ; Cheng et al., 2012 ; Wang et Bai, 2007) soulignent la nature nominale des titres. Un milieu largement « averbal » comme les titres fait douter de retrouver les CS-I et CS-II dedans.

Néanmoins, Schmid (2000, p. 26) mentionne une autre CS de la forme **NSS** + *de* + syntagme nominal. Or, la complémentation des noms est une caractéristique de l'écriture académique (Biber et Gray, 2010), nos noms pourraient donc s'insérer dans cette CS. Prenons les deux exemples 1 et 2¹, pour éclairer l'hypothèse d'un rapprochement possible entre nos noms et les NSS :

(1) Le **problème** de l'abandon de l'habitat dans la Corse médiévale

(2) Le **problème** du Paléolithique final de Haute-Normandie

Problème est un terme listé comme employé très fréquemment dans un emploi sous-spécifié par Flowerdew et Forest (2015) et Schmid (2000, p. 85). Selon Schmid (2018, p.118), ce qui unit les contenus désignés comme un problème est qu'il s'agit d'un « *fait étant un obstacle au progrès* » ou, citant Tuggy dans ce même article (2018, p. 122), « *une chose qui n'est pas en conformité avec quelque chose établi ou désiré* ». On peut rajouter à ces définitions, une chose qui a des conséquences négatives. Ainsi est catégorisé à chaque fois un concept temporaire créé par l'énoncé : l'abandon de l'habitat dans la Corse médiévale pour (1) et le Paléolithique final de Haute-Normandie pour (2). Le choix de catégoriser ce concept de *problème*, au lieu de *question* par exemple, indique une volonté de l'interlocuteur de souligner qu'il y a un obstacle ou du moins un imprévu dans le raisonnement scientifique. On peut également voir que *problème* crée une liaison à son contenu spécificationnel dès le titre. Il pourra également créer des références anaphoriques en étant repris avec un démonstratif, *ce problème*, si ce n'est dans le titre du fait sa trop grande concision, dans le résumé ou le texte de la publication scientifique.

¹ Les exemples donnés sur fond gris sont tous tirés de notre corpus de titres.

De plus, il est toujours possible que nos noms s'intègrent à d'autres schémas d'utilisation très fréquents qui pourraient jouer le rôle de CS. Pour répondre à toutes ces questions, nous utiliserons une approche se basant sur le traitement automatique des langues et la linguistique de corpus (Cori et David, 2008). Pour les NSS, nous nous appuyons plus particulièrement sur Legallois (2008), Schmid (2000) et Flowerdew et Forest (2015).

Tout d'abord, Nous pensons que la classe de nom ayant émergé dans notre premier travail peut gagner à être redéfinie par une autre approche, indépendante de la position des noms immédiatement après le double point, à la fois plus stricte et d'une couverture plus large. Nous avons en effet écarté dans notre précédente étude toute la partie avant le double point et les phénomènes récurrents pouvant y survenir, perdant ainsi des découvertes potentielles et n'utilisant pas une large partie de notre corpus.

Nous faisons l'hypothèse, soutenue par notre intuition et notre connaissance du précédent corpus, que le premier nom que nous étudions immédiatement après le double point est la tête, aussi appelée noyau ou racine, du syntagme de premier niveau du segment après le double point et donc la tête du segment. Nous redéfinissons notre cible d'étude comme les têtes de segments et nous élargissons cette étude, en ne regardant plus seulement le segment après le double point, mais aussi le segment avant.

Nous élargissons également notre étude aux titres à un seul segment et aux titres à deux segments séparés par un autre signe de ponctuation que le double point. Notre étude portera donc sur toutes les têtes nominales des segments des titres à un ou deux segments. Dans l'exemple (3) ci-dessous, le titre est constitué de deux segments, délimités par un double point. Nous en mettons en gras la tête de chaque segment :

(3) Un nouvel **OVNI** dans le ciel réunionnais : la **transparence** des prix

Ce nouveau travail doit donc commencer par le découpage de nos titres en segments en reprenant et en amendant une liste de signes de ponctuation qui segmentent les titres en anglais, établie par Anthony (2001). Ensuite, pour trouver les têtes de syntagmes, plutôt que de simplement parcourir le segment et prendre le premier nom rencontré comme nous le faisons en première année, nous avons décidé d'utiliser l'analyse syntaxique en dépendances (Tesnière, dans Schwischay, 2001) pour identifier les têtes de segments.

Ce sont ces têtes de segments dont nous voulons étudier le rapprochement possible avec les noms sous-spécifiés. Pour cela, nous voulons caractériser ces têtes et les schémas récurrents dans lesquels elles s'insèrent, dans un corpus de titres de publications scientifiques. Nous voulons ensuite rapprocher les têtes des noms sous-spécifiés et les schémas des constructions spécificationnelles.

De précédents travaux ont montré qu'il existe des spécificités disciplinaires dans l'écriture des titres pour l'anglais (Haggan, 2004 ; Lewison et Hartley, 2005 ; Soler, 2007, 2011 ; Nagano, 2015) et le français (Tanguy et Rebeyrolle, à paraître). Nous ne manquerons pas de déterminer dans le cadre de notre problématique s'il existe des variations des têtes et des schémas suivant les domaines. Nous pourrions ainsi mettre au jour des têtes spécifiques à certains domaines et d'autres qui seraient transdisciplinaires.

Ce sont les têtes transdisciplinaires qui nous semblent les meilleures candidates pour être rapprochées des NSS. On peut suspecter que leur capacité à apparaître très fréquemment dans la plupart des domaines n'est possible qu'à cause d'un faible contenu sémantique et que seule la prise en compte du contexte de la tête transdisciplinaire permet d'accéder à son sens complet. Nous voulons déterminer cette proximité de fonctionnement entre têtes transdisciplinaires et NSS en identifiant :

- Une liste de têtes transdisciplinaires à rapprocher des NSS.
- Une liste de schéma récurrents dans lesquels s'inscrivent nos têtes transdisciplinaires à rapprocher des constructions spécificationnelles dans lesquelles les NSS s'inscrivent.
- Une répartition des têtes transdisciplinaires et des schémas par rapport aux domaines scientifiques.

Notre étude se déroulera en trois temps. Dans un premier temps, nous partons des données rassemblées pour délimiter un corpus de travail. Nous décrivons certains traits saillants de notre corpus à l'aide de différentes mesures, en faisant référence aux nombreux travaux existants. Nous nous réassurons de la nature éminemment nominale des titres et étudions les variations entre les différents domaines scientifiques, notamment les têtes de segments spécifiques à certains domaines. Dans un deuxième temps, nous construisons la liste des têtes de segments transdisciplinaires. Nous rappelons les apports des travaux sur les noms sous-spécifiés et essayons de détecter les constructions spécificationnelles dans lesquelles ils s'inscrivent généralement dans notre corpus. Nous détectons ensuite les schémas récurrents dans lesquels s'inscrivent nos têtes transdisciplinaires pour essayer de rapprocher les schémas des constructions spécificationnelles et les têtes transdisciplinaires des noms sous-spécifiés. Nous nous appuyons notamment sur la forte fréquence et la transdisciplinarité des têtes transdisciplinaires pour fournir une liste de têtes transdisciplinaires se comportant comme des NSS. Enfin, dans un troisième temps, nous discutons de nos résultats, des limites de notre travail et ouvrons de nouvelles perspectives.

I. Exploration du corpus à la lumière de l'état de l'art

I.1 Origine et prétraitements des données

I.1.1 Récupération des données

L'accès aux titres a été grandement facilité par la création de bases de données bibliographiques, dont celles des archives ouvertes. Chaque chercheur, quelle que soit son domaine, ou documentaliste d'un centre de recherche, est libre de déposer un document sur une archive ouverte avec l'accord de ses auteurs. Une archive ouverte présente l'avantage de centraliser l'accès aux travaux scientifiques, d'aider à leur diffusion et de les conserver de manière pérenne, par rapport au site d'une institution particulière ou le site web personnel d'un chercheur, et de façon gratuite et accessible à tous, au contraire des éditeurs.

Nous utilisons le corpus constitué par Tanguy et Rebeyrolle (à paraître) comprenant près de 340 000 titres. Pour obtenir une si grande quantité de titres français, ils se sont tournés vers l'archive ouverte Hyper Article en Ligne (HAL, <https://hal.archives-ouvertes.fr>) (Nivard, 2010). Cette archive fonctionne depuis 2001 et est gérée par le Centre pour la Communication Scientifique directe du Centre National pour la Recherche Scientifique (CNRS). Elle contient plus de 1,6 millions de références, soit de travaux dont elle possède une copie, soit par le biais d'une notice. HAL possède de nombreux types de documents différents : articles scientifiques mais aussi vidéo, cours, ouvrages ou thèses. Plusieurs institutions, dont le CNRS, encouragent le dépôt sur HAL des travaux produits par leurs chercheurs, garantissant un nombre important de titres issus de plusieurs domaines scientifiques. Alors que la majorité de la littérature traite des titres en anglais, HAL permet d'avoir accès à un grand corpus de titres en français. Nous veillerons dans ce premier chapitre à vérifier sur notre corpus certains enseignements tirés de l'étude des titres en anglais, notamment la nature des titres.

Notre matière de départ se restreint aux titres en français, d'articles scientifiques, de chapitre, de poster ou de communication, car nous prenons comme hypothèse qu'ils sont construits de manière similaire. Chaque titre est fourni avec cinq informations supplémentaires relatives à la publication titrée :

1. un **identifiant** unique de la publication et donc du titre
2. les prénoms et noms des **auteurs** de la publication dont on peut déduire le nombre d'auteurs,
3. le **type** du document qui ne peut être qu'un article scientifique, un chapitre d'un ouvrage collectif, une communication ou un poster dans un congrès ou une conférence,
4. l'**année** de publication,
5. les **domaines scientifiques**, ou disciplines académiques, auxquels est associée la publication dont nous déduisons un domaine principal selon la méthode établie par Tanguy et Rebeyrolle (à paraître).

L'exemple (4) ci-dessous montre les différentes informations pour un titre donné :

(4) Villes durables et changement climatique : quelques enjeux sur le renouvellement des ressources urbaines

Identifiant 609897

Auteurs Véronique Peyrache-Gadeau et Bernard Pecqueur

Type de document Article scientifique (code ART)

Année de publication 2011

Domaines scientifiques 0.sde et 1.sde.mcg, le premier correspond aux sciences de l'environnement et le second à un sous-domaine des sciences de l'environnement.

HAL permet d'attribuer plusieurs domaines à un document. Les domaines sont organisés en une taxonomie possédant quatre niveaux de profondeur, néanmoins la granularité des branches est très variable : « Sciences de l'Homme et Société » est une des racines de l'arbre, regroupant sous son égide de nombreux domaines scientifiques, allant de l'histoire aux littératures, alors que toutes les sciences exactes bénéficient elles d'une racine propre comme informatique ou chimie. Tanguy et Rebeyrolle (à paraître) ont proposé une méthode de recodage des domaines pour n'en garder qu'un seul, le plus important et discriminant, que nous utilisons. Dorénavant, un titre est associé à un seul domaine principal : le domaine de premier niveau pour les sciences exactes, le domaine de second niveau pour les sciences humaines et sociales.

Nous avons relevé les domaines suivant, avec en gras les sciences exactes (voir pour l'annexe [A4.2 Code des 27 domaines de HAL retenues](#) pour une correspondance entre les codes et les domaines scientifiques) : anthropologie, archéologie et préhistoire, architecture, art et histoire de l'art, autres, **chimie**, droit, **économie et finance quantitative**, éducation, géographie, gestion et management, histoire, **informatique**, linguistique, littératures, **mathématiques**, philosophie, **physique**, **planète et univers**, psychologie, science politique, **sciences cognitives**, **sciences de l'environnement**, sciences de l'information et de la communication, **sciences du vivant** et sociologie.

I.1.2 Étiquetage et analyse syntaxique en dépendances

Les titres ont été analysés à l'aide du logiciel Talismane (Urieli et Tanguy, 2013 ; Urieli, 2013) qui fournit un découpage en différents tokens, mots et signes de ponctuation, et réalise un étiquetage morphosyntaxique des mots et une analyse syntaxique en dépendances des tokens. Pour chaque token du titre nous avons :

- sa **forme** dans le titre,
- son **lemme** (pour les mots),
- sa **classe grammaticale/catégorie** (pour les mots, sinon nous avons "signe de ponctuation")
- des **informations complémentaires**
- son token **recteur**,
- la **relation de dépendance** qui le lie à son recteur.

Les informations complémentaires dépendent de la classe grammaticale, comme le genre pour les noms, le mode et le temps pour les verbes. Les titres étant des textes très travaillés, ils ne nécessitent pas de prétraitement pour corriger les fautes, même s'il y en a de très rares comme la

concaténation d'un titre et d'un sous-titre sans token séparateur (5) ou le redoublement d'une préposition (6) :

(5) Développement stratégique du tourisme sportif de rivière par régulation corporatiste
L'expérience du bassin de Saint Anne (Québec) appliquée aux Rivières de Provence

(6) Dispositif **de de** caractérisation simultanée de l'abondance de pucerons et de la croissance végétative d'arbres fruitiers

Il est à noter que Talismane a été conçu pour analyser des phrases beaucoup plus longues que des titres et entraîné sur de tels textes. On peut donc douter de sa capacité à analyser correctement les titres. Notamment, comme nous le verrons plus tard, les titres ne comportent souvent pas de verbes conjugués au contraire des phrases plus longues, ce qui pourrait pousser Talismane à reconnaître comme verbes des mots n'en étant pas. Nous avons donc décidé d'inclure une phrase de vérification de l'analyse de Talismane lors de l'étape de sélection des têtes pour vérifier son comportement.

I.1.3 Segmentation des titres

Nous avons segmenté les titres selon la liste des signes de ponctuation segmentants établie par Anthony (2001). Nous en retranchons le tiret car il est utilisé pour lier de nombreux mots en français comme *e-commerce*, *semi-figement* ou *petit-déjeuner*. Nous avons pu vérifier que Talismane traitait les formes en *e-X* et *semi-X* comme un *e* ou *semi* suivi d'un tiret suivi d'un nom (voir la section **Erreur ! Source du renvoi introuvable.**). Nous y ajoutons le point d'exclamation et les points de suspension dont l'absence ne nous semble pas justifiée. Nous avons donc les signes segmentants suivants :

Type de ponctuation	Signe de ponctuation
Ponctuation forte	. ? ! ...
Ponctuation faible	; :

Tableau 1: signes de ponctuation segmentants

Il y a dans cette liste des signes de ponctuation forte, comme le point ou le point d'interrogation, et des signes de ponctuation faible comme le point-virgule ou le double-point. Le type de segmentation effectuée découle directement du type de ponctuation : forte ou faible.

L'avantage d'utiliser le segment est qu'il s'agit d'une unité que nous définissons clairement à la suite d'Anthony (2001), directement applicable computationnellement, au contraire de la proposition dont la définition est selon Joseph Donato dans l'ouvrage collectif sous la direction de Mounin (1974) « *très empirique* » et pour la laquelle la « *distinction entre syntagme et proposition n'était pas toujours très claire ni très systématique dans l'analyse des phrases spécifiques* ».

I.1.4 Sélection de la tête des segments

Nous voulons ensuite récupérer la tête des segments, qui s'assimile à la notion de prédicat suivant la définition de Conrad Bureau, toujours dans Mounin (1974) :

« Désigne, en syntaxe, l'élément central de la phrase, celui par rapport auquel tous les autres éléments de la phrase marquent leur fonction. Est prédicat celui des éléments : 1° qui ne dépend syntaxiquement d'aucun autre élément ; 2° par rapport auquel la phrase s'organise, et 3° dont la disparition détruit l'énoncé. »

Pour trouver les têtes et les compter, deux solutions s'offraient à nous. La première est une règle qui consiste à prendre le verbe conjugué du segment comme tête s'il y en a un, sinon une préposition si elle occupe la première position du segment et sinon le premier nom rencontré. Cette solution présente l'avantage d'être très simple mais nous avons peur de manquer des phénomènes remarquables ou de sélectionner le mauvais mot comme tête en nous basant si fortement sur la position.

Nous avons donc opté pour la seconde solution qui consiste à utiliser l'outil Talisman pour effectuer une analyse syntaxique en dépendances du titre. Il s'agit d'une utilisation à minima de l'analyse en dépendances, uniquement pour faire émerger une tête mais cela n'a toutefois pas été sans soulever deux problèmes.

Notre but est que chaque segment ait une tête correctement identifiée mais la segmentation que nous effectuons, basée sur des signes de ponctuation, est décorrélée de l'analyse de Talisman qui possède sa propre segmentation que nous nommerons partition et le résultat des parties pour les distinguer de nos segments. Talisman va produire pour chaque partie un arbre avec une racine unique. Dans le cas nominal, chaque partie de Talisman correspond à un segment, et la tête de chaque segment est directement la racine de l'arbre produit par Talisman.

Mais si notre titre est constitué d'une seule partie elle-même constituée de plusieurs segments, nous obtenons des segments sans tête. Nous avons décidé de nous limiter aux titres avec au maximum deux parties et deux segments car ils sont les plus nombreux dans notre matériau : nous comptons 87 % de titres avec une partie et 11 % avec deux et 58 % titres avec un segment et 37 % avec deux. On peut classer nos résultats d'analyse en trois cas :

1. Des titres ayant un segment et une tête
2. Des titres ayant deux segments dont un seul a une tête (soit le premier, soit le second)
3. Des titres ayant deux segments avec une tête dans chaque

L'exemple (7) montre un titre à deux segments avec une segmentation faible, le double-point et l'exemple (8) montre un titre à deux segments avec une segmentation forte, le point. Les deux exemples ont pour Talisman une seule partie.

(7) L'**omniprésence** de la famille au sein de l'exploitation agricole : une *situation* de fait encouragé par les règles de droit

(8) **MODÈLES** THÉORIQUES DE LA STRUCTURE DES JOINTS DE GRAINS. LES *MODÈLES* DE STRUCTURE DES JOINTS DE GRAINS ET LEUR UTILISATION²

² Dans cet exemple, il n'y a pas d'espaces autour du point qui est pourtant bien reconnu comme marque de ponctuation.

Dans les deux exemples précédents, *omniprésence* et *modèles* (en gras) sont reconnus comme des têtes des premiers segments mais pas *situation* et *modèles* (en italique) pour les seconds segments. Nous utilisons Talismane comme une « boîte noire » et nous ne voulons pas entrer dans les détails de sa partition des titres et de son analyse. Nous voulons néanmoins prendre en compte les spécificités des résultats donnés pour mieux les exploiter dans la perspective de notre travail : trouver des têtes aux différents segments d'un titre.

Avant d'aborder notre méthode pour résoudre le premier problème des segments sans tête, nous devons présenter le second problème de notre approche. La fiabilité de Talismane n'étant pas assurée sur des énoncés courts et généralement averbaux comme des titres, nous avons décidé d'estimer sa fiabilité. Nous avons choisi un échantillon de 20 titres aléatoirement pour chaque structure, en différenciant le cas numéro deux selon que le segment sans tête est le premier et le second. Nous avons également choisi 20 titres ayant un segment et deux têtes pour observer cet ensemble et éventuellement tenter d'en reprendre des titres. Nous avons vérifié manuellement pour ces 100 titres le choix de la tête, sa catégorisation morphosyntaxique et son lemme. Les résultats complets sont dans l'annexe [A5.C Analyse de 100 titres traités par Talismane](#). Si globalement, Talismane arrive à étiqueter morphosyntaxiquement et à trouver le lemme correctement dans des énoncés aussi courts que des titres, la fiabilité pour sélectionner les têtes diffère grandement selon la structure segments-têtes.

Avant d'aborder les résultats structure par structure, un premier point émerge : Talismane ne catégorise comme type de dépendance racine, « root » dans sa nomenclature, que les verbes. Pour les autres catégories, il reconnaît que la tête est le token racine de l'arbre de l'analyse en dépendances mais sans qualifier sa relation de dépendance de racine : il indique « _ » au lieu de « root ». Le second point qui émerge concerne les segments sans racine dans les titres ayant deux segments : on constate l'existence d'un mot qui est uniquement régi par un mot de l'autre segment. D'après nos analyses manuelles, ce mot est le plus souvent la tête de l'autre segment. Nous avons donc développé un algorithme de sélection des têtes pour suppléer les déficiences de Talismane tout en gardant le bénéfice de l'analyse syntaxique en dépendances. Notre algorithme est présenté en détail après les résultats.

A. Titres avec un segment et une tête

Sur les 20 titres pris, Talismane a à chaque fois détecté la bonne tête, avec la bonne catégorie morphosyntaxique et le bon lemme, sauf une fois, où l'absence d'un accent ne lui a pas permis de retrouver le lemme à partir de la forme. On peut donc estimer que les titres qui suivent cette structure sont correctement analysés par Talismane.

B. Titres avec un segment et deux têtes

Sur les 20 titres pris, Talismane a analysé incorrectement 12 titres et 8 ont une analyse discutable. Nous ne considérons pas le tiret et la virgule comme des caractères segmentants alors qu'ils sont clairement utilisés comme tels par un titre pour le tiret et deux titres pour la virgule. De plus, les mots composés provoquent des erreurs d'analyse dans Talismane qui désigne comme tête la partie après le tiret. Enfin, on remarque un oubli de signe de ponctuation segmentant et un crochet droit utilisé comme signe de ponctuation segmentant qui entraînent à chaque fois une mauvaise analyse.

Nous pourrions changer notre liste de caractères segmentants, mais cela reviendrait à créer potentiellement de nouvelles erreurs. Nous décidons donc de ne pas utiliser les titres ayant deux têtes dans un seul segment.

C. Titres avec un segment ayant une tête suivie d'un segment sans tête

Sur les 20 titres, notre algorithme permet de sélectionner une tête valide dans le segment n'en contenant pas pour 17 d'entre eux. Deux titres utilisent la virgule comme un caractère segmentant. Enfin un dernier échappe à notre algorithme de sélection d'un mot pour sa promotion en tête de segment.

D. Titres avec un segment sans tête suivi d'un segment avec tête

Sur les 20 titres, notre algorithme permet de sélectionner une tête valide dans le segment n'en contenant pas pour 18 d'entre eux. On note des erreurs d'analyse de Talismane liées à une mauvaise catégorisation morphosyntaxique de mots dont cinq entraînent une mauvaise sélection de la tête.

E. Titres avec un segment avec tête suivi d'un segment avec tête

Sur les 20 titres, 16 sont correctement analysés par Talismane qui trouve les têtes des segments. Pour trois titres la tête est mal catégorisée et pour un dernier le lemme n'est pas trouvé.

F. Algorithme de sélection de tête de segment

Notre algorithme pour détecter la tête d'un segment à partir du résultat de l'analyse de Talismane est le suivant :

- Soit un mot du segment sans tête est régi par la tête de l'autre → promotion de ce mot comme tête. 46 798 titres ont une tête sélectionnée de cette façon.
- Soit le premier mot du segment sans tête est régi par un mot de l'autre segment → promotion de ce mot comme tête. 8 866 titres ont une tête sélectionnée ainsi.

Nous récupérons en tout 55 664 titres, soit 98 % des 56 851 titres ayant deux segments mais une seule tête. Ces titres problématiques comptent pour 18 % de l'ensemble des titres à un ou deux segments. Cela nous permet de récupérer plus de titres valides selon notre définition qu'il doit y avoir une tête par segment et au maximum deux segments par titre.

Une fois les données récupérées et prétraitées, nous constituons notre corpus de travail. Il faut pour cela établir un périmètre qui délimitera notre corpus de travail. Il faut expliquer le choix de notre périmètre et effectuer des mesures dessus, afin de mettre en relation notre corpus de travail avec ceux étudiés précédemment dans la littérature.

I.2 Constitution d'un corpus de travail représentatif

Un périmètre de recherche établit dans le matériau de base une dichotomie claire entre ce que nous allons étudier et ce que nous n'étudierons pas. Plus il est large, plus il donne une fondation solide pour la confirmation ou l'infirmité d'hypothèses dessus. Mais plus il est large, plus nous risquons de nous confronter à des hapax, des phénomènes extrêmement rares remettant en cause confirmations et

infirmations ou rendant l'établissement de celles-ci beaucoup plus difficile. Nous pensons que, pour notre travail, le juste milieu est d'essayer de prendre le maximum de matériel tout en écartant les cas les plus rares. Notre périmètre sera constitué sur deux points : la structure segmentale des titres et la nature des têtes.

I.2.1 Sélection selon la structure des titres

Nous avons décidé de prendre les titres composés de seulement un ou deux segments. Nous justifions ce choix par le fait qu'il s'agit de la plus grande majorité des titres (320 561 soit 94 % des titres initiaux) et qu'ils sont plus faciles à analyser. De nombreux travaux didactiques sur l'écriture des titres (Aleixandre-Benavent et al., 2014 ; Swales et Feak, 1994 ; Gustavii, 2008) conseillent d'ailleurs d'organiser les titres en deux segments autour d'un double point soit la forme *segment 1: segment 2*.

Un autre délimiteur que nous utilisons pour établir notre périmètre, en plus du nombre de segments dans le titre, et le nombre de têtes par segments. Nous nous limiterons aux titres avec au maximum une tête par segment. On distingue donc deux cas : les titres composés d'un seul segment avec une tête et les titres composés de deux segments avec une tête chacun.

Il y a 171 890 titres composés d'un seul segment ayant une seule tête de segment, soit près de 51 % des données initiales, comme les exemples (9) et (10). Il y a 124 938 titres composés de deux segments, soit près de 37 % des données initiales, comme les exemples (11a), (11b) et (12). Nous indiquons entre indice la catégorie morphosyntaxique du lemme.

(9) L'**actualité**_{nom} de la jurisprudence communautaire et internationale

(10) **Doit**_{verbe} -on écouter Björk ?

(11a) Un nouvel **OVNI**_{nom} dans le ciel réunionnais : la **transparence**_{nom} des prix

(11a) La **performativité**_{nom} de l'évidence : **analyse**_{nom} du discours néolibéral

(12) **Traces**_{nom} de contenus africains sur Internet : **entre**_{préposition} homogénéité et identité

Du fait des limites entre les capacités de Talismane et notre définition des segments, certains segments n'ont pas de tête. Nous avons appliqué notre algorithme créé pour suppléer ces limitations.

Pour finir, nous gardons 110 785 titres composés de deux segments avec une tête dans chaque. Nous avons donc 171 890 titres monosegmentaux (61 %), 110 785 bisegmentaux (39 %), soit un corpus de travail de 282 675 titres, ce qui représente 83 % du matériau initial, les presque 340 000 titres collectés sur HAL. Nous avons réussi à conserver 83 % du matériau initial dans cette première étape de définition du périmètre de notre corpus de travail, néanmoins nous restreignons encore notre périmètre dans l'étape suivante pour nous intéresser à une catégorie morphosyntaxique particulière.

I.2.2 Sélection selon la nature des têtes

A) Répartition des natures des têtes

Nous nous sommes interrogés sur la nature de la tête des segments pour opérer une sélection sur ce critère. Cette question est directement liée à la question de la nature des titres. D'après

Schwischay (2001), « *un nœud forme avec tous les nœuds qu'il domine (directement ou indirectement) un syntagme ; et, par convention, ce syntagme porte le nom du nœud dominant* ». Nous pouvons donc, grâce à la complémentarité du modèle de l'analyse en constituants immédiats et celui de l'analyse en dépendances, déterminer le type de syntagme de chaque segment en étudiant la catégorie morphosyntaxique de sa tête à l'aide du tableau (2). La dernière colonne indique ces valeurs sur tous les segments des titres, soit 354 168 segments, en considérant les segments des titres bisegmentaux de façon indépendante.

Catégorie morphosyntaxique de la tête du segment	Titres monosegmentaux	Titres bisegmentaux, segment 1	Titres bisegmentaux, segment 2	Sur tous les segments (354168 segments)
Noms communs	136 734 80 %	82 959 75 %	84 960 77 %	304 653 86 %
Noms propres	11 094 6 %	10 406 9 %	4 758 4 %	26 258 7 %
Noms c. et p.	147 828 86 %	93 365 84 %	89 718 81 %	330 911 93 %
Verbes à l'indicatif	8 186 5 %	3 478 3 %	3 513 3 %	15 177 4 %
Verbes à l'infinitif	5 135 3 %	6 004 5 %	2 140 2 %	13 279 4 %
Tous les verbes	15 749 9 %	10 672 10 %	6 549 6 %	32 970 9 %
Prépositions	6 792 4 %	5 456 5 %	10 456 9 %	22 704 6 %

Tableau 2: Distribution des catégories morphosyntaxiques des têtes de segments

On peut remarquer des points communs : la grande majorité des têtes sont des noms, et a fortiori des noms communs, pour toutes les configurations segmentales. Les autres catégories les plus représentées sont les verbes à l'indicatif ou à l'infinitif et les prépositions. La différence la plus notable entre les premiers et seconds segments des titres bisegmentaux est que pour les seconds segments, la seconde catégorie la plus fréquente sont les prépositions et non les verbes : les têtes prépositionnelles sont presque deux fois plus fréquentes (9 %) que dans les segments des titres monosegmentaux (4 %) et dans les premiers segments des titres bisegmentaux (5 %).

On peut ensuite s'interroger sur les combinaisons possibles dans les titres bisegmentaux entre les catégories des deux têtes de segments. Nous agrégeons les différentes catégories nominales, verbales et prépositionnelles en trois catégories : Nom, Verbe et Préposition. Le tableau (3) présente les cinq combinaisons les plus fréquentes, sur 96 en tout. L'annexe [A2. Combinaisons des têtes de titres bisegmentaux](#) liste l'ensemble des 96 combinaisons existantes. Les cinq combinaisons les plus fréquentes couvrent 93 % des titres bisegmentaux. On constate là-aussi que la grande majorité des titres bisegmentaux ont à chaque fois un nom pour tête de segment.

Catégorie de la tête du premier segment	Catégorie de la tête du second segment	Nombre de titres et pourcentage
Nom	Nom	75 592 (68 %)

Nom	Préposition	8 996 (8 %)
Verbe	Nom	8 506 (8 %)
Nom	Verbe	5 426 (5 %)
Préposition	Nom	4 650 (4 %)

Tableau 3 : Combinaisons agrégées les plus fréquentes de têtes dans les titres bisegmentaux

Notons qu'il existe 409 titres dont le premier et le second segment ont le même lemme pour tête. Ce qui vient à l'esprit en regardant les exemples de (13) à (18), c'est la possibilité d'achever un effet stylistique de répétition et la possibilité d'introduire une comparaison ou un questionnement :

- (13) La **crise** ? Quelle **crise** ?
(14) **Crise** du logement ? Quelle **crise** ?
(15) **Ville** de jour. **Ville** de nuit
(16) **Linux** embarqué. **Linux** Temps Réel
(17) **Feu** l'arrêt Mercier ! **Feu** l'arrêt Mercier ?
(18) **Corps** dansant. **Corps** glorieux

B) La nature nominale des titres

Chercher la nature d'un titre revient à s'interroger sur la nature de ses têtes de segments. Pour les titres monosegmentaux, déterminer la nature du titre revient à prendre la nature de son unique segment. On obtient à partir du tableau (2) directement 86 % de titres nominaux. Pour les titres bisegmentaux, on peut considérer deux options. La première est qu'un titre est nominal si son premier segment l'est. On obtient alors 84 % de titres nominaux. L'autre option est de considérer qu'un titre est "purement" nominal si et seulement si les deux têtes de ses segments sont des noms. On obtient alors 68 % de titres nominaux.

Quelle que soit la solution choisie, les titres sont majoritairement constitués d'un ou plusieurs syntagmes nominaux et non d'une phrase avec un noyau verbal, ce qui rejoint les conclusions de nos prédécesseurs (Leech, 2000 ; Haggan, 2004 ; Soler, 2007 ; Cheng et al., 2012 ; Wang et Bai, 2007). Cheng et al. (2012) relèvent jusqu'à 93 % de titres nominaux pour leur corpus et Wang et Bai (2007) relèvent 99 % pour leur corpus.

Pour notre corpus de travail, nous décidons de nous restreindre aux titres monosegmentaux dont la tête est un nom et aux titres bisegmentaux dont au moins une des têtes de ses segments est un nom, l'autre pouvant être un nom, une préposition ou un verbe. Ce choix nous permet de garder la grande majorité de nos titres et d'éliminer les cas les moins fréquents, suivant ainsi le principe de *From-Corpus-To-Cognition* de Schmid (2000, p. 47) qui est que « *despite the indisputable charm of rare or exotic examples, one should mainly be interested in frequent and therefore systemically and cognitively more important items* ». Nous obtenons un corpus de 250 998 titres, soit 74 % du matériau initial, ce qui

nous semblait important pour renforcer nos hypothèses en les établissant sur le plus grand nombre possible de faits linguistiques.

Une fois le périmètre des titres étudiés défini sur la structure segmentale des titres et la nature grammaticale de leurs têtes, nous avons constitué notre corpus de travail. Nous pouvons alors effectuer plusieurs mesures sur notre corpus et les mettre en rapport avec les mêmes mesures effectuées dans des travaux précédents, avant d'étudier plus avant les têtes de syntagmes.

I.2.3 Un corpus de travail représentatif du matériau de base

Nous avons défini notre périmètre d'étude comme portant sur 250 998 titres constitués d'un ou deux segments. Les titres monosegmentaux (147 828 soit 59 %) ont une tête nominale, les titres bisegmentaux (103 170, 41 %) ont au moins un segment ayant une tête nominale, l'autre ayant une tête verbale, nominale ou prépositionnelle.

On notera que les différentes caractéristiques des titres ne sont pas indépendantes : Kutch (1978), Yitzhaki (1994) et Tanguy et Rebeyrolle (à paraître) ont ainsi montré que le nombre d'auteurs est corrélé positivement à la longueur du titre. Larivière et al. (2015) ont montré que le domaine est lié au nombre d'auteurs : il y a en moyenne plus d'auteurs dans les sciences exactes. Baethge (2008) a montré que le nombre d'auteurs augmente avec le temps. Tanguy et Rebeyrolle (à paraître) ont également montré, en partant des mêmes données de base et donc avec le même déséquilibre de répartition, que la longueur était très légèrement corrélée à l'année de publication.

Sur la longueur des titres, les titres monosegmentaux ont une longueur moyenne de 10,38 mots, avec une longueur minimale de 1 mot et une longueur maximale de 77 mots, tandis que les titres bisegmentaux ont une longueur moyenne de 14,45 mots, avec une longueur minimale de 2 mots et une longueur maximale de 228 mots. Les titres bisegmentaux les plus courts sont au nombre de 64, 49 utilisent comme signe segmentateur le double point et 51 sont des chapitres d'ouvrage dont 29 sont de la forme *Entrée : NC*, indiquant une entrée dans un ouvrage de type dictionnaire ou encyclopédie. La longueur supérieure des titres bisegmentaux s'explique par la facilité de traitement qu'apporte la segmentation à l'interlocuteur : la segmentation sert à la fois de pause et d'articulation pour sa compréhension. La longueur moyenne des titres du corpus de travail est de 12,05 mots, alors que celle des données de départ est de 13,8 mots. Cette constatation est normale car il existe des titres ayant plus de deux segments que notre corpus de travail n'inclut pas.

On peut regarder comment nos corpus se répartit en fonction du type de publication scientifique :

Type de publication	Titres monoseg.	Titres biseg.	Corpus
Article	63 993 43 %	45 827 44 %	109 820 44 %
Communication	53 148 36 %	35 350 34 %	88 498 35 %
Chapitre d'ouvrage	29 413 20 %	21 221 21 %	50 634 20 %
Poster	1 274 1 %	772 1 %	2 046 1 %

Tableau 4: Distribution des structures des titres selon le type

La structure des titres n'est pas corrélée au type de publication, la distribution des deux ensembles étant presque identique. De plus, cette répartition est quasi identique à celle de l'ensemble des 340 000 titres qui constituent nos données de départ (Tanguy et Rebeyrolle, à paraître).

On peut aussi mesurer le nombre d'auteurs en fonction de la structure du titre :

Nombre d'auteurs	Titres monoseg.	Titres biseg.	Corpus
1	87 646 59 %	65 199 63 %	152 845 61 %
1-4	135 564 92 %	96 581 94 %	232 145 92 %
1-9	146 767 99 %	102 307 99 %	249 074 99 %

Tableau 5 : Distribution des structures des titres selon le nombre d'auteur

On voit bien que quelle que soit la structure du titre, la répartition par le nombre d'auteurs est la même pour les deux sous-ensembles de notre corpus de travail que pour le corpus de travail pris dans sa totalité et sur l'ensemble des données où 62 % des articles avaient également un seul auteur.

On regarde également la répartition par années de publication. Pour l'ensemble du corpus, elles s'étendent de 2019 pour les sept publications les plus récentes à 1779 pour la plus ancienne. On note que 85 % des publications ont été publiées en 2000 ou après, 90 % après 1994 et 99 % après 1933. Pour l'ensemble des données, Tanguy et Rebeyrolle (à paraître) trouvent les mêmes années pour les deux premiers pourcentages et un peu plus tard, 1940, pour le dernier. Notre corpus ne peut donc pas servir pour des études diachroniques du fait de sa répartition totalement inégale sur le temps. La période qui comporte le plus de titres, de 2005 à 2017, soit 74 % du corpus, est également trop courte. La répartition est similaire pour nos deux sous-corpus, titres monosegmentaux et bisegmentaux. Nous pouvons à présent étudier comment la structure segmentaire des titres et les têtes varient selon les domaines.

I.3 Structures semblables des domaines et têtes spécifiques

I.3.1 Variations de la structure en fonction du domaine

Nous regardons à présent la répartition des titres par domaine pour le corpus et les deux sous-corpus. Nous rappelons que nous avons sélectionné, grâce à la méthode décrite dans Tanguy et Rebeyrolle (à paraître), un seul domaine principal pour chaque titre. Le tableau suivant présente les 27 domaines qui existent dans notre corpus. Nous avons mis en gras les domaines des sciences exactes.

N°	Domaine	Corpus Nb/fréq/fréq. cumul	Répartition entre	
			Titres monosegmentaux	Titres bisegmentaux
01	Physique	26 559 11% 11%	81 %	19 %
02	Sociologie	23 732 9% 20%	48 %	52 %

03	Droit	21 486	9%	29%	67 %	33 %
04	Histoire	19 093	8%	36%	54 %	46 %
05	Pas de domaine associé	18 941	8%	44%	59 %	41 %
06	Gestion et management	18 318	7%	51%	45 %	55 %
07	Sciences du vivant	17 498	7%	58%	66 %	34 %
08	Informatique	13 505	5%	63%	74 %	26 %
09	Linguistique	11 556	5%	68%	52 %	48 %
10	Littératures	10 712	4%	72%	52 %	48 %
11	Archéologie et Préhistoire	10 124	4%	76%	61 %	39 %
12	Science politique	7 152	3%	79%	46 %	54 %
13	Éducation	7 062	3%	82%	50 %	50 %
14	Art et histoire de l'art	6 471	3%	85%	53 %	47 %
15	Philosophie	6 152	2%	87%	60 %	40 %
16	Sciences de l'environnement	5 542	2%	89%	54 %	46 %
17	Sciences de l'information et de la communication	5 481	2%	91%	46 %	54 %
18	Anthropologie	5 166	2%	93%	51 %	49 %
19	Architecture	3 444	1%	95%	51 %	49 %
20	Planète et Univers	2 781	1%	96%	62 %	38 %
21	Mathématiques	2 377	1%	97%	81 %	19 %
22	Sciences cognitives	2 370	1%	98%	53 %	47 %
23	Chimie	2 185	1%	99%	69 %	31 %
24	Psychologie	2 006	1%	99%	54 %	46 %
25	Géographie	860	0%	100%	51 %	49 %
26	Économie et finance quantitative	346	0%	100%	47 %	53 %

27	Autres	79 0% 100%	54 %	46 %
	Sciences exactes	73 163 29%	72 %	28 %
			moyenne 65 % écart-type 0.11 écart-type relatif 18 %	
	Sciences humaines et sociales	177 835 71%	54 %	46 %
			moyenne 53 % écart-type 0.06 écart-type relatif 10 %	

Tableau 6 : Distribution des structures selon le domaine

On compte 73 163 titres en sciences exactes, ce qui représente 29 % de notre corpus et 177 835 titres en sciences humaines et sociales, soit 71 %.

Les sciences exactes globalement privilégient plus les titres monosegmentaux que les sciences humaines et sociales. Si l'on regarde la moyenne des répartitions par domaine, l'écart-type relatif important nous pousse néanmoins à la prudence. Parmi les sciences exactes, les mathématiques et la physique utilisent le plus fréquemment des titres monosegmentaux, où ils représentent 81 % des titres. Ces domaines sont suivis par l'informatique, où ils représentent 74 % des titres, suivie de la chimie avec 69 %, des sciences du vivant avec 66 % et des sciences des planètes et de l'univers avec 62 %.

Les sciences humaines et sociales sont globalement plus équilibrées entre l'utilisation de titres monosegmentaux et bisegmentaux. L'écart-type relatif de 10 % montre néanmoins que cet équilibre global varie d'un domaine à l'autre. Ainsi le droit avec 67 %, l'archéologie et la préhistoire avec 61 % et la philosophie avec 60 % privilégient elles aussi le titre monosegmental.

Si on compare la répartition par domaine de notre corpus de travail par rapport à l'ensemble des données initiales, nous avons le même ordre que celui relevé par Tanguy et Rebeyrolle (à paraître). Nous notons également que la répartition entre les domaines n'est pas homogène, certains étant très peu représentés, les plus faiblement dotés étant la géographie avec 860 titres, l'économie et finance quantitative avec 346 titres, et le domaine autres avec 79 titres. D'où la nécessité de travailler en fréquence relative pour les phénomènes que nous étudierons tout en retenant qu'une fréquence relative peut dissimuler un très petit phénomène : un phénomène ayant une fréquence relative importante de 15 % dans le domaine autre, ne concernera finalement que 11 titres, rendant ce calcul très sensible à l'ajout ou au retrait d'un titre dans l'ensemble considéré.

I.3.2 Têtes spécifiques à un domaine

A) Définition et principe de sélection

Nous souhaitons faire émerger une liste de têtes spécifiques aux domaines et interpréter ce qu'on y trouve. Intuitivement, on peut penser retrouver les principaux objets d'étude des différents

domaines. Pour chaque tête, on peut établir deux séries statistiques ayant autant de valeurs qu'il y a de domaines :

- Les fréquences relatives de la tête dans les différents domaines :

$$\frac{\text{nombre d'occurrences de la tête dans le domaine}}{\text{total des occurrences des têtes du domaine}}$$

- La répartition relative des occurrences de la tête entre les différents domaines :

$$\frac{\text{nombre d'occurrences de la tête dans le domaine}}{\text{total des occurrences de la tête dans le corpus}}$$

Nous cherchons dans cette partie indifféremment les noms communs et les noms propres. Pour un résultat plus interprétable, lorsqu'une tête de segment qui est un nom propre est suivie par un autre nom propre, ou *de* et un autre nom propre, nous concaténons cette séquence en une seule forme qui devient la nouvelle tête, pour éventuellement réunir un prénom, optionnellement la particule et un nom. Nous estimons qu'il est plus intéressant de tester si *Gustave Eiffel*, *Gustave Flaubert* et *Gustave Guillaume* sont des têtes spécifiques à un domaine que *Gustave* qui est beaucoup plus générique.

Pour être véritablement spécifique à un domaine, une tête doit y être très fréquente mais également apparaître le moins possible dans d'autres domaines. Nous avons décidé d'utiliser pour sélectionner les têtes spécifiques le calcul de TF*IDF en l'adoptant à notre configuration particulière. Nous considérons en effet chaque domaine comme un seul vaste document où apparaîtrait tous les titres, le TF est alors la fréquence du terme dans le domaine. Le TF*IDF adapté devient alors :

$$TF * \log_{10}(\text{nombre total de domaines} / \text{nombre de domaines avec ce terme})$$

Le calcul de têtes spécifiques à un domaine n'a pas de sens pour le domaine Autres et les titres sans domaine associé : nous gardons donc seulement 25 domaines pour nos calculs. Chaque tête aura alors une valeur de TF*IDF par domaine, son coefficient de spécificité. Une tête présente dans les 25 domaines aura un TF*IDF de zéro.

B) Corrections de Talisman

Nos résultats, basés sur un faible nombre d'occurrences, peuvent être très sensibles à un mauvais traitement d'un mot. Pour les améliorer, nous avons corrigé certaines erreurs et limitations de l'étiquetage morphosyntaxique et de la lemmatisation opérés par Talisman en établissant un dictionnaire de corrections. Le tableau (7) liste nos 13 catégories d'erreurs. Pour savoir comment les corriger, nous avons regardé les différents titres concernés pour établir à chaque fois une règle ad-hoc, la colonne Nombre indiquant le nombre de corrections effectuées :

Erreur ou limitation	Correction	Exemples	Nombre
1. Faux nom propre Nom commun erronément catégorisé comme nom propre avec un lemme	Lemme ajouté, catégorie corrigée à nom commun.	Effet, Adolescence, Autoformation, Approche, Cohomologie, Teneur,	228

inconnu car forme avec une majuscule		Polyhandicap	
2. Faux nom commun Nom propre erronément catégorisé commun nom	catégorie corrigée à nom propre	bitcoin, créacé	16
3. Lemme de nom commun non reconnu car erreur d'orthographe	Lemme corrigé, catégorie corrigée pour Synthèse	Quantification, événement, indicateurs (-r), Synthèse	17
4. Lemme de nom commun non reconnu car caractère non compris	Lemme corrigé (en écrivant oeuvre)	œuvre	876
5. Lemme de nom commun non reconnu	Lemme ajouté	démotorisation, maritimisation, Compactification, Ondettes	849
6. Lemme de nom propre non reconnu	Lemme corrigé	Paris, Freud	1927
7. Lemme de nom propre non reconnu car concaténation du prénom et du nom	Lemme corrigé (nous concaténons prénom et nom lorsque nous avons une tête constituée d'une suite de deux noms propres : ceci n'est pas pris en compte par Talismane et n'est pas à proprement parler une erreur de celui-ci)	Jacques Androuet, Claude Perrault, Jean Cocteau	66
8. Forme faussement reconnue comme nom alors qu'il s'agit d'un adjectif	Forme non prise en compte et retirée de nos calculs	Cyber, Environnemental, Global	36
9. E- et Semi- considérés comme un nom propre indépendant	Lemme corrigé en e- ou semi- + lemme suivant	E-chronic, E-commerce, E-administration, e-inclusion, Semi-figement	608
10. s considéré comme un nom commun à cause d'un signe de ponctuation	On regarde à gauche et à droite du s pour trouver un nom commun ou un nom propre après un signe de ponctuation	mobilité.s, Linguistique(s), Quel(s) avenir(s)	404
11. Mot anglais non reconnu catégorisé à tort	Forme non prise en compte et retirée de nos calculs, provenant	The	59

comme nom commun	de titres en anglais.		
12. Nom commun anglais non reconnu	Prise en considération de son lemme en français	Synthesis, risk, Treatment	21
13. Emploi d'un nom propre au pluriel	Lemme corrigé à la forme singulière	Venises	1

Tableau 7 : Corrections opérées sur l'étiquetage et la lemmatisation

Une fois ces corrections effectuées sur notre corpus de travail, nous pouvons passer notre filtre dessus pour obtenir les têtes spécifiques à certains domaines, en les classant par leur valeur de TF*IDF.

C) Évaluation des résultats

Avec la formule du TF*IDF, toutes les têtes d'un domaine seront classées par ce facteur de spécificité. Le nombre de têtes différentes par domaine va de 272, pour l'économie et finance quantitative, à 7 005 pour l'histoire en comptant les têtes ayant un facteur d'une valeur de zéro. On compte en tout 30 410 têtes différents. Nous présentons dans le tableau (8) ci-dessous un extrait de notre résultat en prenant arbitrairement 10 têtes pour nos 25 domaines. Pour chaque domaine, classés par ordre alphabétique, nous indiquons trois nombres : le nombre de lemmes de têtes, le nombre d'occurrences de têtes et le nombre de titres.

	Domaine	Têtes associées
01	Anthropologie 2 579 / 6 942 / 5 166	ethnologie, ethnologue, anthropologie, ethnographie, Népal, sépulture, pentecôtisme, François Cadic, rite, rituel
02	Archéologie et préhistoire 3 444 / 13 391 / 10 124	céramique, sanctuaire, décor, nécropole, sépulture, occupation, mobilier, archéologie, vaisselle, habitat
03	Architecture 1 624 / 4 629 / 3 444	ambiance, urbanisme, ville, fortification, habitat, château, photogrammétrie, quartier, Broadacre City, concepteur
04	Art et histoire de l'art 3 376 / 8 685 / 6 471	vitrail, verrière, décor, musique, peinture, sculpture, notice, théâtre, artiste, peintre
05	Chimie 788 / 2 710 / 2 185	catalyse, catalyseur, oxydation, ligand, polymère, spectroscopie, hydrogénation, nanoparticule, membrane, préparation
06	Droit 4 189 / 26 398 / 21 486	droit, juge, clause, obligation, contentieux, chronique, garantie, cession, responsabilité, jurisprudence
07	Économie et finance quantitative 272 / 489 / 346	aversion, GRP, déterminant, complexification, aluminium, assuabilité, polyhandicap, Solvency II, traitement, Paul W
08	Éducation 1 786 / 9 445 / 7 062	autoformation, didactique, éducation, e-inclusion, hypermédia, enseignant, informatique, scolarisation,

		ordinateur, TICE
09	Géographie 604 / 1 191 / 860	démographie, excision, SIDA, fécondité, vigie, mutilation, écologie, appui, géomorphologie, scolarisation
10	Gestion et management 3 546 / 25 955 / 18 318	comptabilité, management, finance, financement, déterminant, gouvernance, marketing, GRH, RSE, internationalisation
11	Histoire 7 005 / 25 671 / 19 093	évêque, noblesse, historiographie, manuscrit, femme, guerre, notice, abbaye, protestant, italien
12	Informatique 3 281 / 16 241 / 13 505	algorithme, ordonnancement, segmentation, extraction, optimisation, routage, détection, minimisation, visualisation, spécification
13	Linguistique 3 435 / 15 512 / 11 556	néologie, figement, verbe, préposition, grammaticalisation, phonologie, syntaxe, prosodie, adjectif, corpus
14	Littératures 5 142 / 14 278 / 10 712	littérature, roman, Proust, poétique, Perceforest, poésie, théâtre, Montaigne, René Char, poème
15	Mathématiques 888 / 2 745 / 2 377	cohomologie, théorème, estimation, package, approximation, optimisation, mathématique, algorithme, compactification, Mixmod
16	Philosophie 2 800 / 7 856 / 6 152	philosophie, Leibniz, Spinoza, Descartes, Bergson, Kant, Habermas, Nietzsche, Poincaré, Henri Poincaré
17	Physique 3 603 / 30 667 / 26 559	antenne, optimisation, spectroscopie, spectre, laser, propagation, absorption, excitation, commande, diffraction
18	Planète et Univers 1 244 / 3 675 / 2 781	ammonite, géologie, Crétacé, gisement, forage, métamorphisme, excursion, datation, bassin, massif
19	Psychologie 943 / 2 663 / 2 006	autisme, psychologie, psychologue, sevrage, psychanalyse, scarification, psychodrame, psychose, clinique, hallucination
20	Science politiques 2 520 / 9 864 / 7 152	élection, parti, sociologie, justice, Turquie, État, politisation, décentralisation, vote, parlement
21	Sciences cognitives 1 164 / 3 141 / 2 370	précocité, proverbe, adjectif, grammaticalisation, catégorisation, phonologie, but, psychologie, prosodie, NBIC
22	Sciences de l'environnement 1 983 / 7 484 / 5 542	brève, bibliographie, agriculture, karst, muraille, Pralognan, cadastre, émission, forêt, Médiaterre
23	Sciences de l'information et de la communication	journalisme, média, bibliothèque, télévision, sémiotique, journaliste, SIC, communication, blog, open

	2 053 / 7 523 / 5 481	
24	Sciences du Vivant 3 800 / 22 149 / 17 498	dosage, protéine, lait, acide, sécrétion, digestion, infection, alimentation, teneur, nutrition
25	Sociologie 5 268 / 32 398 / 23 732	sociologie, ville, géographe, géographie, tourisme, nuit, quartier, socialisation, déscolarisation, territoire

Tableau 8 : Les 10 têtes les plus spécifiques de chaque domaine

On constate plusieurs faits : le premier est une mise en garde sur la limite de 10 têtes choisie pour la présentation de ce tableau. Selon le nombre de titres et le nombre de lemmes différents dans le domaine, les mots sélectionnés peuvent avoir des nombres d'occurrences très variés. Plus le nombre de titres étudiés est faible, plus les résultats sont très sensibles.

Dans l'éducation, on constate la présence dans les 10 premières spécifiques de *ordinateur* alors qu'il apparaît en 72^e position en informatique. Avec seulement 12 occurrences en informatique, on peut présumer qu'il s'agit là d'un terme trop générique pour la science dont c'est le principal objet et donc délaissé dans les titres soumis à une forte contrainte informationnelle et de concision.

Les sciences cognitives, avec seulement 2 370 titres, sont à la croisée de plusieurs domaines, notamment la linguistique et la psychologie, ce qui peut expliquer la non-présence de têtes « propres ».

Seule l'évaluation des résultats permet de juger de la pertinence de notre méthode. Le premier contrôle que nous pouvons effectuer, bien que très subjectif et limité, et de parcourir nous-même ces têtes, classées par TF*IDF pour voir si les premières semblent plus correspondre au domaine associé que les suivantes. Ce premier contrôle est positif : les têtes avec le plus haut TF*IDF semblent effectivement les plus proches des objets d'études des domaines, comme *céramique* et *nécropole* pour l'archéologie. L'extrême majorité des têtes ayant un TF*IDF élevé est ce que Schmid (2000, p. 15) appelle des *full-content nouns* ayant un contenu sémantique important. Nous remarquons néanmoins la tête *brève*, pour le domaine des sciences de l'environnement, qui ne désigne pas un objet d'étude mais un support de publication.

Une méthode d'évaluation aurait été de comparer les têtes avec des lexiques spécialisés pour mesurer la précision et le rappel. Néanmoins, cela exige de ne sélectionner qu'une partie des têtes spécifiques à l'aide d'un filtre pour ne pas avoir trop de bruit. Ce filtre peut être un seuil appliqué à la valeur de TF*IDF plutôt que de prendre les X premières têtes. Il faudrait dans ce cas faire attention au taux de couverture des têtes sélectionnées par un tel seuil : plus il sera élevé, plus on sera sûr d'avoir des têtes spécifiques au détriment du nombre de titres couverts.

Une autre approche est de calculer une distance entre les domaines : si on assimile les domaines à un sac de têtes, où pour chaque tête, on met la valeur de son TF*IDF ou 0 si la tête n'apparaît pas dans le domaine, on obtient un vecteur à 30 410 dimensions. On peut ensuite calculer une distance généralisée entre les domaines pour savoir lesquels sont les plus proches et les plus éloignés en termes de têtes dont l'annexe [A1. Distance des domaines de par leurs têtes spécifiques](#) présente le résultat. On constate ainsi que la sociologie a pour domaine le plus proche le domaine gestion et management et comme domaine le plus éloigné la chimie. Cette représentation permet d'avoir un aperçu de comment

les domaines se positionnent les uns par rapport aux autres par la spécificité de leurs têtes et ainsi vérifier la validité de notre approche.

Un lemme peut avoir une valeur distinctive de $TF*IDF$ dans plusieurs domaines, ce qui traduit que cet objet d'étude est partagé par les différents domaines et qu'il n'a pas de pertinence pour un grand nombre d'autres. L'importance dans chaque domaine est pondérée par la valeur de $TF*IDF$. Par exemple, *femme* a une valeur de 0,0003 en géographie, sciences de l'information et de la communication et psychologie, 0,0004 en sociologie, anthropologie et littérature et 0,0007 en histoire. Néanmoins, une forte limite de cette approche est la polysémie de certaines têtes. L'*architecture* en informatique n'est pas la même que dans le domaine de l'architecture, de même qu'une *tempête* en sciences exactes et en sciences humaines et sociales.

Nous avons dans cette partie établi le périmètre délimitant notre corpus de travail et mesuré ses contours. Nous avons décidé d'étudier le cas le plus nombreux : celui des titres monosegmentaux ou bisegmentaux possédant au moins une tête nominale.

Notre corpus de travail se compose de 250 998 titres, soit 74 % du matériau initial. Notre corpus de travail est représentatif du matériau initial en ce qui concerne la répartition des titres par type de publication, nombre d'auteurs ou domaine. Nous avons démontré que les titres sont essentiellement des syntagmes nominaux à 85 % si on ne considère que le premier segment des titres bisegmentaux et les titres monosegmentaux.

Nous avons relevé que la répartition des titres par domaine n'est pas homogène, 71 % des titres se rapportent aux sciences humaines et sociales contre 39 % pour les sciences exactes. Les premières utilisent de façon à peu près égale les titres monosegmentaux et bisegmentaux alors que les sciences exactes favorisent les titres monosegmentaux. Nous avons également calculé un indice de spécificité des têtes par rapport à un domaine particulier en se fondant sur le $TF*IDF$.

Nous voulons à présent étudier des têtes qui sont à l'inverse des têtes spécifiques : des têtes des fréquentes dans toutes les disciplines, que nous appellerons têtes transdisciplinaires.

II. Têtes transdisciplinaires et NSS dans notre corpus

Dans cette partie, nous nous intéressons aux têtes de nos segments. Nous avons vu que nous avons une tête par segment et de un à deux segments par titre. Cela fait donc trois sous-ensembles de notre corpus de travail : les segments des titres monosegmentaux, les premiers segments des titres bisegmentaux et les seconds segments des titres bisegmentaux. Nous allons étudier dans ces trois ensembles les têtes de segments qui sont très fréquentes dans de nombreux domaines, des têtes que nous appellerons transdisciplinaires. Ce sont ces dernières têtes, que nous voulons rapprocher des noms sous-spécifiés que nous décrivons dans la sous-partie suivante. Enfin, nous abordons les schémas récurrents dans lesquels s'insèrent nos têtes transdisciplinaires pour essayer d'en faire le rapprochement avec les constructions spécificationnelles des noms sous-spécifiés.

II.1 Sélection des têtes transdisciplinaires

II.1.1 Principe de sélection

Pour être véritablement transdisciplinaire, une tête ne doit pas seulement se retrouver dans de nombreux domaines. Elle doit se retrouver *fréquemment* dans de nombreux domaines. Nous nous méfions de la moyenne des fréquences relatives de la tête dans les différents domaines car elle peut cacher des situations très disparates. Nous préférons prendre les têtes qui apparaissent avec un seuil minimum dans la moitié des domaines étudiés dans notre corpus. Nous établissons donc un seuil arbitraire de 0,001 (0,1 %), que nous nommons **seuil de médiane**, au-dessus duquel nous sélectionnons nos têtes transdisciplinaires.

II.1.2 Résultats et évaluations du résultat

Sur les 123 227 lemmes de têtes de notre corpus de travail, cela en sélectionne 94 soit 0,08 %. Elles ont en tout 94 738 occurrences, soit près de 27 % des 354 168 occurrences de têtes que comptent notre corpus. Elles couvrent 93 457 titres, soit 37 % des titres de notre corpus. Les occurrences de ce très petit nombre de têtes transdisciplinaires concentrent plus d'un quart de toutes les têtes et plus d'un tiers de tous les titres.

Les 20 premières têtes des 94 classés par la médiane sont : *étude, analyse, cas, approche, exemple, enjeu, évolution, apport, rôle, modèle, réflexion, évaluation, outil, question, représentation, application, construction, introduction, histoire* et *développement*. La liste complète est fournie dans l'annexe **A3. Liste des têtes transdisciplinaires**. Aucun nom propre ne figure dans cette liste ce qui est logique. Il s'agit de noms communs abstraits ayant un faible contenu sémantique.

Le premier contrôle possible pour tester la validité de notre filtre est de compter les domaines où ces têtes sont présentes. Tutin (2008) fixe la présence d'une forme dans 15 domaines comme marque de sa transdisciplinarité. 15 domaines représentent 60 % des 25 domaines retenus pour nos calculs sur les 27 de notre corpus. Nos 94 têtes transdisciplinaires sont au minimum présentes dans 20 domaines, soit 80 % des 25 domaines. 35 têtes transdisciplinaires sont présentes dans les 25 domaines.

Le nombre moyen de domaine où les 94 têtes sont présentes est 23,95 ce qui est extrêmement élevé sachant que le nombre minimum de domaines est de 20.

Un second contrôle est de le confronter à la liste des noms du lexique transdisciplinaire des écrits scientifiques (LTES) établie par Tutin (2007, 2008). Sur les 94 têtes transdisciplinaires, 74 sont présentes dans le LTES soit 79 %. Les 20 têtes qui ne figurent pas dans le LTES sont : *enjeu, histoire, dynamique, regard, impact, retour, essai, politique, enseignement, note, formation, science, remarque, émergence, point, conception, méthodologie, discours, défi, jeu*. Il nous semble paradoxal que certains lemmes ne figurent pas dans le LTES, surtout ceux sémantiquement liés directement à la science comme *méthodologie* ou *science*. Les autres peuvent avoir été considérés comme trop génériques : il en effet difficile de délimiter ce qui est propre à la science, le lexique transdisciplinaire des écrits scientifiques étant considéré comme un sous-ensemble d'un lexique abstrait général (Tutin, 2007).

II.1.3 Études des têtes selon leurs segments et la structure segmentale du titre

Nous avons ensuite étudié les variations des têtes transdisciplinaires entre trois sous-ensembles de notre corpus de travail : les titres monosegmentaux, les premiers segments des titres bisegmentaux, puis leurs seconds segments. Nous traitons les segments des titres bisegmentaux séparément pour essayer de déterminer d'éventuelles différences entre les deux.

Pour les titres monosegmentaux, les têtes transdisciplinaires relevées sont au nombre de 81. Six seulement d'entre elles n'apparaissent pas dans les 94 têtes transdisciplinaires relevés sur tout le corpus. Les six têtes sont : *contrôle, fonction, notion, temps, transformation* et *valeur*. Pour le premier segment des titres bisegmentaux, nous relevons 63 têtes transdisciplinaires. Cinq têtes n'apparaissent pas dans les 94 précédemment relevées : *compte, contribution, culture, économie* et *identité*. Dans le second segment, nous relevons 99 têtes transdisciplinaires et 19 têtes n'apparaissent pas dans les 94 têtes transdisciplinaires relevés sur tout le corpus : *condition, contexte, définition, démarche, donnée, illustration, leçon, limite, mode, mythe, paradoxe, parcours, piste, problématique, réalité, revue, source, synthèse* et *voie*. Si on dénombre toutes les têtes transdisciplinaires relevées par l'étude du corpus et des trois sous-corpus, on obtient le nombre de 123. Le tableau (5) résume le nombre de têtes transdisciplinaires trouvées par corpus.

Corpus	Nombre de têtes transdisciplinaires
Ensemble du corpus de travail	94
Titres monosegmentaux	81
Premier segment des titres bisegmentaux	63
Second segment des titres bisegmentaux	99
Fusion des quatre listes	123

Tableau 9 : Nombre de têtes transdisciplinaires selon le corpus choisi

Un fait remarquable du sous-corpus de travail des seconds segments de titres bisegmentaux, c'est que certaines têtes transdisciplinaires sont surreprésentées spécifiquement dans ce corpus. Les occurrences des têtes *cas, exemple, étude, application* et *approche* représentent respectivement 4 %, 3 % et 2 % pour les trois dernières des 95 282 occurrences de têtes de ce sous-corpus. Cette très forte présence ne se rencontre pas dans l'ensemble du corpus et le corpus des premiers segments des titres bisegmentaux. Les occurrences de la tête *étude* du corpus de travail ne représente que 2 % du total des

occurrences de têtes, celles des têtes analyse et étude près de 1 % du corpus des premiers segments des titres bisegmentaux. Uniquement voit-on dans le sous-corpus des titres monosegmentaux pointer *étude* à 3 %. Il y a donc une concentration remarquable sur un petit nombre de têtes dans le sous-corpus des seconds segments de titres bisegmentaux.

On peut également étudier les titres bisegmentaux en prenant les deux têtes ensembles, formant ainsi des couples ordonnés de la forme (tête premier segment, tête second segment). Seuls cinq couples ont une médiane différente de 0 : (*de, exemple*), (*rôle, cas*), (*approche, cas*), (*apport, exemple*) et (*effet, cas*). L'apparition de la préposition *de* s'explique car nous exigeons qu'une des têtes soient un nom, l'autre peut être un verbe ou une préposition. La préposition *de* étant la plus fréquente, il est logique qu'elle apparaisse dans les couples les plus fréquents. Cette préposition est utilisée dans des structures de la forme *de ... vers ...*, *de ... à ...* étudiées par Tanguy et Rebeyrolle (à paraître), mais comme il ne s'agit pas d'un nom nous l'écartons ici.

Nous avons identifié 94 têtes transdisciplinaires dans notre corpus de titres, à la fois très fréquente et ayant un très faible contenu sémantique. Ces deux caractéristiques les rapprochent d'une classe d'emploi des noms, les noms sous-spécifiés, très fréquentes dans le discours académique.

II.2 Noms sous-spécifiés et constructions spécificationnelles

II.2.1 Définitions des noms sous-spécifiés

De nombreux travaux avec différentes perspectives se sont penchés sur les noms sous-spécifiés en anglais et plus tardivement en français. Les définitions théoriques et opératoires de ces différents auteurs ne se recoupent pas exactement, ainsi que la liste des noms pouvant être employé de la sorte, ce qui se traduit par un foisonnement terminologique (Flowerdew et Forest, 2015, p. 9 ; Schmid, 2000, p. 10-11) : *container nouns* (Vendler, 1968), *signalling nouns* (Flowerdew 2003, 2006 ; Flowerdew et Forest, 2015), *type 3 vocabulary* (Winter, 1977), *metadiscursive nouns* ou *anaphoric nouns* (Francis, 1986), *enumerables* et *advance labels* (Tadros, 1994), *carrier nouns* (Ivanic, 1991), *advance labels* et *retrospective labels* (Francis, 1994), *unspecific nouns* ou *metalanguage nouns* (Winter, 1992), *shell nouns* (Hunston et Francis, 1999 ; Schmid, 2000, 2018), *noms sous-spécifiés* (Legallois, 2008) et *noms porteurs* (Huygue, 2018). Nous retenons que la plupart de ces travaux s'accordent pour définir les NSS comme un emploi particulier et non une classe lexicale : un nom peut ainsi être employé de façon sous-spécifié ou non, nous reprenons pour le 1^{er} cas un exemple de Huygue (2018) :

Emploi sous-spécifié du nom *fait* : le fait que Pierre soit arrivé en retard à la réunion

Emploi spécifié du nom *fait* : Il n'y a aucun fait qui étayent cette supposition.

Comme définition théorique, nous nous proposons de reprendre celle de Flowerdew (2006, p. 348) pour sa concision et sa clarté : « *potentially any abstract noun which is unspecific out of context, but specific in context* ». Un exemple d'emploi sous-spécifié pour le lemme *défi* est le suivant : *Pour les Américains, le **défi** est de marcher à nouveau sur la Lune*. Le sens complet de *défi* ne peut être appréhendé qu'en faisant référence au contexte, ici *marcher à nouveau sur la Lune*.

La définition de Flowerdew est néanmoins très générale. Pour compléter notre définition théorique, peut donner une définition fonctionnelle en rappelant les trois fonctions clés de l'emploi sous-spécifié selon Schmid (2000, p. 14 ; 2018, 112) :

- Fonction cognitive de **conceptualisation** ou d'**encapsulation** : un morceau d'information est encapsulé dans création un concept temporaire nominal. Dans notre exemple, *marcher à nouveau sur la Lune* est encapsulé dans un concept nominal, le **défi**.
- Fonction sémantique de **catégorisation** ou de **classification** : catégorisations de concepts, il s'agit d'une mise en perspective par le locuteur d'un morceau d'information qu'il souhaite transmettre à l'interlocuteur en lui imposant son point de vue (Legallois, 20108, p. 8). Le fait d'utiliser **défi** et non **problème** n'est pas neutre, comme nous le verrons plus bas, car si le NSS a un manque de contenu sémantique, il n'en est toutefois pas dénué complètement.
- Fonction textuelle ou discursive de **liaison** : capacité de référence quasi-pronominale au concept créé qui structure le texte, qui pourra être repris par exemple par l'énoncé *ce défi*. C'est cette fonction qui assure une cohérence et une continuité au texte et qui intéresse d'un point de vue discursif Flowerdew et Forest (2015, p. 2)

On peut noter, à la suite de Huyghe (2018, p. 36), que même si c'est une classe d'emplois et non une classe lexicale, la fonction d'encapsulation est néanmoins conditionnée par leurs propriétés sémantiques. Legallois (2008, p. 2) parle d'une « *interdéfinition entre lexique et grammaire* ». Schmid (2000, p. 63-73) reprend la distinction en trois de ordres de Lyons (1977) des entités dénotées par les noms. Nous traduisons ci-dessous la définition qu'en fait Benítez-Castro (2014, p. 96) :

« *Les entités de premiers ordres sont des éléments tangibles du monde réel, comme les personnes, les animaux et les objets, ayant une localisation spatiale et temporelle, les entités de second ordre, qui n'existe pas mais arrive ou prenne place, avec une localisation spatiotemporelle, comme un crime, un mouvement ou un combat, enfin les noms de troisièmes ordres convoient purement des significations abstraites, idées, propositions ou faits, comme théorie, affirmation, aspect). Les second et troisième ordres partagent une nominalisation comme origine mais les entités de troisièmes ne sont pas observables et en dehors de toute dimension spatiotemporelle.* »

Schmid (2000, 63-73) considère que les emplois de NSS ne concernent que les noms qui dénotent des entités de second ou de troisième ordres. Schmid (2000, p. 85 ; 2018 p. 118) distingue également trois grandes catégories de shell nouns selon leur contenu sémantique. La première est les *prime shell nouns*, des noms utilisés de façon privilégiée et fréquente dans des emplois de NSS comme *concept, fact, issue, idea, notion, principle, problem, reason, rumour, legend* et *thing*. La seconde est celle des *good shell nouns* (Schmid, 2000, p. 86) qui sont moins interchangeables entre eux comme *order*. La troisième catégorie se compose des *less good* ou *peripheral shell nouns* comme *move, measure, reaction, situation, way, procedure*.

Comme Flowerdew et Forest (2015, p. 12), nous considérerons les NSS comme une classe ouverte même s'ils empruntent à la classe fermée des pronoms la caractéristique d'avoir besoin d'un contenu spécifiant (Flowerdew et Forest , 2015, p. 11). Le fait qu'ils proviennent de la classe lexicale des

noms leur confèrent un statut intermédiaire entre la classe fermée pronominale et la classe ouverte nominale (Huyghe, 2018, p.44 ; Legallois, 2006, p. 11).

Huyghe (2018) distingue les noms généraux tels que définit par Halliday et Hasan (1976), « *a small set of nouns having generalized reference* », servant à construire la cohérence du texte, des NSS, appelés noms porteurs dans son article, tout en reconnaissant la possibilité d'appartenir aux deux classes. Cette distinction n'est pas aussi franche pour Flowerdew et Forest (2015, p. 9) et les deux se rejoignent sur la notion de non-spécification (Schmid, 2000, p. 10). Ce qui distingue les NSS des noms généraux, c'est le focus mis sur les structures grammaticales dans laquelle ils s'insèrent et qui en devient une définition opératoire.

II.2.2 Les constructions spécificationnelles classiques

A) Définitions des CS

Un NSS s'insère au sein d'une construction spécificationnelle (CS) qui va relier le NSS à un contenu qui va le spécifier ou le « remplir » (Legallois, 2008, p. 6). Cette opération est appelée spécification ou identification (Nakamura, 2017, p. 3).

Nous recensons ici les deux constructions spécificationnelles les plus fondamentales étudiées par Schmid (2000, p. 22) pour l'anglais. Legallois (2008, p. 2) a transposées ces constructions en français et elles ont été reprises par Huyghe (2018, p. 36), Roze et al. (2014, p. 4) et Nakamura (2017, p. 2) :

CS-I. **NSS** + être + proposition subordonnée conjonctive :

Le problème est que l'homme abandonne son habitat.

CS-II. **NSS** + être + de + proposition subordonnée infinitive :

Le plus grand **effort** est de vaincre les passions.

Kolhatkar et Hirst (2014, p. 4) montrent que les NSS ont une préférence pour certaines constructions spécificationnelles. En se fondant sur une étude du corpus du français frWac en son état du 25 avril 2017, Huyghe (2018, p. 37) indique qu'un NSS peut n'accepter qu'une des deux constructions : ainsi le NSS *capacité* s'utilise avec une infinitive, comme dans *la capacité de sélectionner les candidats*, et non avec une conjonctive, **la capacité que le jury sélectionne les candidats*. Cette « *compatibilité propositionnelle* » conditionne la syntaxe, le type de proposition subordonnée, mais il conditionne également la sémantique du contenu propositionnel (Huyghe, 2018, p. 38) : *action* implique la dynamité, *propriété*, la stativité. Ainsi chaque NSS a une « *capacité de portage propositionnel* » plus ou moins étendue (Huyghe, 2018, p. 37).

Ils existent pour (CS-I) et (CS-II) à chaque fois une variante qui peut être rapprocher des pseudo-clivées en insérant, entre le NSS et être, une virgule et le pronom de reprise *ce* (Legallois et Gréa, 2006, p. 161 ; Roze et al., 2014, p. 4), variantes qui se rencontrent notamment à l'oral :

CS-III. **NSS** + virgule + c'/ce + être + proposition subordonnée conjonctive :

Le problème, c'est que l'homme abandonne son habitat.

CS-IV. **NSS** + virgule + c'/ce + être + de + proposition subordonnée infinitive :

Le plus grand **effort**, c'est de vaincre les passions.

De plus, Schmid propose notamment trois autres constructions spécificationnelles (Schmid, 2000, p. 22, 26) que Legallois (2008, p. 2) n'a pas repris :

CS-V. **NSS** + proposition subordonnée conjonctive :

Le **problème** que l'homme abandonne son habitat

CS-VI. **NSS** + de + proposition subordonnée infinitive :

Le plus grand **effort** de vaincre ses passions

CS-VII. **NSS** + **of** + syntagme avec pour noyau un verbe au gérondif :

The **problem** of raising money

CS-V et CS-VI reprennent CS-I et CS-II mais sans le verbe être. Legallois (2008, p. 2) qualifie ces constructions « *d'apparentées* » et indique que les shell nouns de Schmid (2000) sont « *une catégorie plus large que les NSS* ».

La CS-VII réunit dans un syntagme nominal complexe le NSS et le contenu spécifiant, dont le noyau est un déverbal, un gérondif en anglais. Cette dernière contrainte se retrouve implicitement dans les exemples de son ouvrage (2000). Schmid lève la contrainte du gérondif de la CS-VII dans l'exemple qu'il donne dans son article de 2018 (p.115) : « *The **notion of love*** ». On remarque néanmoins que le déverbal *love*, de *to love*, est toujours un nom dénotant une entité d'ordre supérieur à un, l'action d'aimer. Le gérondif anglais n'ayant pas d'équivalent direct en français, une traduction possible vers le français est l'infinitif, rejoignant alors la construction CS-VI :

The problem of raising money → le problème de lever/réunir/recueillir de l'argent/des fonds

En français, dans le cas d'un déverbal dénotant une action ou une activité (DDAA), la difficulté se pose pour la CS-VII de distinguer les emplois proprement sous-spécifiés des emplois en nom plein suivi d'un complément de nom. Ainsi Roze et al. (2014, p. 8) indiquent que les énoncés « *marché de travail, contrat de travail* » ne sont pas des NSS alors que *travail* est le déverbal de travailler. Cela nous semble justifié par le degré de figement des ces énoncés qui fait de *contrat de travail* une locution nominale où contrat n'est pas substituable par un autre nom.

On peut se demander jusqu'à quel point cette contrainte d'avoir pour contenu spécifiant un DDAA est vérifiée. Prenons « *projet de loi* » qui est également refusé par Roze et al. (2014, p. 8) comme toutes les formes *projet de NC*. Il nous semble néanmoins possible de rapprocher les trois énoncés suivants qui reprennent les trois constructions spécificationnelles :

- CS-I Le projet que l'État légifère contre le vapotage dans les lieux publics.
- CS-II Le projet de légiférer contre le vapotage dans les lieux publics.
- CS-VII Le projet de loi contre le vapotage dans les lieux publics

L'équivalence des trois peut se comprendre en sous-tendant une action implicite dans la CS-VII, celle de rédiger/émettre une loi. L'interprétation sémantique dans ce dernier cas est ambiguë, à savoir si

le *projet* concerne l'acte de rédiger, on se rapproche d'un NSS, si le *projet* concerne la loi en elle-même, ou si l'on doit interpréter *projet de loi* comme une locution nominale dénotant une classe distincte, en ne dissociant pas *projet* et *loi*. Si nous rejetons le dernier emploi comme NSS, le second ouvre la possibilité d'avoir une action implicite sous-tendue par le nom, qu'un nom DDAA rend explicite.

Nakamura (2017, p. 2) reprend également la construction suivante comme CS, cette fois toujours avec le verbe être :

CS-VIII. **NSS** + être + syntagme nominal :

Notre **objectif** majeur est la rédaction d'une proposition de loi.

On remarque le noyau du syntagme nominal droit est *rédaction*, un DDAA qui dénote l'action de rédiger. L'équivalence avec *notre objectif majeur est de rédiger* est ainsi directe.

Nakamura (2017, p. 5) présente également une variante pseudo-clivée pour CS-VIII à la manière dont son dérivée CS-III et CS-IV de CS-I et CS-II respectivement. Nous la nommons CS-IX :

CS-IX. **NSS** + virgule + c'/ce être + syntagme nominal :

Notre **objectif** majeur, c'est la rédaction d'une proposition de loi.

Les NSS étant une classe fonctionnelle et non lexicale, les différentes constructions spécificationnelles traditionnelles sont autant de définitions opératoires des NSS (Schmid 2000). L'annotation manuelle d'un grand corpus pour détecter de tels emplois n'est pas envisageable. L'annotation purement automatique à partir d'un repérage structural semble moins difficile mais présente de sérieuse difficulté, notamment pour les CS les plus ouvertes comme la CS-V. Nous proposons comme solution une présélection automatique, la plus restreinte possible, suivie d'une évaluation manuelle des résultats, s'ils sont peu nombreux, pour déterminer s'il s'agit bien d'un NSS. Pour pouvoir utiliser le traitement automatique des langues en vue d'effectuer cette présélection automatique, il faut se pencher sur les conséquences des différentes et nombreuses définitions de constructions spécificationnelles proposées et particulièrement la nature et la fonction du contenu spécifiant des CS décrites, dites classiques désormais.

B) Nature et fonction du contenu spécifiant dans les CS classiques

CS-I, CS-II, CS-III, CS-IV, CS-V et CS-VI : NSS [(, ce être) | être] proposition en **que** ou **de**

Sur la nature du contenu spécifiant, pour CS-I et CS-II, nous suivons Legallois (2008) et Schmid (2000) en affirmant que le contenu spécifiant est avant tout une proposition subordonnée, pour CS-I une conjonctive commençant par *que*, et pour CS-II, une infinitive même si cela pose plus de questions. Roze et al. (2014) assimile la nature des CS-III et CS-IV, les pseudo-clivées, à CS-I et CS-II respectivement.

La première hypothèse est de considérer qu'il s'agit d'une proposition subordonnée infinitive que l'on peut voir comme incluse dans un syntagme prépositionnel commençant par *de* ou comme une seule proposition subordonnée infinitive où *de* est inclus dedans et joue le même rôle de complémenteur subordonnant que *que* (Huot, 1981). La définition de la proposition en grammaire traditionnelle, rappelée par Joseph Donato dans l'ouvrage collectif sous la direction de Mounin (1974), est qu'il s'agit d'« *un groupe de mots qui a son propre sujet et son propre prédicat* ». Cette obligation d'avoir un sujet propre, différent de la principale, potentiellement implicite et impersonnel comme dans

l'exemple de CS-II, n'est pas forcément toujours respectée. D'où la seconde hypothèse de considérer le contenu spécifiant comme un syntagme prépositionnel introduit par *de* incluant un syntagme verbal dont le verbe est à l'infinitif. Joseph Donato rappelle à ce propos que la « *distinction entre syntagme et proposition n'était pas toujours très claire ni très systématique* » mais cette problématique vaste s'éloigne trop de notre sujet. Par symétrie, nous parlerons de proposition subordonnée infinitive, considérant le *de* comme un subordonnant équivalent à *que*.

Nous évitons le terme de *complétive* car, s'il signifie que la proposition peut occuper les fonctions d'un nom, il se rapporte directement au nom d'une fonction, celle de complément, alors qu'un nom, et d'autant plus les constructions spécificationnelles avec le verbe *être*, rapproche le contenu spécifiant de la fonction d'attribut ou complément attribut selon la terminologie de Delhay (2014). Nous privilégions donc deux appellations se référant à la catégorie morphosyntaxique d'un terme distinctif de chaque construction : la conjonction de coordination que dans un cas, l'infinitif dans l'autre. Comme l'indique Kalmbach (2019), « *on peut facilement mettre en parallèle les deux types de construction* » par une transformation : « le fait que le jury sélectionne les candidats » ➔ « le fait de sélectionner les candidats ». Néanmoins, l'auteur constate également une différence majeure : « *le sujet n'est pas exprimé dans l'infinitive. Par rapport à la construction conjonctive, la construction infinitive prend donc une valeur impersonnelle ou générale* » car en effet le sujet de *sélectionne*, *le jury*, est perdu dans la transformation.

Les constructions CS-V et CS-VI, qui reprennent CS-I et CS-II mais sans le verbe *être*, sont rejetées par la majorité des travaux français comme constructions spécificationnelles. Schmid (2000, p. 20), adoptant le point de vue de la grammaire traditionnelle sur cet aspect, ne statue pas (p. 23) entre *noun complements* et *appositive modifiers*. Legallois (2008, p. 8) les rapproche des noms à compléments prépositionnels (NCP) de Riegel. Or Riegel (2006, p. 38) estime pour les CS-V qu'il s'agit de propositions attributives réduites, par rapport à la proposition attributive copulative avec le verbe *être* et qu'elles sont « *les deux réalisations syntaxiques d'un même schéma prédictif, la première sous la forme d'une construction copulative, la seconde sous celle d'une configuration propositionnelle averbale* ». On peut en effet transformer les CS-I en CS-V par l'ajout du verbe copulatif. La même chose est possible pour les CS-II en CS-VI, nous nous permettons de reprendre le terme de proposition subordonnée infinitive. Pour Riegel, la fonction est donc celle d'attribut.

CS-VIII et CS-IX : NN [, ce] être syntagme nominal

La nature du contenu spécifiant est syntagme nominal pour les CS CS-VIII et CS-IX et la fonction est celle de complément attribut.

CS-VII : NSS *de* syntagme nominal

La construction CS-VII n'a pas été reprise en français. Depuis l'anglais, si le noyau du syntagme est un verbe au gérondif, on peut la rapprocher de la construction CS-VI pour le français que nous verrons ci-dessous. Mais si son noyau est un nom de type DDAA, on considère que le contenu spécifiant est un syntagme prépositionnel avec *de* comprenant un syntagme nominal, que nous appelons syntagme prépositionnel-nominal. On peut alors la rapprocher des constructions CS-VIII et CS-IX du fait

que le contenu spécifiant soit aussi un syntagme nominal mais l'articulation avec le NSS se fait par le verbe être dans CS-VIII et CS-IX.

La fonction du syntagme prépositionnel-nominal dans CS-VII se rapproche formellement de celle de complément du nom. Néanmoins, le fait que le contenu spécifiant soit de la même nature que pour CS-VII et CS-VIII, l'équivalence entre le DDAA noyau de ce syntagme et le verbe dénotant la même action et activité dans les constructions avec une proposition, le fait qu'il puisse y avoir des constructions attributives non copulatives (Riegel, 2006), le fait enfin que le contenu spécifiant remplisse le NSS, tout cela rapproche le contenu spécifiant de la fonction attribut.

Un test possible est l'appel au contenu : un véritable complément de nom peut être supprimé alors qu'un attribut est essentiel à la phrase. On peut comparer les deux suppressions qui suivent :

- « le chat de Julie est blanc » vs « le chat est blanc »
- « l'**objectif de rédiger la loi** est important » vs « l'objectif est important »

L'« *attente de spécification* » est plus forte pour le NSS *objectif* qui « *appelle un complément d'information* » (Huyghe, 2018, p. 45). Sur la sémantique, *chat* dénote une entité de premier ordre, alors qu'*objectif* dénote une entité de troisième ordre. Néanmoins on pourrait toujours affirmer que la différence d'attente de spécification entre les deux est une affaire de degré, de quel chat parle-t-on, plutôt qu'une dichotomie franche entre attente et non-attente. Sur le plan syntaxique, *chat* est en revanche incapable d'accepter un contenu propositionnel ce qui le disqualifie comme NSS.

Cela amène à considérer le contenu spécifiant comme obligatoire. Si l'attribut est essentiel à une phrase, **Le problème est*, le complément du nom ne l'est pas : *Le problème de définir une nouvelle loi est complexe* vs *Le problème est complexe*. Mais ce deuxième cas n'est pas un NSS en lui-même. S'il est précédé d'un emploi de *problème* comme NSS, il peut s'agir d'une reprise anaphorique du concept déjà formé, l'utilisation de l'adjectif démonstratif *ce* renforcerait cette reprise mais n'est pas obligatoire. Or, nous nous intéressons au moment précis où le contenu spécifiant est associé au NSS, non aux reprises qui, dans l'étroitesse d'un titre, nous semblent peu pertinentes. Nous pouvons donc, pour identifier les NSS, parler d'une obligation de complémentation du nom si l'on adopte ce point de vue.

Pour notre part, nous privilégions la relation de complément attribut car il s'agit bien de conférer une propriété à un nom, ici donc de le remplir sémantiquement, et elle doit être au moins une fois obligatoire : la fonction de cohérence devient caduque si un NSS est seulement repris en anaphore sans jamais avoir été utilisé dans une construction spécificationnelle. Le cas d'une définition extralinguistique par le contexte de communication n'est pas recevable dans le contexte des titres qui introduisent un sujet.

La question se pose de la possibilité de transformer la CS-VIII en CS-VII. Si l'on reprend l'exemple de Nakamura (2017, p. 2), *Notre objectif majeur est la rédaction d'une proposition de loi* on a :

- *Notre objectif majeur la rédaction d'une proposition de loi
- Notre objectif majeur, la rédaction d'une proposition de loi,
- ?Notre objectif majeur de la rédaction d'une proposition de loi

La première phrase est agrammaticale par la suppression du verbe copule entre sujet et attribut. La seconde transforme l'attribut en apposition. La troisième regroupe le NSS et le contenu spécifiant en un seul syntagme nominal complexe, en utilisant la préposition *de*. On retombe alors sur le type de construction CS-VII de Schmid (2000, p. 26 ; 2018, p. 155) : *The notion of love*. Néanmoins on peut se demander si l'énoncé formé est grammatical et acceptable. Les exemples (19, 20) tirés de notre corpus montre que le NSS objectif peut s'insérer dans une CS-VII.

(19) L'objectif de **satisfaction de victimes** en droit pénal international

(20) Comment l'**objectif de maîtrise des flux de polluants** est-il traduit dans les critères de gestion à l'amont des eaux pluviales ? - Analyse des pratiques en France et à l'international

On remarque pour les deux exemples (19, 20), le noyau nominal du contenu spécifiant est également un DDAA. Nous pensons qu'il s'agit d'une bonne contrainte pour les constructions spécificationnelles CS-VIII et CS-IX, comme pour la CS CS-VII, même si des cas épineux subsistent comme dans l'exemple (30) discuté plus bas.

Pour finir, on peut donc construire le tableau d'équivalence (10) entre les différentes CS, même si nous ne plaçons pas les transformations entre CS-I, CS-III et CS-V et CS-II, CS-IV et CS-VI sur le même niveau que la paraphrase possible entre CS-VII et CS-VIII.

CS-I, III NSS + [ce] + être + proposition subordonnée conjonctive	CS-V NSS + proposition subordonnée conjonctive
CS-II, IV NSS + [ce] + être + de + proposition subordonnée infinitive	CS-VI NSS + de + proposition subordonnée infinitive
CS-VII NSS + syntagme prépositionnel-nominal	CS-VIII NSS + être + syntagme nominal

Tableau 10: Tableau d'équivalence entre construction copulative et réduire

Nous rassemblons donc tous les contenus spécifiants sous la bannière de la fonction complément attribut. Les quatre natures possibles pour les contenus spécifiants sont donc une proposition subordonnée conjonctive introduite par *que* (CS-I, CS-III et CS-V), une proposition subordonnée infinitive (CS-II, CS-IV et CS-VI) introduite par *de*, un syntagme prépositionnel-nominal (CS-VII) ou un syntagme nominal (CS-VIII et CS-IX). Pour ces deux derniers, le noyau nominal doit être un DDAA, ce qui revient à demander que le noyau du contenu spécifiant dénote toujours une action, soit par l'entremise du verbe conjugué de la proposition subordonnée conjonctive (CS-I, CS-III et CS-V), soit par l'entremise du verbe à l'infinitif de la proposition subordonnée infinitive (CS-II, CS-IV et CS-VI), soit par le DDAA des trois dernières constructions (CS-VII, CS-VIII et CS-IX). À présent que nous avons rappelé la définition des NSS et des CS qui les incluent et observer la nature et la fonction du contenu spécifiant, nous allons essayer de chercher les CS classiques dans notre corpus.

II.2.3 Recherche des CS classiques dans notre corpus

L'annotation manuelle des NSS sur un grand corpus comme le nôtre n'est pas envisageable. Le seul moyen de trouver des NSS est de rechercher, à la manière de Legallois (2008) pour CS-I et CS-II et de Roze et al. (2014) pour CS-I, CS-II, CS-III et CS-IV, les occurrences de constructions spécificationnelles dans notre corpus, ce qui nous a fait adopter le terme de définition opératoire malgré la mise en garde

de Schmid (2018, p. 5) de ne pas confondre définition et opérationnalisation, ce qui se traduit chez nous par la distinction faite entre définition théorique et définition opératoire.

A) Constructions avec une proposition subordonnée conjonctive CS-I, CS-III et CS-V

Contrairement à ces travaux, dans un contexte averbal comme les titres, nous ne pouvons faire l'économie de pas considérer les CS sans verbe être conjuguée comme CS-VI et CS-VI. Nous cherchons donc les schémas suivant dans notre corpus :

NSS³ nom commun [(, **ce** clitique sujet⁴ être) | être conjugué] **que** conjonction de subordination

Nous prenons l'exemple (e1) pour illustrer qu'un syntagme prépositionnel peut s'insérer entre le NSS et le contenu spécificationnel. Pour prendre en compte cette flexibilité, plutôt que des schémas linéaires, nous faisons correspondre nos schémas à des relations de dépendance.

(e1) Le **problème** de cette nouvelle présentation est qu'elle n'est pas satisfaisante.

La difficulté est ici d'écarter toutes les propositions relatives. Schmid (2000, p. 3) indique clairement qu'une proposition relative ne peut être employée dans une construction spécificationnelle et qu'il ne faut pas confondre le *que* pronom relatif du *que* conjonction de subordination. Les deux ayant des étiquettes différentes dans Talismane, cela ne posera pas de problème.

En recherchant ce schéma, nous trouvons 26 titres qui correspondent. Néanmoins, Talismane étiquette erronément des lemmes *que* comme conjonctions de subordination alors qu'il s'agit de pronoms relatifs. Sur un si faible nombre de résultats, nous pouvons manuellement les filtrer et ne gardons que trois titres, (21), (22) et (23) qui possèdent un nom en emploi sous-spécifié :

(21) Condamnation d'une société au paiement de ses cotisations volontaires obligatoires en l'absence de **preuve** que ces cotisations faisaient l'objet d'un emploi contraire au droit européen des aides d'État

(22) Bibliothèque implicite ou les **représentations** que les enseignants se font d'une culture humaniste

(23) Démystification de l'**idée** que le réseau d'aide informelle se délite

On remarque qu'il n'y a jamais de verbe *être* conjugué pour relier le NSS à la proposition subordonnée conjonctive. Néanmoins on peut facilement construire une telle phrase à partir du couple NSS / proposition comme par exemple *L'idée est que le réseau d'aide informelle se délite* pour valider qu'il s'agit bien d'un emploi sous-spécifié. On peut donc constater que ce schéma est très peu présent dans nos titres, même sans verbe être conjugué.

B) Constructions avec une proposition subordonnée infinitive CS-II, CS-IV et CS-VI

Pour ces CS, nous cherchons le schéma suivant :

NSS nom commun [(, **ce** clitique sujet être) | être conjugué] **de** préposition **VINF**

³ Dans les faits nous cherchons un nom commun mais nous utilisons cette mise en forme pour mettre le signaler l'emplacement du nom sous-spécifié dans notre schéma.

⁴ Nous ajoutons une capacité à nos schémas : celle de définir conjointement un lemme et une catégorie morphosyntaxique pour un token, toujours en indice dans ce cas, lorsqu'il y a une ambiguïté possible.

L'exemple (e2) montre que la négation *ne pas* peut s'insérer entre le *de* et verbe à l'infinitif en plus d'avoir un syntagme prépositionnel entre le NSS et le contenu. Nous continuons pour cette raison à faire correspondre nos schémas à des relations de dépendance.

(e2) Le **problème** de cette nouvelle présentation est de ne pas satisfaire le client.

En cherchant ce schéma, nous trouvons 1 161 titres qui correspondent. Néanmoins, Talismane n'arrive souvent pas à correctement choisir le recteur de la préposition *de* entraînant des faux positifs comme dans l'exemple (24) où le dernier *de* devant « faire le genre » a pour recteur le premier nom *corps*.

(24) Le corps recteur des filles à l'épreuve des filières scolaires masculines. Le rôle des socialisations primaires et des contextes scolaires dans la manière de dépendant « faire le genre »

Nous ajoutons des filtres pour trouver des occurrences de véritables constructions spécificationnelles : suppression des 27 titres avec « en vue de + infinitif », correction de la mauvaise dépendance si on trouve un nom commun immédiatement avant le *de* qui précède l'infinitif, non inclusion des sept titres avec la forme *Grégoire* étiquetée comme un verbe à l'infinitif, des six titres faisant de même pour *Alexandre*, des 12 titres avec *bien-être* dont Talismane considère l'*être* comme un infinitif et des 34 titres où un nombre était considéré comme infinitif, on tombe à 1 075 résultats.

Il n'y a que neuf résultats avec le verbe être conjugué. Nous pouvons rapidement les parcourir manuellement. Parmi ces résultats, Il n'y a qu'une seule construction spécificationnelle avec une proposition subordonnée infinitive et le verbe être, l'exemple (25).

(25) Situation palestinienne : le plus grand **effort** de la CPI est de vaincre les passions

Pour les 1066 résultats sans le verbe être conjugué, nous décidons d'en tester manuellement 10 %, soit 107, pour avoir une estimation du nombre véritable de constructions spécificationnelles dans ces résultats. Sur les 107, 59 % ne sont pas des CS. Si on applique ce taux à nos 1 066 résultats, on tombe à 629 faux positifs et 437 utilisations estimées comme véritables de NSS. Parmi les CS trouvées, on peut citer les exemples (26), (27), (28) et (29).

(26) La **tentation** d'instituer des « Cours constitutionnelles régionales »

(27) **Possibilités** de réduire les émissions de gaz à effet de serre et d'autres impacts environnementaux dans les systèmes de production de viande bovine

(28) L'**obligation** de renégocier le contrat au nom de la lutte contre les gaz à effet de serre

(29) Réversibilités post-coloniales : les mobilités d'**art** de vivre à Marrakech

On peut également construire une phrase à partir du couple NSS / proposition avec le verbe être comme par exemple *La tentation est d'instituer des « Cours constitutionnelles régionales »* pour valider qu'il s'agit bien d'une construction spécificationnelle. On remarque que pour les exemples (26), (27) et (28), le NSS est également une tête de segment ce va dans le sens d'un rapprochement.

C) CS avec verbe copule et syntagme nominal, CS-VIII et CS-IX

Le schéma pour les deux constructions spécificationnelles CS-VIII et CS-IX est le suivant :

NSS nom commun [, **ce** clitique sujet] **être** verbe conjugué **DDAA** nom commun

DDAA signifie un nom déverbal dénotant une action ou une activité, néanmoins, nous laissons ouverte la possibilité d'avoir des noms n'étant pas des DDAA mais avec une action ou une activité implicite.

En cherchant le schéma correspondant à CS-VIII et CS-IX, toujours sur les relations de dépendances pour permettre une certaine flexibilité comme la présence de déterminants ou d'adjectifs, nous trouvons 226 résultats. Manuellement, nous éliminons des résultats qui nous semblent incorrects. Si erreurs de Talismane comme confondre le verbe être avec le point cardinal *est* sont triviales, distinguer un emploi sous-spécifié ne l'est pas toujours. Si écarter les *full content nouns* comme *remariage*, *miroir* ou *misère* ne pose pas de problème, d'autres exemples se révèlent plus ardues à l'inspection du jugement de l'autre, à défaut d'heuristique plus déterminante. Une technique est d'essayer de transformer l'énoncé en une CS-I ou CS-II qui sont plus restrictives, ou CS-III et CS-IV, mais cela n'est pas toujours évident.

Nous retenons, sur les 226 résultats, 1 seul titre utilisant le pronom de reprise :

(30) Le plus grand **danger** social, c'est le bandit imberbe. La justice des mineurs à la Belle Époque

On voit bien ici que danger va créer un concept temporaire, que le locuteur caractérise sous un jour négatif, qui encapsule *le bandit imberbe*. Une phrase équivalente en CS-III serait *Le plus grand danger social, c'est que le bandit imberbe existe/menace/rôle*. On voit bien avec la phrase équivalente que nous retombons dans le cas où le nom noyau n'est pas un DDAA mais sous-tend de manière implicite une activité, le fait que le bandit existe.

Sur nos 226 résultats, 1 seul titre correspond à un emploi sous-spécifié :

(31) L'activité d'évaluation et les systèmes d'information. L'**évaluation** est aussi un travail langagier, assisté, organisé

La tête *évaluation* figure parmi nos têtes transdisciplinaires.

Les exemples (32) et (33) ont été rejetés car

(32) La **connaissance** est un réseau : perspective sur l'organisation archivistique et encyclopédique

(33) La **théorie** des chances n'est pas un jeu d'esprit : le statut de la probabilité mathématique selon Cournot

On touche ici aux limites de la capacité de jugement intuitive pour cette tâche : on ne peut pas dire que *travail*, *réseau* et *un jeu d'esprit* remplisse complètement le NSS sur le plan sémantique. On effectue les tests suivants :


- Est-il possible d'utiliser le nom dans une CS-I ou une CS-II : si oui, il y a un potentiel de portage d'une proposition, mais cela ne prouve que l'emploi étudié en est un.

- Est-ce que le nom du syntagme nominal est un DDAA ?

Si l'on répond par l'affirmative à ces deux réponses, nous sommes bien présence d'un NSS. Ce qui est certain, c'est le faible nombre de résultats qui ont le potentiel de correspondre à un emploi en NSS. Sur les dix exemples de NSS que nous avons extraits, *preuve*, **représentation**, *idée*, *effort*, *tentation*, *possibilité*, *obligation*, *art*, *danger*, **évaluation** deux sont des têtes transdisciplinaires. Nous savons donc que 2 % de nos 94 têtes transdisciplinaires admettent un emploi sous-spécifié néanmoins cet emploi semble rare : 2 occurrences sur les 94 738 que comptent les têtes transdisciplinaires. Il reste enfin la dernière CS classique.

D) CS avec un syntagme prépositionnel-nominal, CS-VII

Cette dernière construction utilise le schéma suivant, très généraliste, où le premier NC est employé en NSS, que nous recherchons sur les liens de dépendance pour permettre une plus grande flexibilité :



Schmid (2018, p. 115) indique que son étude de 2000 n'a pas pris la définition CS-V-N pour des raisons techniques, car elle rapporte trop de résultats et avec beaucoup de bruits, comme les relations partie-totalité comme dans *le cœur du problème*. Or nos titres étant majoritairement averbaux, nous avons bien plus de chance d'y trouver des contenus spécifiants nominaux. Ne pas retenir cette construction nous ferait perdre de nombreux exemples. De plus, nous n'avons, pour une recherche automatique, pas d'autres alternatives qu'une définition structurelle. Nous n'avons néanmoins pas de moyen d'identifier les noms de type DDAA à notre disposition. Dans notre corpus, cette requête rapporte 179 931 résultats ce qui est beaucoup trop large pour permettre ensuite une sélection manuelle.

Une possibilité, reprise de Roze et al. (2014, p. 8) est de contraindre la requête en prenant le résultat uniquement si le premier nom appartient à un lexique. Roze et al. utilise ce procédé pour découvrir de nouvelles CS en fournissant un lexique de noms déjà identifiés dans un ensemble de CS de type CS-I, CS-II, CS-III et CS-IV. Nous voulons faire de même avec nos têtes transdisciplinaires.

II.3 Schémas récurrents d'emploi des têtes transdisciplinaires

II.3.1 Recherche de schémas d'emplois des têtes transdisciplinarité

Du fait que les NSS sont une classe ouverte, et que les définitions varient d'un auteur à l'autre, aucune liste définitive n'est possible. Schmid liste 670 *shell nouns* (2000, p. 381), Flowerdew et Forest (2015), 845 *signalling nouns*, et Tutin (2008, p. 3), 356 *noms sous-spécifiés*. Néanmoins, Schmid (2018, p. 118) souligne la convergence de sa liste avec celle de Flowerdew et Forest (2015) sur les NSS les plus fréquents malgré leurs différentes méthodes. Ces listes peuvent donc servir d'indices, mais en aucun cas de preuves, pour prendre en compte le potentiel d'emploi sous-spécifié de nos têtes transdisciplinaires.

Sur les 94 têtes transdisciplinaires, 23 sont reconnues comme pouvant être un NSS par Legallois (2008, p. 3), soit seulement 24 %. Cependant, la définition opératoire de Legallois repose uniquement sur les CS CS-I et CS-II, et son corpus, les articles de l'année 1995 du quotidien *Libération*, est très

éloigné du nôtre. Or, une définition opératoire est toujours dépendante du corpus sur lequel elle est appliquée.

Sur les 94 têtes transdisciplinaires, 83 ont un lemme dont la traduction en anglais apparaît dans la liste de Flowerdew et Forest (2015), soit 88 %. Son corpus est beaucoup plus proche de notre matériau, puisqu'il s'agit du Flowerdew Corpus of Academic English (Flowerdew et Forest, 2015, p. 68) composé de journaux académiques, de discours et de leçons. Cela nous amène à vouloir chercher les schémas récurrents des têtes transdisciplinaires dans nos titres.

A) Impossibilité de trouver des schémas émergents

L'existence de nos têtes transdisciplinaires, fréquentes, abstraites, dotées d'un faible contenu sémantique, le fait que 83 % d'entre elles apparaissent dans la liste des signalling nouns, nous pousse à nous demander s'il n'existerait pas d'autres constructions spécificationnelles, propres aux titres. Nous allons à présent essayer de rechercher des schémas récurrents dans lesquels s'inséreraient nos têtes transdisciplinaires et d'évaluer si ceux-ci pourraient jouer le rôle de construction spécificationnelle.

La question se pose de distinguer les schémas récurrents des têtes transdisciplinaires des autres. Pour cela, nous reprenons directement une méthode formulée par Roze et al. (2014, p. 8), qui s'inspiraient de Quiniou et al. (2012) : la fouille de données séquentielles. Tout d'abord, nous construisons des séquences de mots autour des noms. Chaque séquence est composée d'items qui sont, pour les classes fermées, le lemme du mot, et, pour les classes ouvertes, son étiquette morphosyntaxique, sauf pour les verbes *être* et *avoir* où nous gardons également le lemme. Nous ajoutons les items INIT pour le début du titre et END pour sa fin.

Nous calculons toutes les séquences existantes en utilisant une taille minimale de deux éléments et une taille maximale de cinq éléments. Nous les répartissons en deux bases : d'un côté, les motifs dont le pivot est une tête transdisciplinaire et de l'autre ceux dont ce n'est pas le cas.

Nous calculerons ensuite le taux de croissance de chaque motif spécifique aux têtes transdisciplinaires par rapport au motif correspondant dans l'autre base. S'il n'y a pas de motif correspondant, le taux de croissance est infini. Sinon il est égal au support de la séquence transdisciplinaire divisé par le support de la séquence non transdisciplinaire. Le support d'une séquence S dans une base donnée est le nombre de séquences contenant S, c'est-à-dire qu'elles contiennent tous les items de S dans le même ordre, y compris de façon disjointe.

Les motifs émergents sont « *les motifs dont le support augmente de manière significative d'un ensemble de données à un autre* » (Roze et al., 2014, p. 8), ce qui se traduit par un taux de croissance supérieur à une valeur p que nous fixons à un. Nos résultats ne permettent pas de distinguer des motifs émergents propres aux têtes transdisciplinaires par rapport aux autres têtes.

B) Deux schémas fréquents proches de la CS-VII

Si le taux de croissance ne donne rien de probant, cela signifie que les têtes transdisciplinaires ne se distinguent pas syntaxiquement des têtes non transdisciplinaires. Néanmoins, nous pouvons utiliser le comptage des séquences pour faire émerger les motifs les plus fréquents des têtes transdisciplinaires sur les 1 604 847 séquences recensées.

La figure (1) permet d'avoir un aperçu de ces séquences, une flèche indiquant la relation "est contenu dans" qui est transitive (pour trois séquences A, B et C, si A → B → C alors A → C). Par souci de lisibilité, nous n'avons pas fait figurer les relations déductibles par transitivité. Nous avons étagé le diagramme selon le nombre d'éléments par séquence et nous avons filtré pour ne garder que les séquences les plus fréquentes à chaque niveau.

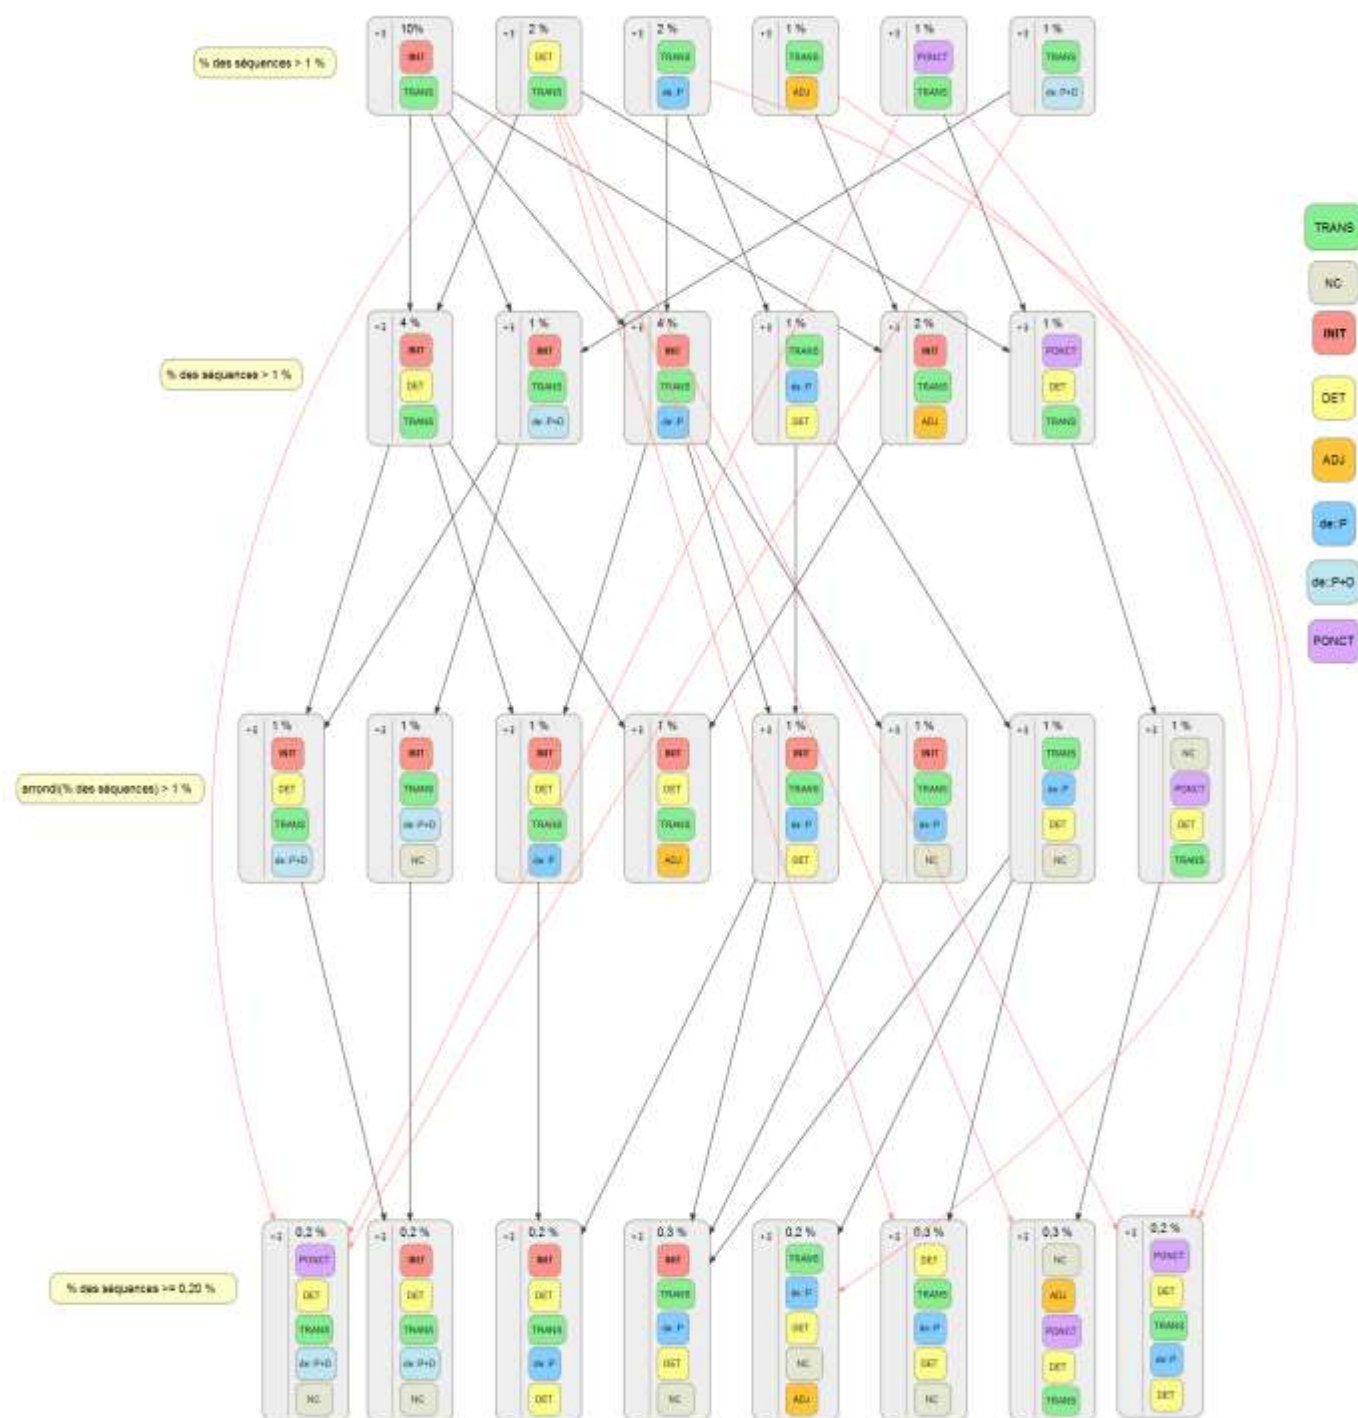


Figure 1 : Arbre des séquences les plus fréquentes des têtes transdisciplinaires

Normalement, il n'y aucune relation sautant un niveau, néanmoins avec les filtres appliqués sur les fréquences, certaines séquences existantes mais pas assez fréquentes ne sont pas affichées. Nous avons donc fait figurer en rouge les relations qui sautent des niveaux de l'arbre.

La fouille de données séquentielles est une méthode qui peut être appliquée de façon neutre à n'importe quel type de données. Nos connaissances linguistiques nous permettent d'interpréter ce diagramme, notamment l'optionnalité de certains items, pour en tirer les deux schémas suivants qui sont les plus grands conteneurs de séquences :

Schéma 1 :	INIT ⁵	[DET]	TRANS	((P [DET]) P+D)	NC	[ADJ]
Schéma 2 :	PONCT	DET	TRANS	((P [DET]) P+D)	NC	[ADJ]

Le fait le plus remarquable est que les deux schémas correspondent à la CS-VII, NSS de NC, en élargissant à toutes les prépositions d'un côté mais en contraignant sur l'emplacement dans le titre. Dans le premier la tête transdisciplinaire est le premier nom du titre, dans le second elle est le premier nom après une marque de ponctuation, potentiellement une marque de segmentation, ce qui ferait de la tête transdisciplinaire le premier nom d'un second segment. Remarquons que ce dernier cas se rapproche de notre travail de première année, mais par un autre cheminement.

Les motifs fréquents dont sont issus ces schémas ont un faible le taux de croissance par rapport aux motifs des têtes non transdisciplinaires : ils ne sont pas spécifiques aux têtes transdisciplinaires. Ce fait s'explique car ce qui apparaît formellement comme une complémentation de nom est accessible à une grande quantité de noms, sinon tous, alors que la capacité de portage propositionnel (Huyghe, 2018) n'est propre qu'aux NSS.

Pour déterminer s'il s'agit d'emplois sous-spécifiés, il faut à présent s'interroger sur la sémantique du nom commun présent dans ces deux schémas.

II.3.2 Lexique des noms et détermination de l'emploi

Nous construisons un lexique de ces noms, en indiquant à chaque fois le nombre de fois où on le trouve après une tête transdisciplinaire étant directement après INIT (schéma 1), ou si on le trouve après une tête transdisciplinaire directement après une ponctuation (schéma 2). La détermination de l'emploi repose donc sur l'analyse du nom commun qui suit la tête transdisciplinaire. Nous avons vu que ce nom doit directement dénoter une action ou une activité ou amener une action ou une activité de façon implicite.

A) L'étude de problème

La recherche du schéma 1 sur notre corpus donne 33 849 couples (TRANS, NC) différents. On remarque que toutes les têtes transdisciplinaires apparaissent dans nos résultats. Pour analyser s'il pourrait s'agir d'un emploi NSS nous décidons de nous concentrer sur une tête transdisciplinaire *problème*. Dans nos résultats, il est la 55^e dans l'ordre de fréquence des têtes transdisciplinaires. Selon notre méthode de sélection, il est la 58^e tête transdisciplinaire, sur 94, en les classant par valeur de

⁵ Le schéma de couleur reprend celui de la figure (1).

médiane. Il est également un *prime shell noun* de Schmid (2000, p. 85 ; 2018 ; p. 118). Dans la liste de Flowerdew et Forest (2015, p. 203), il est le 3^e par ordre de fréquence normalisée. Il y a donc une forte probabilité que *problème* puisse avoir des emplois en NSS dans notre corpus et plus particulièrement dans le schéma 1.

On coerce donc notre schéma 1 en prenant pour TRANS que les occurrences de *problème*. Mais, en prévision d'un faible nombre de résultats, nous décidons de rechercher notre schéma comme une séquence : on autorise une correspondance disjointe des énoncés avec le schéma, cela permet de maximiser la correspondance avec des variantes que l'on n'aurait pas prévues dans la définition initiale : par exemple, avoir un adjectif pour la tête transdisciplinaire, ce qui est une des séquences qui avait été trouvées lors de notre fouille de données séquentielles. De plus, on lève dans ce cas la contrainte que TRANS soit une tête pour estimer s'il existe des énoncés qui correspondent à cette séquence où le lemme *problème* ne serait pas une tête de segment. TRANS peut donc correspondre à deux cas :

- Lemme de *problème non-tête de segment*
- Lemme de *problème tête transdisciplinaire*

On obtient 282 couples différents (TRANS, NC) dans 370 occurrences à analyser manuellement. Pour chacun, nous nous aidons du contexte en suivant les indices déjà évoqués pour la CS-VII : capacité de paraphrase en CS-I ou CS-II, nom étant un DDAA, nom rendant implicite l'action ou l'activité.

Nous obtenons 135 occurrences pouvant être reçues comme un emploi de *problème* en NSS directement selon la construction CS-VII, soit 36 % du total des occurrences de *problème* dans les résultats du schéma 1, comme les exemples (34) et (35).

(34) Quelques **problèmes** d'analyse de la délinquance juvénile à la fin du XIXe siècle. L'exemple parisien
(35) Le **problème** du regroupement des activités dans la modélisation ABC. Une approche possible
(36) **Problèmes** de création en multimédia : marier l'expérience de l'audiovisuel et la rigueur de la qualité

La paraphrase de ces exemples en CS-II, avec un infinitif, est immédiate : *Quelques problèmes d'analyser, le problème de regrouper, Problèmes de créer en multimédia. Analyse, regroupement, création* sont des déverbaux dénotant une action ou une activité.

Sur les 370 résultats, deux occurrences correspondent au schéma sans que *problème* ne soit une tête de segment : les exemples (37) et (38). Une seule de ces deux occurrences peut être reçue comme un emploi de *problème* en NSS, l'exemple (37).

(37) Problème d'interprétation des enclos quadrangulaires de La Tène moyenne **découverts** en Flandre française : l'exemple de Borre (Nord)
(38) Les problèmes **viennent** du fonctionnement du système, pas des individus. Entretien avec Maurice Godelier

Cela signifie que, sur les 1 660 occurrences de *problème* dans le corpus, nous avons 613 occurrences où il s'agit d'une tête de segment et 1 047 occurrences en tant que non-tête. Cela fait, en

ne considérant que le schéma 1, un taux d'utilisation en tant que NSS de 0,1 % si le lemme n'est pas une tête, et de 22 % si le lemme est une tête.

Cette utilisation en tant que NSS est liée à la position en tant que tête, ce qui était prévisible car, dans le schéma 1, le TRANS est le premier nom rencontré dans le titre, or les têtes de titres monosegmentaux ou de premier segment de titres monosegmentaux, sont à 86 % le premier nom commun du titre.

Les 135 occurrences retenues utilisent toutes la préposition *de* même s'il existe également des occurrences non gardées qui utilisent une construction de la forme *le problème posé par X* comme dans l'exemple (39) et qui semblent correspondre à un emploi NSS dans 17 cas. L'exemple (39) peut en effet être paraphrasé en *Problèmes de prédire en persan*. Néanmoins, cet emploi est propre à *problème*, on ne peut pas mettre un autre lemme à la place, nous ne le retenons dans notre tentative de trouver une détermination générale de l'emploi NSS.

(39) Problèmes posés par la prédication en persan. Approche contrastive persan

Le résultat le plus marquant est la très forte présence de DDAA dans résultats dont le trait saillant est l'utilisation d'un suffixe. On catégorise leurs formations morphologiques dans le tableau (1).

Suffixe	Compte	%	Exemples
-tion	83	62 %	<i>évaluation, communication, compréhension</i>
-ment	14	11 %	<i>financement, réordonnancement, désencastrement</i>
-age	6	5 %	<i>réglage, échantillonnage, démarrage, remplissage</i>
-sion	6	5 %	<i>expansion, inversion, compréhension, prévision, conversion</i>
Suffixe zéro	15	11 %	<i>abandon, commande, enquête, transport, groupe, nuance, contrôle, calcul, rejet, analyse</i>

Tableau 11: Suffixes associés au nom noyau du contenu spécifiant

Les 10 restants, soit 8 %, sont des déverbaux avec modification du radical, comme *compromis* → *compromettre*, *livraison* (x3) → *livrer*, *émergence* → *émerger* (x2), *résistance* → *résister*, *gouvernance* → *gouverner*, *ordre* → *ordonner* ou un gérondif anglais importé directement en français, *routing*, retrouvant ainsi les exemples initiaux de la CS-VII.

Sauf pour les 10 derniers et les 15 déverbaux avec zéro suffixe, on peut donc construire un filtre sur les terminaisons les plus fréquentes qui indiquent un DDAA : « -tion » et sa variante « -sion », « -age », « -ment » pour mieux sélectionner les titres avec un usage potentiel de NSS. De plus, on peut rétrécir le schéma à la préposition *de*, pour rapprocher notre schéma 1 le plus possible de la CS-VII, laissant de côté les variantes possibles.

Nous exécutons notre requête de façon disjointe encore une fois, mais en n'autorisant aucune autre proposition que *de* entre le TRANS et le NC. Nous obtenons 117 résultats. Ce filtre étant construit par l'ajout de contraintes sur le précédent, il ne peut pas y avoir de résultats qui n'auraient pas été couverts par le précédent. Nous pouvons donc calculer une précision, nous avons 7 faux positifs donc une précision de 94 %, et un rappel, de 81 %, de notre nouvelle définition du schéma par rapport à

l'ancienne. Les 7 faux positifs bruitant nos résultats sont dus à la manière disjointe de faire correspondre l'énoncé à notre schéma pour 6 d'entre eux, comme pour l'exemple (37) et par l'utilisation d'un mot ayant une des terminaisons ciblées pour 1 d'entre eux, l'exemple (38) avec *environnement*.

(37) Quelques problèmes éditoriaux autour de L'Éducation sentimentale

(38) Les problèmes d'environnement dans une région d'extraction pétrolière : la région de Nijnevartovsk situé sur le territoire Khanti-Mansi (Russie)

Étudier *problème* nous amené à constater que :

- L'utilisation en tant que NSS semble liée au fait que le mot soit tête de segment, reste à déterminer l'éventuelle corrélation entre les deux faits.
- L'utilisation en tant que NSS peut être estimée en analysant la morphologie du nom après la préposition *de*.
- Il pourrait exister des constructions spécificationnelles propre à chaque nom, comme *le problème posé par*, comme Nakamura (2017, p. 7) signale *avoir pour/comme objectif de*.

B) Estimation globale à l'aide du schéma 1

À partir du schéma 1 modifié, nous pouvons estimer l'usage en tant que NSS des têtes transdisciplinaires. La détermination d'un emploi sous-spécifié dans une construction aussi large que la CS-VII étant une affaire d'interprétation sémantique, nous ne pouvons qu'admettre que notre schéma ne sera au mieux qu'une estimation large. Néanmoins, nous pouvons comparer pour chaque lemme des têtes transdisciplinaires le nombre d'emplois correspondant à notre schéma 1, c'est-à-dire où le nom suivant se termine en -tion, -sion, -age, -ment, et si cet emploi intervient si le lemme est bien une tête. Nous différencions donc à chaque fois :

- *Lemme de tête transdisciplinaire qui n'est pas tête de segment (exemple 37 et 38)*
- *Lemme de tête transdisciplinaire effectivement tête transdisciplinaire*

Nous obtenons, sur l'ensemble de notre corpus, 12 124 correspondances avec notre schéma 1. Seulement 52 sont une correspondance alors que le lemme n'est pas une tête, soit 12 072 où nous avons une tête transdisciplinaire estimée employée comme NSS. Nous comptons en tout 94 738 occurrences de têtes transdisciplinaires dont 58 003 dans le premier segment, les seules pouvant correspondre au schéma 1. Sur ces têtes transdisciplinaires de premier segment, nous en avons donc 21 % estimées employées comme NSS, soit dans 23 % des titres. Ce même emploi ne se retrouve qu'à 0,09 % lorsque le lemme n'est pas une tête. On peut également se poser la question si cette caractéristique est propre aux têtes transdisciplinaires. Nous recherchons les correspondances du schéma 1 avec cette fois-ci les têtes qui ne sont pas transdisciplinaires. On obtient 17 051 résultats, soit 11 % des têtes non transdisciplinaires. Les têtes que nous n'avons pas sélectionnées comme transdisciplinaires ont également la capacité être employée comme NSS, bien que moins fréquemment.

B) Estimation globale à l'aide du schéma 2

Nous refaisons le même cheminement pour le second schéma en restreignant directement la préposition à *de*. Nous obtenons les résultats suivants :

- Têtes transdisciplinaires : 2 928 emplois de NSS
- Lemmes de têtes transdisciplinaires non-têtes : 1 773 emplois de NSS

Ce résultat peut sembler paradoxal : le fait d'être employé en tant que NSS semble beaucoup moins corrélé au fait d'être une tête. Cela s'explique en analysant ces résultats, comme les exemples (39) et (40).

(39) La connaissance, un **outil** de la prévention de la délinquance

(40) Caractérisation et génération de surfaces agricoles – **Etude** de la diffraction en coordonnées non orthogonales

Les deux utilisent des marques de ponctuation non reconnues comme segmentatrices par notre définition, la virgule pour (39) et le tiret pour (40). Nous pensons qu'il s'agit pourtant bien ici de titres bisegmentaux ayant pour tête de second segment *outil* et *étude*, qui sont tous les deux des lemmes de têtes transdisciplinaires. La forte proportion d'emploi NSS de lemmes non-têtes provient donc d'une mauvaise segmentation initiale des titres.

Nous prenons comme hypothèse que le schéma 2 ne peut se trouver que dans un second segment de titre, écartant ainsi les titres mal segmentés. Si on fait ces requêtes uniquement sur les titres bisegmentaux, ce qui revient à contraindre que la marque de ponctuation soit segmentatrice, on obtient les résultats qui suivent :

- Têtes transdisciplinaires : 3 626 emplois de NSS
- Lemmes de têtes transdisciplinaires non-têtes : 1 395 emplois de NSS

Nous avons 36 731 occurrences de têtes transdisciplinaires en second segment qui ont une proportion à hauteur de 10 % à avoir un emploi de NSS. Sur les 47 335 autres occurrences de têtes nominales non transdisciplinaires de second segment, on estime à 3 166 les emplois en tant que NSS, soit une proportion de 7 %.

C) Tests de corrélation entre emploi NSS et le fait d'être une tête transdisciplinaire

En ne comptant que notre estimateur fondé sur les schémas 1 et 2 pour détecter les emplois NSS, car les autres CSS donnent en tout moins de 500 résultats et n'influent qu'à la marge, nous avons les informations suivantes :

Corpus	Nombre de têtes / dont emploi NSS	Nombre de têtes transdisciplinaires / dont emploi NSS	Nombre de têtes non transdisciplinaire / dont emploi NSS
Nombre de titres monosegmentaux	147 828		
Nombre de titres monosegmentaux dont la tête est un nom commun	136 734		
Nombre de titres bisegmentaux	103 170		

Nombre de 1 ^{er} segment dont la tête est un nom commun	136 734 + 79 959 = 216 693 / 29 123	58 003 / 12 072 21 %	158 690 / 17 051 11 %
Nombre de 2 nd segment dont la tête est un nom commun	84 066 / 6 792	36 731 / 3 626 10 %	47 335 / 3 166 7 %
Total	300 759 ↑→ / 35 915	94 734 / 15 698 17 %	206 025 / 20 217 10 %

On peut calculer la corrélation entre deux associations :

- Têtes transdisciplinaires et estimation d'emploi NSS : 0,35
- Têtes non transdisciplinaires et estimation d'emploi NSS : 0,18

On rappelle que plus un coefficient de corrélation est proche, en valeur absolue, de 1, plus les deux variables sont liées, positivement ou négativement selon la valeur du coefficient. On voit que le fait d'être une tête transdisciplinaire augmente ce coefficient, les têtes transdisciplinaires ont plus de chance d'être NSS, mais qu'il demeure trop faible pour qu'une véritable corrélation soit établie entre les deux notions.

D) Tests de corrélation entre emploi NSS et le fait d'être une tête

On peut néanmoins vouloir savoir si le fait, pour un nom commun, d'être une tête est corrélée au fait d'être un emploi en NSS. Il y a 1 118 481 de noms communs dans nos titres. Nous avons qu'il y a sur ceux-ci 300 759 têtes dont 35 915 sont estimées être des emplois NSS. Nous faisons donc le coefficient de corrélation entre :

- Tête et estimation d'emploi NSS : 0,30

Là aussi, le coefficient de corrélation est trop faible pour qu'un véritable lien soit fait entre le fait pour un mot d'être tête de segment et le fait d'être employé en tant que NSS.

E) Tests de corrélation entre emploi NSS et problème

Devant ce manque de résultats, nous revenons à *problème* qui compte 1 660 occurrences dans nos titres sur 1 118 481 occurrences de noms communs. On regarde, indépendamment que l'occurrence soit tête ou pas, si notre estimateur le classe comme potentiel NSS :

	Occurrences	NSS
<i>problème</i>	1 660 (dont 1226 têtes) / 1 118 481	185 (dont 167 têtes)

Nous calculons la corrélation entre :

- Fait pour une occurrence d'avoir pour lemme *problème* et d'être un NSS : 0,32.

Ce coefficient semble assez faible si l'on prend en compte le fait que *problème* soit un *prime shell nouns* et le 3^e sur la liste de fréquence de Flowerdew et Forest (2015). Nous ne pouvons que constater :

- Soit notre estimateur d'emploi en NSS est mauvais, pourtant le cas d'étude sur *problème* avait montré une précision de 94 % et un rappel de 81 % en ce qui concerne le schéma 1. Nous n'avons pas estimé ces valeurs pour le schéma 2 mais la non-segmentation des titres sur certains caractères pourraient expliquer ce défaut, ainsi que la non prise en compte des déverbaux à suffixe zéro et des constructions particulières comme *le problème posé par*.
- Soit il n'y a effectivement pas de corrélation entre le fait d'être une tête transdisciplinaire et d'être employé de façon sous-spécifiée. La similitude entre la liste des têtes transdisciplinaires et les listes de NSS, 88 % des têtes transdisciplinaires apparaissent dans la liste de Flowerdew et Forest (2015), n'est que d'ordre lexicale. Ce qui est renforcé par le fait que les NSS sont une classe fonctionnelle, un emploi potentiel d'un lemme, et non une classe lexicale, même si des propriétés sémantiques en facilitent l'utilisation en tant que NSS.

II.3.4 Transdisciplinarité des schémas

On peut chercher comment les deux schémas identifiés précédemment se répartissent dans les différents domaines de notre corpus. Nous mettons le pourcentage que cela fait par rapport aux têtes transdisciplinaires de ce domaine dans le premier segment pour le schéma 1, dans le second segment pour le schéma 2 et par rapport à toutes les têtes transdisciplinaires du domaine dans la troisième colonne. Nous mettons enfin l'ordre des domaines par rapport à ce pourcentage.

Domaine	Tête transdisciplinaire en emploi de NSS selon schéma 1				Tête transdisciplinaire en emploi de NSS selon schéma 2				Total tête transdisciplinaire en emploi de NSS			
Anthropologie	121	22 %	17		73	9 %	13		194	11 %	20	
Archéologie et Préhistoire	212	21 %	18		134	9 %	10		346	11 %	21	
Architecture	125	26 %	11		56	9 %	12		181	14 %	15	
Art et histoire de l'art	73	18 %	23		59	8 %	18		132	9 %	24	
Chimie	116	20 %	20		20	7 %	23		136	14 %	14	
Droit	521	19 %	21		124	7 %	21		645	13 %	18	
Éducation	495	29 %	7		195	12 %	5		690	17 %	7	
Gestion et management	1118	31 %	3		507	10 %	9		1625	16 %	10	
Géographie	47	31 %	2		24	12 %	6		71	16 %	9	
Histoire	253	19 %	22		199	8 %	19		452	9 %	23	
Informatique	919	26 %	10		177	11 %	7		1096	19 %	2	
Linguistique	484	26 %	9		272	12 %	4		756	14 %	13	
Littératures	97	15 %	25		65	6 %	24		162	8 %	25	
Mathématiques	128	20 %	19		20	9 %	14		148	15 %	12	
Philosophie	124	18 %	24		53	7 %	22		177	10 %	22	

Physique	2606	26 %	12	193	8 %	20	2799	21 %	1
Planète et Univers	165	24 %	15	42	9 %	15	207	15 %	11
Psychologie	139	30 %	5	51	12 %	3	190	18 %	4
Science politique	240	25 %	13	117	9 %	10	357	13 %	17
Sciences cognitives	158	32 %	1	67	12 %	2	225	18 %	3
Sciences de l'environnement	410	30 %	6	118	10 %	8	528	18 %	6
Sciences de l'information et de la communication	276	31 %	4	152	13 %	1	428	16 %	8
Sciences du Vivant	1414	25 %	14	228	8 %	16	1642	18 %	5
Sociologie	957	26 %	8	420	8 %	17	1377	13 %	16
Économie et finance quantitative	21	24 %	16	5	5 %	25	26	13 %	19

Nous constatons des écarts dans l'utilisation de ces schémas, et donc dans la présence de têtes transdisciplinaires en emploi sous-spécifié. L'étendue est de 13 et la moyenne de 14,36. La plus grande fréquence est en physique avec 21 %. On remarque des fréquences beaucoup plus faibles pour le schéma 2, ce qui indiquerait qu'il y a plus de têtes transdisciplinaires en emploi NSS dans le premier, ou le seul, segment.

Nous avons dans cette partie identifié un petit nombre de têtes transdisciplinaires, 123 en tout si on reprend tous les lemmes identifiés dans les différents sous-corpus, et 94 si on applique nos calculs globalement au corpus de travail. Les têtes transdisciplinaires sont très fréquentes et donc utilisées dans de nombreux titres de notre corpus de travail et, à 70 % pour les 123 têtes et à 79 % pour les 94 têtes, déjà relevées dans le lexique transdisciplinaire des écrits scientifiques de Tutin (2008). L'étude du second segment des titres bisegmentaux a mis en avant deux têtes transdisciplinaires qui le caractérisent tout particulièrement, *cas* et *exemple*. Les têtes transdisciplinaires sont caractérisées par une haute fréquence en tant que têtes et un haut degré d'abstraction. Nous conservons le nombre de 94 pour garder un point de vue global sur le corpus.

Nous avons ensuite rappelé le concept de NSS, un nom fréquent au faible contenu sémantique dont la particularité est d'être spécifié par son contexte à l'aide de plusieurs constructions spécificationnelles. Nous avons montré que le contenu spécifiant qui est relié au NSS joue une fonction d'attribut. Nous avons également montré que, si le NSS en a la capacité, on peut facilement passer de certaines CS à d'autres, que cela soit par l'ajout du pronom de reprise *ce* ou par l'ajout du verbe copule *être*. Nous avons également montré que, dans le cas d'un syntagme nominal comme contenu spécifiant, il faut toutefois que son nom noyau soit un déverbal qui dénote une action ou une activité.

Nous avons essayé de détecter les différentes occurrences de constructions spécificationnelles dans nos titres où une tête transdisciplinaire serait employée comme NSS. Nous nous sommes heurtés au problème que les définitions les plus contraignantes retournaient très peu de résultats, du fait

qu'elles utilisent des verbes alors que les titres sont essentiellement averbaux. Nous pouvons résumer les emplois sous-spécifiés des têtes transdisciplinaires dans les constructions spécificationnelles dans le tableau (11).

Construction spécificationnelle	Nombre de têtes intégrant une construction spécificationnelle
CS-I NSS + être + que	3
CS-II NSS + être + de + inf	1
C-III NSS + , + ce + être + que	0
C-IV NSS + , + ce être + de + inf	0
C-V NSS + que	0
CS-VI NSS + de + inf	estimé à 437
CS-VII NSS + de + DDAA	15 698
CS-VIII NSS + être + DDAA	1
CS-IX NSS + , + ce + être + DDDAA	1
Total	16 141 soit 6 % des 278 185 têtes nominales

Tableau 12: Présence des constructions spécificationnelles classiques dans notre corpus

Nous n'avons trouvé que très peu de constructions spécificationnelles classiques dans notre corpus, nous avons décidé d'utiliser la fouille de données séquentielles pour mettre à jour des schémas d'utilisation récurrents des têtes transdisciplinaires. Nous avons trouvé deux schémas qui restreignent la CS-VII en la situant au début du titre ou après une marque de segmentation et qui fonctionnent comme des constructions spécificationnelles.

Nous n'avons pas pu établir de corrélation entre les têtes transdisciplinaires, ou le simple fait d'être une tête de segment, et l'emploi sous-spécifié. Nous avons néanmoins identifié plusieurs emplois de têtes transdisciplinaires sous-spécifiés et que les têtes transdisciplinaires sont utilisées dans un emploi NSS à hauteur de 17 %, contre 10 % pour les autres mais sans qu'il y ait de corrélation systématique.

III. Discussion sur nos résultats, limites et perspectives

Dans cette dernière partie nous revenons sur notre travail et nos résultats pour les mettre en perspective. Il s'agit de montrer leurs limites et éventuellement les perspectives d'améliorations pour nous en affranchir.

III.1 Éléments de discussion

Limite de l'analyse en dépendance automatique de Talismane

Si de prime abord Talismane a donné une très bonne satisfaction pour étiqueter morphosyntactiquement les titres, il n'en est pas de même pour les relations en dépendance, notamment celles reposant sur la préposition *de* que Talismane relie souvent au mauvais recteur. Cela a peuplé de nombreux faux positifs nos requêtes au point où nous avons dû combiner la recherche via l'arbre de dépendances à la recherche positionnelle. Par exemple, l'énoncé A de B de C, se voit souvent attribué un arbre de dépendance où le second *de* a le même recteur que le premier, A, alors qu'il s'agit souvent de C. Ce cas peut-être très ambigu en français, mais empiriquement, nous avons fait un algorithme détectant B entre A et C et réattribuant le rôle de recteur à B. Des problèmes de liens de dépendances ayant une portée encore plus grande et fausse ont également été observés mais non quantifié. Cela nous laisse penser qu'on ne peut s'appuyer autant que nous le pensions initialement sur l'analyse en dépendance. L'utilisation d'un outil doit toujours être précautionneuse et détachée. Réaliser un post-traitement de correction des résultats en sortie pour comme nous l'avons fait, permet d'exploiter au mieux les puissants outils à notre disposition.

Limitations des têtes spécifiques aux domaines

Pour la question de la variation des têtes par rapport au domaine, nous avons finalement optés pour attribuer une pondération à chaque tête. Nous sommes libres après de choisir un seuil minimum, un nombre minimum ou un pourcentage de têtes pour passer à une appréciation binaire du fait qu'il s'agit d'une tête spécifique ou non. Il manque surtout un moyen d'évaluer la pertinence des têtes.

Nous n'avons pas utilisé l'apprentissage automatique pour obtenir les têtes spécifiques aux domaines. Nous aurions pu soumettre les titres résumés à leurs têtes, une ou deux selon le nombre de segments, pour obtenir un arbre de classification supervisée. En parcourant celui-ci, nous aurions pu voir quelles têtes étaient les plus importantes pour pouvoir catégoriser dans un domaine un titre, et donc quelles têtes étaient le plus spécifique à un domaine donné.

Nous y avons vu néanmoins deux obstacles. Le premier était d'avoir seulement une ou deux têtes comme traits est très pauvre : l'apprentissage automatique se base sur la définition de traits plus pertinents, mais notre travail se concentrait uniquement sur les têtes. Le second était la difficulté de parcourir l'arbre pour avoir une liste linéaire et coefficientée des têtes spécifiques comme nous l'avons obtenue avec notre méthode.

L'utilisation de la liste des têtes spécifiques pour une autre approche de la catégorisation se heurte. Le troisième obstacle était un obstacle d'utilisation de la : la couverture des têtes spécifiques est assez faible selon le domaine considéré. L'utilisation de cette liste pour catégoriser des titres ne donnerait pas un bon résultat, mais elle peut être utilisée comme un trait dans un processus de catégorisation par apprentissage automatique.

Têtes transdisciplinaires

La sélection des têtes transdisciplinaires sur un simple seuil de médiane, représentant le fait que la tête doit avoir dans au moins la moitié des domaines une fréquence supérieure à ce seuil est empirique. La définition d'une classe nominale par la statistique ou la structure syntaxique se prête très bien à l'automatisation. Néanmoins, il ne nous semble pas aussi simple de sélectionner automatiquement des noms sur des critères sémantiques, lorsqu'il s'agit d'aller plus loin qu'une liste.

Listes de NSS et des lexiques scientifiques

Une grande difficulté a été de mettre la main sur des listes numériques des différentes acceptations des NSS et des lexiques scientifiques. Elles peuvent servir seulement d'indices, mais précieux, car les NSS sont un emploi et non une classe lexicale a priori, bien qu'il existe des propriétés lexicales a priori de capacité à pouvoir être employé comme NSS. Certains articles pointaient sur un site web n'était plus en ligne, d'autres ne prenaient même pas cette peine, ou d'autres proposaient seulement un format PDF.

Pour la linguistique de corpus, la mise à disposition pérenne des listes produites par la computation est parfois aussi importante que l'article. La capacité de stocker un article avec des pièces-jointes, parfois volumineuses, nous semble importante, notamment pour les archives ouvertes. L'ensemble de nos données et de notre code est de notre côté disponible à l'URL : <https://github.com/Xitog/tal/tree/master/master2>

Opérationnalisation des NSS

L'opérationnalisation des NSS est ardue, surtout dans une perspective de traitement automatique des langues. L'idée de Huyghe (2018) de se retreindre au concept de nom porteur, noms capables de porter un contenu prépositionnel qui correspond aux constructions CS-I et CS-II, présente l'avantage de réduire considérablement le périmètre d'investigation pour pouvoir l'analyser plus profondément, comme il le fait pour *fait* dans son article.

Avec les constructions les moins contraintes, le bruit augmente considérablement. L'obligation d'un nom déverbal dénotant une action ou une activité permet de les restreindre. Muni d'une liste adéquate, mais il s'agit là-aussi d'une classe ouverte, ou, mieux, d'une règle de formation automatique des déverbaux, on pourrait considérablement augmenter la précision de notre recherche. Néanmoins, reste la question d'un nom non déverbal mais qui induit une action implicite.

Nous avons laissé de côté encore d'autres constructions spécificationnelles, faute de temps. Notamment Nakamura (2017) a commencé à développer des constructions attributives avec le verbe

avoir : « Il a pour **objectif** de rédiger une loi » / « Il a pour **objectif** la rédaction d'une loi » / « Il a pour objectif qu'une loi soit rédigée ». Roze et al. (2016) ont également mis à jour de nouvelles CS dont une est celle proposée par Nakamura avec *pour*.

Conclusion

La première étape de notre travail a été de revenir sur le travail effectué pour notre mémoire de M1 : l'identification de schémas récurrents après le double point dans les titres de publications scientifiques avait mis en avant une classe de noms communs abstraits, très fréquents et pluridisciplinaires. Nous sommes partis de cette découverte pour reformuler le problème et élargir son périmètre en une étude des têtes de segments des titres.

La deuxième étape a été de forger un périmètre de travail au sein du matériau initial, près de 340 000 titres tirés de HAL, qui nous ont été fournis par Tanguy et Rebeyrolle (à paraître) en utilisant la lemmatisation, la catégorisation morphosyntaxique et l'analyse en dépendances syntaxiques fournis par l'outil Talismane (Urieli, 2013). Nous avons opté pour garder les titres monosegmentaux ou bisegmentaux avec à chaque fois une tête par segment. Lorsque Talismane trouvait un segment à deux têtes, nous avons écarté le titre. Lorsque Talismane trouvait un segment sans tête dans un titre à deux segments, nous avons essayé d'en trouver une en promouvant un mot qui serait régi uniquement par un mot de l'autre segment, qui disposait lui d'une déjà tête. Nous avons pu conformer à notre règle « un segment une tête » près de 98 % des 56 851 titres auxquels il manquait une tête. Pour finir, nous avons constitué un corpus de travail de 250 998 titres, gardant près de 74 % du matériau initial.

Après avoir délimité notre périmètre et donc notre corpus de travail et identifié toutes les têtes, nous nous sommes d'abord interrogés sur le nombre de segments par titre en fonction du domaine. Il apparaît que les sciences humaines utilisent dans les mêmes proportions titres monosegmentaux et titres bisegmentaux tandis que les sciences exactes privilégient les titres monosegmentaux. Nous nous sommes interrogés sur leur classe grammaticale. Il s'est avéré que l'extrême majorité des têtes étaient des noms conférant une nature nominale aux titres : 86 % dans le cas des titres monosegmentaux. Dans le cas des titres bisegmentaux, cette majorité est très claire si l'on ne considère que le premier segment, 84 %, beaucoup moins si l'on demande aux deux segments d'avoir un nom pour tête, 68 %. Nous pouvons donc conclure que les titres sont essentiellement des syntagmes nominaux.

Partant de cette constatation, nous avons voulu savoir s'il y avait des têtes nominales spécifiques à certains domaines. Utilisant la valeur de $TF \cdot IDF$ en considérant les domaines comme un document unique et leurs titres comme autant de phrases de ce document, nous avons pondéré chaque tête par un indice de spécificité. Les têtes sélectionnées sont des noms pleins, qui révèlent les objets d'étude des différents domaines.

Nous avons également recherché les têtes transdisciplinaires, fréquentes dans tous les domaines. Nous avons trouvé 94 têtes transdisciplinaires dans tout notre corpus de travail. Nous avons remarqué que sur les 123 têtes transdisciplinaires, 86 % appartiennent au lexique transdisciplinaire des écrits scientifiques relevé par Tutin (2008).

Nous avons ensuite essayé de rapprocher les têtes transdisciplinaires, dont la fréquence et la transdisciplinarité impliquent un faible contenu sémantique, des noms sous-spécifiés qui se caractérisent par une très grande fréquence et un faible contenu sémantique également. Après avoir défini notre perception des noms sous-spécifiés, nous avons vu que leur définition opératoire est

structurelle : les noms sous-spécifiés s'insèrent dans des constructions spécificationnelles dont la fonction est de le de lier le nom général sous-spécifié à un contenu présent dans son contexte et qui va le « remplir ».

Nous nous sommes heurté d'un côté à l'absence dans notre corpus de constructions spécificationnelles classiques, estimées moins de 500, et de l'autre à une structure non assez sélective malgré la mise en évidence de la nécessité que le contenu spécifiant soit lié à une action ou une activité, soit par le truchement d'un verbe conjugué s'il s'agit d'une proposition subordonnée conjonctive, soit par le truchement d'un verbe à l'infinitif s'il s'agit d'une proposition infinitive, soit, s'il s'agit d'un syntagme nominal pouvant être inclus dans un syntagme prépositionnelle, que le noyau nominal soit un déverbal dénotant une action ou une activité.

Faute de construction spécificationnelle classique, nous avons donc étudié les schémas récurrents dans lesquels s'insèrent nos têtes transdisciplinaires. Nous avons pu établir que ceux-ci sont très ramassés et averbaux ce qui est en accord avec les spécificités des titres. Les deux schémas détectés se rapprochent d'une construction spécificationnelle, la CS-VII, qui est la moins contraignante des CS étudiées. Ils ajoutent comme contrainte que le schéma doit se trouver en début de titre ou de segment. Nous avons ensuite voulu étudier si, outre la correspondance syntaxique entre les deux schémas récurrents détectés et la CS-VII, il y avait effectivement un emploi sous-spécifié des têtes transdisciplinaires.

Nous avons rencontré des problèmes pour estimer l'utilisation en emploi sous-spécifié. La détermination de l'emploi repose moins, dans la configuration de la CS-VII, sur des critères syntaxiques que des critères lexicaux et sémantiques. Pour le lexical, à défaut de liste établie des DDAA, de plus car c'est une classe ouverte, la tâche est impossible, et pour la sémantique, nous n'avons pu faire autrement qu'en faisant appel au jugement de l'intuition ce qui est insuffisant dans une perspective d'automatisation. Néanmoins, nous avons pu déterminer un trait saillant morphologique de certains DDAA : des terminaisons en -tion, -sion, -age, -ment. Nous fondant dessus, nous avons établi un estimateur qui nous a donné le nombre d'utilisations en emploi sous-spécifié des têtes transdisciplinaires.

Malheureusement, nous n'avons pu montrer une corrélation entre les têtes transdisciplinaires et les emplois sous-spécifiés, ni même entre le fait pour un lemme d'être une tête et les emplois sous-spécifiés. Néanmoins, les têtes transdisciplinaires sont légèrement plus utilisées en emploi NSS que les têtes n'étant pas transdisciplinaires, 17 % contre 10 %. Nous pensons cependant que l'amélioration de notre estimateur, la prise en compte de CS spécifique, l'obtention d'une méthode pour vérifier si un nom est un DDAA à suffixe zéro, toutes ces actions permettraient d'augmenter le rappel d'emploi NSS et ainsi mieux mesurer la corrélation entre têtes, têtes transdisciplinaires et emploi NSS.

Bibliographie

- Adler, S. et Moline, E. (2018). Les noms généraux: présentation. *Langue française*, 2018(2), 5-18.
- Aleixandre-Benavent, R., Montalt-Resurecció, V. et Valderrama-Zurián, J. (2014). A descriptive study of inaccuracy in article titles on bibliometrics published in biomedical journals. *Scientometrics*, 101(1), 781-791.
- Anthony, L. (2001). Characteristic features of research article titles in computer science. *IEEE Transactions on Professional Communication*, 44(3), 187-194.
- Ball, R. (2009). Scholarly communication in transition: The use of question marks in the titles of scientific articles in medicine, life sciences and physics 1966–2005. *Scientometrics*, 79(3), 667-679.
- Baethge, C. (2008). Publish together or perish: the increasing number of authors per article in academic journals is the consequence of a changing scientific culture. *Deutsches Arzteblatt international*, 105(20), 380-383.
- Benítez-Castro, M. Á. (2014). *Formal, syntactic, semantic and textual features of English shell nouns*. Thèse de doctorat, Universidad de Granada.
- Biber, D., & Gray, B. (2010). Challenging stereotypes about academic writing: Complexity, elaboration, explicitness. *Journal of English for Academic Purposes*, 9(1), 2-20.
- Cheng, S. W., Kuo, C. W. et Kuo, C. H. (2012). Research article titles in applied linguistics. *Journal of Academic Language and Learning*, 6(1), A1-A14.
- Cori, M. et David, S. (2008). Les corpus fondent-ils une nouvelle linguistique ? *Langages*, 171, 111-129.
- Delhay, C. (2014). Pour un «complément-attribut». *Repères. Recherches en didactique du français langue maternelle*, (49), 57-76.
- Diers, D. et Downs, F. S. (1994). Colonizing: a measurement of the development of a profession. *Nursing research*, 43(5), 316.
- Dillon, J. (1981). The emergence of the colon: an empirical correlate of scholarship. *American Psychologist*, 36, 879-884.
- Dillon, J. T. (1982). In Pursuit of the Colon, A Century of Scholarly Progress: 1880–1980. *The Journal of Higher Education*, 53(1).
- Flowerdew, J. (2003). Signalling nouns in discourse. *English for specific purposes*, 22(4), 329-346.
- Flowerdew, J. (2006). Use of signalling nouns in a learner corpus. *International Journal of Corpus Linguistics*, 11(3), 345-362.
- Flowerdew, J. & Forest, R. W. (2015). *Signalling nouns in English*. Cambridge University Press.
- Francis, G. (1986). *Anaphoric nouns*. English Language Research, Department of English, University of Birmingham.

- Francis, G. (1994). Labelling discourse: an aspect of nominal-group lexical cohesion. In Coulthard, M. ed, (1994), *Advances in written text analysis*, London: Routledge, 83-101.
- François, J. et Legallois, D. (2006). Autour des grammaires de constructions et de patterns. *Cahiers du CRISCO*. Université de Caen.
- Goodman, R. A., Thacker, S. B. et Siegel, P. Z. (2001). What's in a title? A descriptive study of article titles in peer-reviewed medical journals. *Science*, 24(3), 75-78.
- Grant, M. J. (2013). What makes a good title? *Health Information & Libraries Journal*, 30(4), 259-260.
- Gustavii, B. (2017). *How to write and illustrate a scientific paper*. Cambridge University Press.
- Haggan, M. (2004). Research paper titles in literature, linguistics and science: dimensions of attraction. *Journal of Pragmatics*, 36(2), 293-317.
- Halliday, M. A. K. et Hasan, R. (1976). *Cohesion in English*. London: Longman.
- Hartley, J. (2005). To attract or to inform: What are titles for? *Journal of technical writing and communication*, 35(2), 203-213.
- Hatier, S. (2016). *Identification et analyse linguistique du lexique scientifique transdisciplinaire*. Approche fouillée sur corpus d'article de recherche en SHS, Thèse de doctorat, Université Grenoble Alpes.
- Hatier, S., Augustyn, M., Tran, T. T. H., Yan, R., Tutin, A. & Jacques, M. P. (2016). French cross-disciplinary scientific lexicon: extraction and linguistic analysis. In *Proceedings of Euralex*, 355-366.
- Ho-Dac, L.-M., Jacques, M.-P. & Rebeyrolle, J. (2004). Sur la fonction discursive des titres. Dans S. Porhiel et D. Klingler (éds). *L'unité texte*, Pleyben, Perspectives, 125-152.
- Hunston, S. & Francis, G. (1999). *Pattern Grammar. A Corpus-driven Approach to the Lexical Grammar of English*. Amsterdam: Benjamins (Studies in Corpus Linguistics 4).
- Huot, H. (1981). *Constructions infinitives du français: le subordonnant de* (Vol. 12). Genève : Librairie Droz.
- Huyghe, R. (2018). Généralité sémantique et portage propositionnel: le cas de fait. *Langue française*, 2018(2), 35-50.
- Ivanic, R. (1991). Nouns in search of a context: A study of nouns with both open- and closed-system characteristics. *International Review of Applied Linguistics in Language Teaching*, 2, 93-114.
- Jacques, T. S. et Sebire, N. J. (2010). The impact of article titles on citation hits: an analysis of general and specialist medical journals. *Journal of the Royal Society of Medicine Short Reports*, 1(1), 1-5.
- Jamali, H. R. et Nikzad, M. (2011). Article title type and its relation with the number of downloads and citations. *Scientometrics*, 88(2), 653-661.
- Kalmbach, J.-P. (2019). *La grammaire du français langue étrangère pour étudiants finnophones*. Repéré à <http://research.jyu.fi/grfle/675.html>
- Kolhatkar, V., & Hirst, G. (2014). Resolving shell nouns. Dans *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 499-510.

- Kutch, T. D. C. (1978). Relation of title length to numbers of authors in journal articles. *Journal of the American Society of Information Science*, 19(4), 200-202.
- Larivière, V., Gingras, Y., Sugimoto, C. R. and Tsou, A. (2015). Team size matters: Collaboration and scientific impact since 1900. *Journal of the Association for Information Science and Technology*, 66(7), 1323-1332.
- Leech, G. N. (2000). Grammars of spoken English: New outcomes of corpus-oriented research. *Language Learning*, 50(4), 675-724.
- Legallois, D. (2006). Quand le texte signale sa structure : la fonction textuelle des noms sous-spécifiés. *Corela HS-5* : <http://corela.edel.univ-poitiers.fr/index.php?id=1465>
- Legallois, D. (2008). Sur quelques caractéristiques des noms sous-spécifiés. *Scolia*, 23, 109-127.
- Legallois, D., & Gréa, P. (2006). L'objectif de cet article est de... Construction spécificationnelle et grammaire phraséologique. *Cahiers de praxématique*, (46), 161-186.
- Lyons, J. (1977). *Semantics* (Vol. 2). Cambridge: Cambridge university press.
- Mabe, M. A. et Amin, M. (2002). Dr. Jekyll and Dr. Hyde: Author-reader asymmetries in scholarly publishing. *Aslib Proceedings*, 54(3), 149-157.
- Merrill, E., & Knipps, A. (2014). What's in a Title?. *The Journal of Wildlife Management*, 78(5), 761-762.
- Mounin, G. (dir.) (2004). *Dictionnaire de la linguistique*. Paris : PUF (Quadrige).
- Nagano, R. L. (2015). Research article titles and disciplinary conventions: A corpus study of eight disciplines. *Journal of Academic Writing*, 5(1), 133-144.
- Nakamura, T. (2017). Extensions transitives de constructions spécificationnelles. *Langue française*, 2017 (2), 69-84.
- Nivard, J. (2010). Les Archives ouvertes de l'EHESS. Récupéré sur *La Lettre de l'École des hautes études en sciences sociales* n°34: <http://lettre.ehess.fr/index.php?5883>
- Paiva, C. E., Lima, J. P. da S. N. et Paiva, B. S. R. (2012). Articles with short titles describing the results are cited more often. *Clinics*, 67(5), 509-513.
- Quiniou, S., Cellier, P., Charnois, T. et Legallois, D. (2012). Fouille de données pour la stylistique: cas des motifs séquentiels émergents. Dans *Journées Internationales d'Analyse Statistique des Données Textuelles (JADT'12)*, Liège, 821-833.
- Rebeyrolle, J., Jacques, M. et Péry-Woodley, M. (2009). Titres et intertitres dans l'organisation du discours. *Journal of French Language Studies*, 19, 269-290.
- Riegel, M. (2006). Grammaire des constructions attributives : avec ou sans copule. Dans *Construction, acquisition et communication : Études linguistiques de discours contemporains*, Engwall, G. (éd.). Stockholm : Université de Stockholm(Acta Universitatis Stockholmiensis Romanica Stockholmiensia 23).
- Roze, C., Charnois, T., Legallois, D., Ferrari, S. et Salles, M. (2014). Identification des noms sous-spécifiés, signaux de l'organisation discursive. Dans *Proceedings of TALN 2014*, 1, 377-388.

- Sagi, I., & Yechiam, E. (2008). Amusing titles in scientific journals and article citation. *Journal of Information Science*, 34(5), 680-687.
- Salager-Meyer, F. & Alcaraz Ariza, M. Á. (2013). Titles are "serious stuff": a historical study of academic titles. *Jahr*, 4(7), 257-271.
- Schmid, H.-J. (2000). *English Abstract Nouns as Conceptual Shells. From Corpus to Cognition*. Berlin: Mouton de Gruyter (Topics in English Linguistics 34).
- Schmid, H. J. (2018). Shell nouns in English-a personal roundup. *Caplletra. Revista Internacional de Filologia*, (64), 109-128.
- Schwischay, B. (2001). Notes d'exposés sur deux modèles de description syntaxique [Document PDF]. Repéré à <http://www.home.uni-osnabrueck.de/bschwisc/archives/deuxmodeles.pdf>
- Soler, V. (2007). Writing titles in science: An exploratory study. *English for Specific Purposes*, 26, 90–102.
- Soler, V. (2011). Comparative and contrastive observations on scientific titles written in English and Spanish. *English for Specific Purposes*, 30(2), 124-137.
- Subotic, S. & Mukherjee, B. (2014). Short and amusing: The relationship between title characteristics, downloads, and citations in psychology articles. *Journal of Information Science*, 40(1), 115-124.
- Swales, J. M. et Feak, C. B. (1994). *Academic Writing for Graduate Students*. Ann Arbor: University of Michigan Press.
- Tadros, A. (1994). Predictive categories in expository text. In Coulthard, M. ed, (1994), *Advances in written text analysis*, London: Routledge, 83-96.
- Tanguy, L., Rebeyrolle, J. (à paraître). Les titres des publications scientifiques en français : fouille de texte pour le repérage de schémas lexico-syntaxiques.
- Townsend, M. A. (1983). Titular Colonicity and Scholarship: New Zealand Research and Scholarly Impact. *New Zealand Journal of Psychology*, 12, 41-43.
- Tutin, A. (2007). Autour du lexique et de la phraséologie des écrits scientifiques. *Revue Française de Linguistique Appliquée*, 12(2), 5-14.
- Tutin, A. (2008). Sémantique lexicale et corpus : l'étude du lexique transdisciplinaire des écrits scientifiques. *Lublin studies in modern languages and literature*, 32, 242-260.
- Urieli, A. (2013). *Robust French syntax analysis: reconciling statistical methods and linguistic knowledge in the Talisman toolkit*. Toulouse: Doctoral dissertation, Université de Toulouse II-Le Mirail.
- Urieli, A. et Tanguy, L. (2013). L'apport du faisceau dans l'analyse syntaxique en dépendances par transitions : études de cas avec l'analyseur Talisman. *Actes de TALN*, Sables D'Olonne.
- Wang, Y. et Bai, Y. (2007). A corpus-based syntactic study of medical research article titles. *System*, 35(3), 388-399.
- Winter, E. O. (1977). A clause-relational approach to English texts: a study of some predictive lexical items in written discourse. *Instructional science*, 6(1), 1-92.

Winter, E. O. (1992). The notion of unspecific versus specific as one way of analysing the information of a fund-raising letter. *Discourse description: Diverse linguistic analyses of a fund-raising text*, 131-170.

Yitzhaki, M. (1994). Relation of title length of journal articles to number of authors. *Scientometrics*, 30(1), 321-332.

Yitzhaki, M. (2002). Relation of the title length of a journal article to the length of the article. *Scientometrics*, 54(3), 435-447.

Annexes

A1. Distance des domaines de par leurs têtes spécifiques

Distances	0.math	1.sht.inform	1.sht.droit	1.sht.ling	1.sht.gestion	0.phys	1.sht.anthro	1.sht.hist	0.sde	1.sht.phil	0.sdv	1.sht.archi	0.info	1.sht.edu	1.sht.litt	0.scco	1.sht.socio	1.sht.geo	1.sht.art	0.chim	0.sdu	1.sht.py	1.sht.scio	0.qfin	
0.math	0.00000	0.00751	0.00631	0.01596	0.01777	0.01780	0.019385	0.01947	0.026513	0.019763	0.018929	0.021131	0.017654	0.018990	0.020168	0.019431	0.017548	0.021781	0.023302	0.020770	0.021578	0.022563	0.010263	0.018912	0.025392
1.sht.inform	0.00751	0.00000	0.014531	0.012587	0.009874	0.012715	0.012332	0.010783	0.014729	0.013629	0.011331	0.013053	0.013104	0.010376	0.013557	0.013015	0.005273	0.016194	0.018170	0.027586	0.016408	0.016607	0.011342	0.011456	0.020880
1.sht.droit	0.00631	0.014531	0.00000	0.015485	0.021462	0.015538	0.015152	0.013359	0.016929	0.015982	0.014134	0.017478	0.015946	0.013865	0.026316	0.015788	0.021640	0.028244	0.020176	0.028823	0.018362	0.019016	0.016539	0.013668	0.022380
1.sht.ling	0.01596	0.012587	0.015485	0.00000	0.021462	0.015538	0.015152	0.013359	0.016929	0.015982	0.014134	0.017478	0.015946	0.013865	0.026316	0.015788	0.021640	0.028244	0.020176	0.028823	0.018362	0.019016	0.016539	0.013668	0.022380
1.sht.gestion	0.01777	0.009874	0.021462	0.015538	0.00000	0.011176	0.011180	0.002951	0.013272	0.012649	0.009406	0.013937	0.011958	0.009032	0.027237	0.011790	0.007166	0.024073	0.017265	0.026805	0.015297	0.015985	0.012665	0.019382	0.019661
0.phys	0.01780	0.019385	0.01947	0.026513	0.01777	0.00000	0.013540	0.012237	0.014996	0.014618	0.011276	0.016035	0.012362	0.011955	0.014803	0.013785	0.008671	0.016803	0.018723	0.026355	0.016449	0.017611	0.014790	0.012994	0.021346
1.sht.anthro	0.019385	0.01947	0.026513	0.01777	0.01780	0.019385	0.00000	0.011049	0.015296	0.014201	0.011938	0.015533	0.014164	0.011746	0.014657	0.013887	0.009549	0.016595	0.017802	0.027823	0.016888	0.017058	0.014560	0.012301	0.021348
1.sht.hist	0.01947	0.026513	0.01777	0.01780	0.019385	0.01947	0.011049	0.00000	0.014171	0.012721	0.010673	0.014338	0.012958	0.010215	0.022272	0.013942	0.008133	0.015572	0.016275	0.027823	0.016888	0.017058	0.014560	0.012301	0.021348
0.sde	0.026513	0.01947	0.01777	0.01780	0.019385	0.01947	0.015296	0.014171	0.00000	0.016443	0.013588	0.016443	0.013588	0.010215	0.022272	0.013942	0.008133	0.015572	0.016275	0.027823	0.016888	0.017058	0.014560	0.012301	0.021348
1.sht.phil	0.019763	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929
0.sdv	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929	0.018929
1.sht.archi	0.021131	0.013053	0.013104	0.010376	0.013557	0.013015	0.005273	0.016194	0.018170	0.027586	0.016408	0.016607	0.011342	0.011456	0.020880	0.010263	0.018912	0.025392	0.023302	0.020770	0.021578	0.022563	0.010263	0.018912	0.025392
0.info	0.021131	0.013053	0.013104	0.010376	0.013557	0.013015	0.005273	0.016194	0.018170	0.027586	0.016408	0.016607	0.011342	0.011456	0.020880	0.010263	0.018912	0.025392	0.023302	0.020770	0.021578	0.022563	0.010263	0.018912	0.025392
1.sht.edu	0.020168	0.019431	0.017548	0.021781	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302
1.sht.litt	0.020168	0.019431	0.017548	0.021781	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302
0.scco	0.020168	0.019431	0.017548	0.021781	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302
1.sht.socio	0.020168	0.019431	0.017548	0.021781	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302
1.sht.geo	0.020168	0.019431	0.017548	0.021781	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302
1.sht.art	0.020168	0.019431	0.017548	0.021781	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302
0.chim	0.020168	0.019431	0.017548	0.021781	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302
0.sdu	0.020168	0.019431	0.017548	0.021781	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302
1.sht.py	0.020168	0.019431	0.017548	0.021781	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302
1.sht.scio	0.020168	0.019431	0.017548	0.021781	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302
0.qfin	0.020168	0.019431	0.017548	0.021781	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302	0.020770	0.021578	0.022563	0.023302

A2. Combinaisons des têtes de titres bisegmentaux

Ce tableau liste toutes les combinaisons possibles des têtes de titres bisegmentaux en termes de catégories morphosyntaxiques et en agrégeant les catégories nominales, propositionnelles et verbales en une seule à chaque fois, respectivement NOUN, PREP et VERB. La requête pour obtenir ce tableau est donné en première ligne, ainsi que le nombre de titres sur lesquels la requête a été lancée : ici l'ensemble des titres bisegmentaux de notre corpus de travail.

*** ['roots.0.pos:agg', 'roots.1.pos:agg'] *** (110785)

01.	NOUN-NOUN	75592	68.2331 %	68.23 %
02.	NOUN-PREP	8996	8.1202 %	76.35 %
03.	VERB-NOUN	8506	7.6779 %	84.03 %
04.	NOUN-VERB	5426	4.8978 %	88.93 %
05.	PREP-NOUN	4650	4.1973 %	93.13 %
06.	NOUN-CC	1209	1.0913 %	94.22 %
07.	VERB-PREP	1015	0.9162 %	95.13 %
08.	NOUN-ADJ	1000	0.9026 %	96.04 %
09.	VERB-VERB	661	0.5967 %	96.63 %
10.	ADJ-NOUN	537	0.4847 %	97.12 %
11.	NOUN-PONCT	395	0.3565 %	97.47 %
12.	NOUN-CS	368	0.3322 %	97.81 %
13.	PREP-VERB	333	0.3006 %	98.11 %
14.	PREP-PREP	310	0.2798 %	98.39 %
15.	CS-NOUN	270	0.2437 %	98.63 %
16.	VERB-PONCT	145	0.1309 %	98.76 %
17.	VERB-CC	140	0.1264 %	98.89 %
18.	NOUN-PRO	133	0.1201 %	99.01 %
19.	NOUN-ADV	105	0.0948 %	99.10 %
20.	VERB-ADJ	91	0.0821 %	99.18 %
21.	ADJ-PREP	82	0.0740 %	99.26 %
22.	PREP-CC	64	0.0578 %	99.32 %
23.	PRO-NOUN	63	0.0569 %	99.37 %
24.	ADJ-VERB	59	0.0533 %	99.43 %
25.	VERB-CS	50	0.0451 %	99.47 %
26.	NOUN-DET	42	0.0379 %	99.51 %
27.	PREP-ADJ	38	0.0343 %	99.54 %
28.	CS-PREP	37	0.0334 %	99.58 %
29.	PREP-CS	30	0.0271 %	99.60 %
30.	CS-VERB	27	0.0244 %	99.63 %
31.	CC-NOUN	27	0.0244 %	99.65 %
32.	NOUN-I	27	0.0244 %	99.68 %
33.	VERB-ADV	24	0.0217 %	99.70 %
34.	PREP-PONCT	23	0.0208 %	99.72 %
35.	ADV-VERB	20	0.0181 %	99.74 %
36.	NOUN-ADVWH	18	0.0162 %	99.75 %
37.	PONCT-NOUN	15	0.0135 %	99.77 %
38.	NOUN-ET	14	0.0126 %	99.78 %
39.	ADJ-CC	14	0.0126 %	99.79 %
40.	ADV-NOUN	14	0.0126 %	99.81 %
41.	NOUN-CLO	14	0.0126 %	99.82 %
42.	DET-NOUN	13	0.0117 %	99.83 %

43.	ET-NOUN	13	0.0117 %	99.84 %
44.	PRO-VERB	13	0.0117 %	99.85 %
45.	VERB-ADVWH	13	0.0117 %	99.87 %
46.	VERB-PRO	12	0.0108 %	99.88 %
47.	CLR-NOUN	11	0.0099 %	99.89 %
48.	NOUN-DETH	11	0.0099 %	99.90 %
49.	ADJ-CS	9	0.0081 %	99.90 %
50.	NOUN-PROREL	8	0.0072 %	99.91 %
51.	CS-PONCT	6	0.0054 %	99.92 %
52.	CS-CC	6	0.0054 %	99.92 %
53.	ADJ-ADJ	6	0.0054 %	99.93 %
54.	PRO-PREP	5	0.0045 %	99.93 %
55.	CC-PREP	5	0.0045 %	99.94 %
56.	NOUN-CLS	5	0.0045 %	99.94 %
57.	VERB-DET	5	0.0045 %	99.95 %
58.	CS-ADJ	4	0.0036 %	99.95 %
59.	PONCT-VERB	4	0.0036 %	99.95 %
60.	ADJ-PONCT	3	0.0027 %	99.96 %
61.	PONCT-PREP	2	0.0018 %	99.96 %
62.	VERB-ET	2	0.0018 %	99.96 %
63.	NOUN-CLR	2	0.0018 %	99.96 %
64.	VERB-DETH	2	0.0018 %	99.96 %
65.	PREP-I	2	0.0018 %	99.96 %
66.	ADJ-PRO	2	0.0018 %	99.97 %
67.	VERB-I	2	0.0018 %	99.97 %
68.	VERB-PROREL	2	0.0018 %	99.97 %
69.	I-NOUN	2	0.0018 %	99.97 %
70.	CS-CS	2	0.0018 %	99.97 %
71.	I-VERB	2	0.0018 %	99.98 %
72.	CLO-NOUN	2	0.0018 %	99.98 %
73.	ADVWH-NOUN	2	0.0018 %	99.98 %
74.	CLS-VERB	1	0.0009 %	99.98 %
75.	PONCT-CC	1	0.0009 %	99.98 %
76.	CC-VERB	1	0.0009 %	99.98 %
77.	PRO-PONCT	1	0.0009 %	99.98 %
78.	PRO-CC	1	0.0009 %	99.98 %
79.	PRO-ADJ	1	0.0009 %	99.98 %
80.	PREP-ADV	1	0.0009 %	99.99 %
81.	PREP-CLR	1	0.0009 %	99.99 %
82.	CLR-VERB	1	0.0009 %	99.99 %
83.	ET-PREP	1	0.0009 %	99.99 %
84.	I-PREP	1	0.0009 %	99.99 %
85.	PREP-ET	1	0.0009 %	99.99 %
86.	CC-CLS	1	0.0009 %	99.99 %
87.	DET-PREP	1	0.0009 %	99.99 %
88.	ET-VERB	1	0.0009 %	99.99 %
89.	PREP-DETH	1	0.0009 %	99.99 %
90.	CLS-NOUN	1	0.0009 %	99.99 %
91.	PREP-DET	1	0.0009 %	100.00 %
92.	VERB-PROWH	1	0.0009 %	100.00 %
93.	CC-ADJ	1	0.0009 %	100.00 %
94.	ADVWH-PREP	1	0.0009 %	100.00 %
95.	VERB-CLO	1	0.0009 %	100.00 %
96.	PREP-PRO	1	0.0009 %	100.00 %

A3. Liste des têtes transdisciplinaires

Le tableau suivant présente nos 123 têtes transdisciplinaires. Est indiqué le lemme, la catégorie du discours, si le lemme appartient aux formes du lexique transdisciplinaire des écrits scientifiques (Tutin, 2008) (LTES) et si le lemme appartient à la liste des signalling nouns (Flowerdew et Forest, 2015) avec la fréquence normalisée dans leur corpus. Nous notons que :

- Sur les 123 têtes transdisciplinaires relevées, 86 appartiennent au LTES, soit 70 %.
- Sur les 123 têtes transdisciplinaires relevées, 110 sont également relevées par Flowerdew et Forest comme étant utilisées comme signalling nouns, soit 89 %.
- Sur les 123 têtes transdisciplinaires relevées, 103 sont également des têtes spécifiques, soit 84 %.

N°	Lemme	Tout le corpus	Titres monosegmentaux	1 ^{er} segment des titres bisegmentaux	2 ^e segment des titres bisegmentaux	Présence dans le LTES	Présence dans signalling nouns
1	activité	1		1		LTES	59
2	an	1			1	LTES	
3	analyse	1	1	1	1	LTES	178
4	application	1	1	1	1	LTES	44
5	apport	1	1	1	1	LTES	16
6	approche	1	1	1	1	LTES	246
7	aspect	1	1		1	LTES	78
8	bilan	1			1	LTES	83
9	cadre	1	1		1	LTES	31
10	cas	1			1	LTES	890
11	changement	1			1	LTES	209
12	comparaison	1	1		1	LTES	44
13	compte			1			18
14	concept	1			1	LTES	143
15	condition				1	LTES	248
16	conséquence	1	1		1	LTES	132
17	construction	1	1	1	1	LTES	2
18	contexte			1	1	LTES	73
19	contribution	1	1		1	LTES	16
20	contrôle		1			LTES	3
21	culture			1			
22	défi	1			1		26
23	définition				1	LTES	68
24	démarche				1	LTES	112
25	développement	1	1	1	1	LTES	39
26	dimension	1				LTES	8
27	discours	1			1		51

28	dispositif	1		1	1	LTES	7
29	donnée				1	LTES	44
30	dynamique	1	1	1	1		
31	économie			1			
32	effet	1	1	1	1	LTES	393
33	élément	1	1		1	LTES	33
34	émergence	1	1		1		
35	enjeu	1	1	1	1		
36	enquête	1			1		16
37	enseignement	1			1		
38	espace	1	1	1	1		
39	essai	1	1		1		41
40	état	1	1	1	1	LTES	10
41	étude	1	1	1	1	LTES	18
42	évaluation	1	1	1	1	LTES	10
43	évolution	1	1	1	1	LTES	39
44	exemple	1		1	1	LTES	421
45	expérience	1	1	1	1	LTES	3
46	figure	1	1	1	1		88
47	fonction		1			LTES	150
48	formation	1	1	1	1		
49	forme	1	1	1	1	LTES	88
50	gestion	1	1	1		LTES	
51	histoire	1	1	1	1		20
52	identité			1			3
53	illustration				1		33
54	image	1	1	1	1	LTES	5
55	impact	1	1	1	1		96
56	influence	1	1	1	1	LTES	44
57	intégration	1	1	1		LTES	
58	interaction	1	1	1	1	LTES	15
59	intérêt	1	1		1	LTES	29
60	introduction	1	1	1	1	LTES	70
61	jeu	1	1	1	1		
62	leçon				1		51
63	lecture	1	1		1	LTES	33
64	limite				1	LTES	10
65	mesure	1	1	1		LTES	46
66	méthode	1	1	1	1	LTES	280
67	méthodologie	1	1		1		13
68	mode				1	LTES	11
69	modèle	1	1	1	1	LTES	474
70	modélisation	1	1	1	1	LTES	3

71	mythe				1		2
72	note	1	1	1	1		13
73	notion		1			LTES	73
74	objet	1			1	LTES	3
75	organisation	1	1	1		LTES	13
76	outil	1	1	1	1	LTES	7
77	perception	1				LTES	85
78	paradoxe				1		11
79	parcours				1		36
80	perspective	1	1		1	LTES	36
81	piste				1		2
82	place	1	1	1	1	LTES	21
83	point	1	1		1		393
84	politique	1	1	1	1		2
85	pratique	1	1	1	1		73
86	présentation	1	1	1	1	LTES	11
87	principe	1			1	LTES	251
88	problématique				1		287
89	problème	1	1		1	LTES	619
90	processus	1	1	1		LTES	230
91	production	1	1	1		LTES	2
92	projet	1	1	1	1	LTES	37
93	proposition	1	1		1	LTES	46
94	question	1	1	1	1	LTES	313
95	rapport	1			1	LTES	10
96	réalité				1	LTES	23
97	recherche	1	1	1	1	LTES	2
98	réflexion	1	1	1	1	LTES	16
99	regard	1	1		1		5
100	relation	1	1	1	1	LTES	93
101	remarque	1	1		1		21
102	représentation	1	1	1	1	LTES	11
103	réseau	1	1	1		LTES	7
104	résultat	1			1	LTES	572
105	retour	1	1	1	1		29
106	revue				1		8
107	rôle	1	1	1	1	LTES	153
108	science	1					
109	source				1	LTES	10
110	stratégie	1	1	1	1	LTES	205
111	structure	1	1	1	1	LTES	13
112	synthèse				1	LTES	2
113	système	1	1	1	1	LTES	109

114	temps		1			LTES	184
115	théorie	1	1		1		494
116	traitement	1	1			LTES	300
117	transformation		1			LTES	2
118	travail	1	1	1		LTES	24
119	usage	1	1	1	1	LTES	73
120	utilisation	1	1	1	1		5
121	valeur		1			LTES	13
122	variation	1	1			LTES	15
123	voie				1	LTES	668
	123	94	81	63	99	86	110 / 123 83 / 94

A4. Étiquettes utilisées par Talismane et HAL

A4.1 Catégories morphosyntaxiques de Talismane

Ces informations sont tirées de <http://joliciel-informatique.github.io/talismane/#tagset>.

Code	Catégorie morphosyntaxique
ADJ	Adjectif
ADV	Adverbe
ADVWH	Adverbe interrogatif
CC	Conjonction de coordination
CLO	Clitique objet
CLR	Clitique réflexif
CLS	Clitique sujet
CS	Conjonction de subordination
DET	Déterminant
DETH	Déterminant interrogatif
ET	Mot étranger
I	Interjection
NC (que nous rassemblons dans NOUN)	Nom commun
NPP (que nous rassemblons dans NOUN)	Nom propre
P (que nous rassemblons dans PREP)	Préposition
P+D (que nous rassemblons dans PREP)	Préposition et déterminant combinés ("du")
P+PRO (que nous rassemblons dans PREP)	Préposition et pronom combiné ("duquel")
PONCT	Ponctuation
PRO	Pronom
PROREL	Pronom relatif
PROWH	Pronom interrogatif

V (que nous rassemblons dans VERB)	Verbe à l'indicatif
VIMP (que nous rassemblons dans VERB)	Verbe à l'impératif
VINF (que nous rassemblons dans VERB)	Verbe à l'infinitif
VPP (que nous rassemblons dans VERB)	Verbe au participe passé
VPR (que nous rassemblons dans VERB)	Verbe au participe présent
VS (que nous rassemblons dans VERB)	Verbe au subjonctif

A4.2 Code des 27 domaines de HAL retenus

Ces informations sont tirées de HAL : <https://hal.archives-ouvertes.fr>

01	0.chim	Chimie
02	0.info	Informatique
03	0.math	Mathématiques
04	0.phys	Physique
05	0.qfin	Économie et finance quantitative
06	0.scco	Sciences cognitives
07	0.sde	Sciences de l'environnement
08	0.sdu	Planète et Univers
09	0.sdv	Sciences du Vivant
10	1.shs.anthro	Anthropologie
11	1.shs.archeo	Archéologie et Préhistoire
12	1.shs.archi	Architecture
13	1.shs.art	Art et histoire de l'art
14	1.shs.autre	Autres
15	1.shs.droit	Droit
16	1.shs.edu	Éducation

17	1.shs.geo	Géographie
18	1.shs.gestion	Gestion et management
19	1.shs.hist	Histoire
20	1.shs.infocom	Sciences de l'information et de la communication
21	1.shs.ling	Linguistique
22	1.shs.litt	Littératures
23	1.shs.phil	Philosophie
24	1.shs.psy	Psychologie
25	1.shs.scipo	Science politique
26	1.shs.socio	Sociologie
27	NONE	Pas de domaine associé

A5. Éléments techniques

A5.A Présentation de l'API de requêtage de notre corpus

Nous présentons dans cette partie notre interface de programmation de l'application (API) que nous avons développée afin d'interroger notre corpus.

Requêtes sur notre corpus pour filtrer le corpus, trouver des titres et faire des statistiques.

```
stat('domain')
```

Produit un comptage des titres selon le domaine des titres. Le résultat est un dictionnaire où la clé est le domaine et la valeur le nombre de titre dans ce domaine.

```
stat(('nb_parts', 'nb_segments'))
```

Produit un comptage des titres selon les combinaisons des valeurs possibles pour le nombre de parties et le nombre de segments. Le résultat est un dictionnaire où la clé est un tuple constitué d'une combinaison existante de valeurs des deux dimensions, par exemple 1 partie, 2 segments, et la valeur le nombre de titre correspondant à cette combinaison, le nombre de titres ayant 1 partie et 2 segments.

```
count({'nb_parts' : 1, 'nb_segments' : 2})
```

Compte le nombre de titre ayant une partie et deux segments.

```
t12 = select({'nb_parts' : 1, 'nb_segments' : 2})
```

Création d'un sous-corpus composé des titres ayant une partie et deux segments. On peut ensuite utiliser les requêtes stat et count sur celui-ci via une variable globale qui contient le corpus courant.

```
find({'nb_roots' : 2}, nb=20)
```

Cherche et affiche 20 titres ayant 2 têtes.

```
find({'roots.0.lemma' : 'rôle', 'roots.1.lemma' : 'cas',  
      'segments.0.lemma' : '.'})
```

Cherche et affiche 5 titres dont la tête du premier segment est le lemme *rôle*, celle du second segment le lemme *cas* et dont le signe de ponctuation segmentant est un point. Cette requête ne marche que sur un corpus constitué de titres à au moins deux segments.

```
avg('nb_segments')
```

```
minn('nb_segments')
```

```
maxx('nb_segments')
```

Obtient respectivement la moyenne des valeurs, la valeur minimum et la valeur maximum pour la clé *nb_segments* dans le corpus actuel.

A5.B Description de nos données informatiques

Nous avons comme données de base un ensemble de 339 687 titres ayant les caractéristiques suivantes :

- identifiant,
- année,
- type de support (article, chapitre ou communication),
- domaine,
- auteurs,
- nombre d'auteurs,
- texte du titre,
- liste de mots et de signes de ponctuation que nous appelons tokens du titre :
 - Pour chaque token :
 - forme
 - étiquette morphosyntaxique
 - lemme (toujours égale à sa forme pour un signe de ponctuation)
 - informations supplémentaires
 - token recteur
 - type de relation de dépendance
 - sa position dans le titre
- longueur du titre en nombre de tokens (mots + signes de ponctuation),
- longueur du titre en nombre de mots uniquement,
- segments :
 - Permet d'accéder aux différents segments du titre et notamment :
 - sa tête,
 - son caractère segmentant (si ce n'est pas un premier segment)
 - la position de la tête dans le titre,
 - la position du caractère segmentant s'il y en a un
- nombre de segments.

A5.C Analyse de 100 titres traités par Talismane

Nous avons analysé 100 titres traités par Talismane pour vérifier qu'il catégorisait bien les têtes de segments. Nous prenons 20 titres pour chaque structure (nombre de segments et position des têtes dans les segments) qui nous intéresse. Nous indiquons :

- Son identifiant dont la couleur indique le résultat de l'analyse pour le titre :
 - en **vert** si le titre a été analysé correctement en ce qui concerne la détection de têtes de segments,
 - en **orange** si l'analyse de Talismane est discutable mais n'impacte pas notre analyse,
 - en **rouge** si elle est fausse en ne détectant pas la bonne tête de segment,

- en **violet** si la promotion d'un mot en tête de segment par notre algorithme fait changer le titre de catégorie structurelle,
- en **rose** si une tête n'a pas été détectée.
- Pour les cinq structures qui nous intéressent, un code segment- tête de la forme :
 - 1__ pour un titre ayant 1 segment et 1 tête,
 - 2__ pour un titre ayant 1 segment et 2 têtes,
 - 1:0 pour un titre ayant 1 tête dans son premier segment et 0 dans son second,
 - 0:1 pour l'inverse,
 - 1:1 pour un titre ayant 1 tête dans chacun de ses deux segments.
- Les têtes de segment sont en gras et :
 - en **vert** si elles sont correctement catégorisées et lemmatisées,
 - en **bleu** si le lemme est incorrect ou inconnu (lemme ignoré pour NPP),
 - en **orange** si la catégorie morphosyntaxique est incorrecte,
 - en **rouge** s'il ne s'agit pas d'une tête,
 - en **violet** si elles ne sont pas détectées par Talismane mais par notre algorithme,
 - en **rose** si elles ne sont pas détectées ni par Talismane ni par notre algorithme.

001 **62230** 1__ Un possible **modele** semiotique global de la communication
 Note 01 : L'absence d'accent fait que Talismane n'associe pas ce NC au Lemme modèle.

002 **62250** 1__ L'**IMPACT** DE L'EDITION ELECTRONIQUE SUR LA CRISE DU KOSOVO

003 **460613** 1__ Un **indicateur** de politique d'ouverture à l'immigration

004 **62244** 1__ Le **déplacement** médiatique du débat politique

005 **110369** 1__ L'**imprimerie** et sa diffusion en Extrême-Orient

006 **911256** 1__ Les **enfants** d'Hygie

007 **410464** 1__ **Optimisation** de la précipitation des métaux lourds en mélange

008 **911470** 1__ L'**héritage** du Boiteux d'Orgemont

009 **216325** 1__ **DIFFUSION** INTERGRANULAIRE ET ÉNERGIE DES JOINTS DE GRAINS

010 **760276** 1__ **Dépôt** sec des aérosols à l'interface air-eau

011 **1808328** 1__ **Modélisation** de la structure d'un mélange à haute dilution

012 **1015139** 1__ **Analyse** écophysiological de la nitrophilie des espèces adventices

013 **264210** 1__ Un **regard** sur les approches basées sur la vision par ordinateur

014 **1759146** 1__ L'**implantation** de l'abbaye de Conques dans les environs de Sainte-Foy-la-Grande
 au XIe siècle

015 **215986** 1__ La **persistance** du droit successoral de l'Ancien Régime dans l'Europe du XIXe siècle
 *Note 02 : On remarque que Talismane fait dépendre Le du de persistance plutôt que Europe mais
 cela n'affecte pas notre analyse qui se limite à la tête de segment.*

016 **162355** 1__ **Faut-il** jeter la Méditerranée avec l'eau du bain ?

017 **215983** 1__ La **défense** de la victime en France au XIXe et au XXe siècle

018 **110374** 1__ **Rédaction** de 120 notices

019 **62249** 1__ **Vers** une approche ethnographique des usages des Technologies de l'Information et
 de la Communication au sein des petites et moyennes entreprises malaisiennes
 *Note 03 : L'enchaînement de compléments de nom peut perdre Talismane : il ne sait plus par quoi
 est régi la préposition de. Ici celui avant l'Information est indiqué comme étant régi par approche au lieu de Technologies. Cela n'a pas d'incidence sur notre*

travail.

020 1808326 1__ Algorithme de construction de modèles markoviens multidimensionnels pour le mélange des poudres

021 216380 2__ DIFFUSION AVANT ET ARRIÈRE D'IONS LOURDS ET MOMENTS ANGULAIRES COMPLEXES

022 1258669 2__ Contenu et exigences du travail

Note 04 : Talismane normalement ne désigne que le premier NC d'un schéma NC CC NC comme tête. Ici, il désigne les deux NC ce qui n'est pas cohérent.

023 312877 2__ Demain la géographie sociale.

Note 05 : La promotion de l'adverbe comme tête est discutable.

024 1015192 2__ Évaluation de la dispersion des propriétés mécaniques d'un matériau composite par

sous-échantillonnage

Note 06 : La présence d'un tiret provoque une erreur dans Talismane.

025 1808361 2__ Conditionnement des boues par gel-dégel

Note 07 : dégel est désigné comme tête alors que ce n'est clairement pas le cas à cause du tiret.

026 264579 2__ Institutions [Les humanités et les grandes institutions du savoir en France]

Note 08 : On peut considérer le texte entre crochets comme un segment non détecté.

027 1258688 2__ Comparaison isoenzymatique de deux populations boliviennes (altitude et plaine)

de Triatoma infestans (Hemiptera\, Reduviidae)

Note 09 : de est désigné comme tête alors que ce n'est clairement pas le cas.

028 162715 2__ Transfert de chaleur et de masse dans une salle d'opérations conditionnée\, comparaison entre deux modes de soufflage

Note 10 : La virgule n'est pas considérée comme segmentante mais ici elle devrait l'être.

029 264613 2__ Accès à l'information et reconnaissance d'un droit à l'information environnementale - Le nouveau contexte juridique international

Note 11 : Le tiret n'est pas considéré comme segmentant mais ici il devrait l'être. Cela est facilité par la présence d'une majuscule.

030 62420 2__ De l'appropriation inachevée du concept de genre (gender) en communication organisationnelle

Note 12 : en est désigné comme tête alors que ce n'est clairement pas le cas.

031 216445 2__ APPLICATION DES MÉTHODES STATISTIQUES AU CALCUL DES CHAMPS THERMIQUES TURBULENTS

NON HOMOGÈNES

Note 13 : HOMOGÈNES est désigné comme tête alors que ce n'est clairement pas le cas.

032 960687 2__ Amitiés\, des sciences sociales aux réseaux sociaux de l'internet

033 216532 2__ TRANSITION MÉTAL-SEMICONDUCTEUR DANS LES COMPOSÉS Cr₂S₃-xSex ET Cr₂+eSe₃

Note 14 : La présence d'un tiret provoque une erreur dans Talismane.

034 1609898 2__ Les Vigiles debout

Note 15 : Talismane ne devrait prendre que le verbe conjugué.

035 960764 2__ Misère de l'hyper-spécialisation et dérives du professionnalisme

Note 16 : La présence d'un tiret provoque une erreur dans Talismane.

036 62668 2__ Bibliothèques numériques et Google-Print

Note 17 : Print est désigné comme tête alors que ce n'est clairement pas le cas.

037 1559698 2__ Dispositif de de caractérisation simultanée de l'abondance de pucerons et de la

croissance végétative d'arbres fruitiers

Note 18 : La répétition de la préposition entraîne une erreur dans Talismane.

038 264587 2__ Le jeu\, une approche philosophique

Note 19 : ici, la virgule a une valeur segmentante.

039 460685 2__ Surveillance de chorégraphies de Web Services basées sur WS-CDL

Note 20 : La présence d'un tiret provoque une erreur dans Talismane.

- 040 62434 2__ Développement stratégique du tourisme sportif de rivière par régulation corporatiste L'expérience du bassin de Saint Anne (Québec) appliquée aux Rivières de Provence
- Note 21 : Oubli d'un point entre Les deux segments du titre. La présence d'une majuscule permet de bien repérer la segmentation manquante.
-
- 041 62397 1:0 Réinterroger les structures documentaires : de la numérisation à l'informatisation
- 042 62226 1:0 Les temporalités médiatiques des personnes âgées : des évolutions dans la stabilité
- 043 360068 1:0 La performativité de l'évidence : analyse du discours néolibéral
- Note 22 : Le mot n'est pas rattaché à son lemme par Talismane car son statut lexical est discutable.
- 044 1061179 1:0 La Société de la Carte géologique de France (1869-1872) : une éphémère réaction à la création du Service de la Carte géologique de la France
- 045 360074 1:0 Dynamique technologique controversée et débat démocratique : le cas des micros et nanotechnologies
- 046 62256 1:0 Traces de contenus africains sur Internet : entre homogénéité et identité
- 047 216312 1:0 MODÈLES THÉOTIQUES DE LA STRUCTURE DES JOINTS DE GRAINS.LES MODÈLES DE STRUCTURE DES JOINTS DE GRAINS ET LEUR UTILISATION
- Note 23 : Les deux têtes sont les mêmes.
- 048 1759477 1:0 Les objets communicants\, La problématique des Antennes: Dispositif pour détecter le vèlage des vaches.
- Note 24 : pour est détecter faussement par notre algorithme comme un mot à promouvoir en Tête car Dispositif et pour sont régis par objets. De plus, on a une virgule segmentante, la majuscule qui la suit montrant clairement le début d'un segment. Il s'agit donc d'un titre à trois segments.
- 049 760329 1:0 L'omniprésence de la famille au sein de l'exploitation agricole : une situation de fait encouragé par les règles de droit
- 050 1208785 1:0 SymbAphidBase : une base de données nouvelle dédiée aux symbiotes de pucerons pour stocker et visualiser les génomes séquencés en standardisant leurs annotations
- 051 264568 1:0 Bill Viola : voir l'eau ou la transparence en mouvement
- Note 25 : Bill est caractérisé comme un NC au lieu d'un NPP.
- 052 1759420 1:0 Les objets communicants\, La problématique des Antennes; Balises de Détresse
- Note 26 : trois problèmes dans ce titre : problématique est considérée comme un adjectif, la virgule n'est pas segmentante mais ici elle l'est, et Balises est détecté par notre algorithme. En fait, il s'agit d'un titre à trois segments et non deux.
- 053 460618 1:0 PERCEPTION DE L'INDÉPENDANCE DE L'AUDITEUR : ANALYSE PAR LA THÉORIE D'ATTRIBUTION
- 054 1707597 1:0 Élités maléfiques et ""complot pédophile"" : paniques morales autour des enfants
- 055 1759142 1:0 Formation et évolution des paroisses de la basse vallée du Drot : essai de synthèse
- 056 859899 1:0 Classification floue généralisée : Application à la quantification de la stéatose sur des images histologiques couleurs
- 057 510693 1:0 Les gastroentérites aiguës à rotavirus de l'enfant : une priorité de santé publique.
- 058 960530 1:0 Monde pluriel : penser l'unité des sciences sociales
- 059 659177 1:0 Reconnaissance et appropriation : pour une anthropologie du travail
- 060 62190 1:0 Métiers émergents de la nouvelle économie: identification des compétences attendues et typologie des métiers exercés

061 1660207 0:1 Quel **pouvoir** de stabilisation à l'échelle de l'UEM : le pacte de stabilité et de croissance **est-il** viable ?

062 659285 0:1 L'**Etat** et les "" autres "" : **comparer** la visibilisation de la main-d'œuvre immigrée

063 62609 0:1 Le **Libre** Accès (Open Access) : **partager** les résultats de la recherche
Note 27 : Libre est caractérisé comme NPP ainsi que Accès. On peut se poser la question si ce n'est pas Le syntagme nominale entier Libre Accès qui devrait être tête.

064 960680 0:1 De l'apprenti footballeur **au** petit-rat de l'Opéra : comment les institutions d'excellence **agissent** face aux dispositions sociales des apprentis ?
Note 28 : Notre algorithme devrait se contenter de ne prendre que de.

065 1258715 0:1 **Référentiels** de compétences : ce que l'instrument **fait** à la logique compétence

066 860275 0:1 La **question** périurbaine : la **repenser** en tenant enfin compte de ce qui motive les périurbains

067 62568 0:1 **Transférabilité** des connaissances : une re-conceptualisation de la distinction tacite / **explicite**
Note 29 : Talismane catégorise explicite comme V au lieu d'ADJ. De ce fait, il désigne explicite comme tête au lieu de re-conceptualisation.

068 264762 0:1 **Théophile** Gautier : **Regardez**\, mais ne touchez pas (comédie)
Note 30 : On peut se poser la question si ce n'est pas Le syntagme nominal entier Théophile Gautier qui devrait être pris comme tête par notre algorithme.

069 1015049 0:1 Les (**il**)**légalités** ambiguës dans le travail policier : comment l'espace **devient** prétexte
Note 31 : L'utilisation du suffixe entre parenthèses il perd Talisman. Il Le catégorise comme
CLS. Notre algorithme ensuite trouve deux mots à prendre pour têtes au lieu d'un.

070 1358243 0:1 **Evolution** de l'arboricolie chez les Cercopithèques: analyse **combinée** de données moléculaires\, morpho-anatomiques et comportementales
Note 32 : combinée est choisi comme tête alors qu'analyse devrait l'être.

071 1061109 0:1 **ImPAC** Lyon : **évaluer** l'impact environnemental et thermique de l'exploitation des aquifères superficiels pour la climatisation

072 1759247 0:1 **Relation** image/**son** : de l'illustration **sonore** à la fusion multi-modale
Note 33 : sonore est caractérisé comme V au lieu de ADJ et comme tête alors que de est de est un meilleur candidat. On remarque la construction de X à Y. Notre algorithme propose Relation est bien la tête du premier segment et incorrectement son qui est mal catégorisé : DET au lieu de NC.

073 760065 0:1 D'une catastrophe\, l'**autre** : **vivre** avec l'atome
Note 34 : Notre algorithme détecterait autre également comme tête car il est régi par vivre. Mais nous limitons notre algorithme à ne prendre que le premier mot comme tête.

074 110247 0:1 **Vers** une économie des fonctionnalités: **changer** nos rapports avec le produit pour des économies d'échelle et des nouvelles logiques de responsabilités

075 809358 0:1 **Après** la délocalisation...les PME **doivent-elles** relocaliser ?

07 6 460346 0:1 Une jeune **fille** changée en jeune homme : homélie sur un miracle survenu dans le monastère **couvent** de Qartmin\, dans le Tur Abdin
Note 35 : Erreur classique de confondre Le NC couvent avec Le V couvrir, de plus il ne s'agit pas de la tête de segment, homélie y prêtant plus sûrement.

078 1060698 0:1 **Extension** de procédure: ""Le législateur nous **garde** de l'opportunité du juge

079 312714 0:1 Mise au point sur ""Les cathares devant l'histoire"" et retour sur ""L'histoire du catharisme en discussion: le débat sur la charte de Niquinta n'est pas clos
 Note 36 : Mise, détecté par notre algorithme, est catégorisé comme VPP au lieu de NC.

080 162674 0:1 Communication financière : quelles sont les pratiques des entreprises ?

081 1258625 1:1 Un nouvel OVNI dans le ciel réunionnais : la transparence des prix
 082 62241 1:1 De l'anarchisme au combat identitaire : l'internet comme média révolutionnaire ?
 083 62366 1:1 Communication et changement organisationnel : le concept de chaîne d'appropriation
 084 264580 1:1 Mystique et magie naturelle : les paysages mystiques de l'Espagne
 Note 37 : Mystique est catégorisée comme ADJ, Talismane privilégie donc le NC magie comme tête. Mais il aurait dû soit choisir Mystique.

085 216338 1:1 MIGRATION DES JOINTS DE GRAINS.LA MIGRATION DES JOINTS INTERGRANULAIRES
 Note 38 : La capitalisation ne pose pas de problème à Talismane. Les deux têtes sont le même mot.

086 1609872 1:1 La création d'entreprise en réponse au rêve d'île : l'ambivalence d'une attractivité fondée sur le cadre de vie.
 087 659340 1:1 Mise à disposition des données géologiques de surface : Création d'un accès sous
 InfoTerre
 Note 39 : La nominalisation de la locution verbale "mettre à disposition" n'est pas bien catégorisée.

088 960668 1:1 Brevet et patrimoine génétique : la brevetabilité des organismes génétiquement modifiés
 089 62616 1:1 Projet DigiCulture : pour un portrait des usages et des usagers des ressources culturelles numériques canadiennes
 090 62386 1:1 PRATIQUES ENONCIATIVES HYPERTEXTUELLES : VERS DE NOUVELLES ORGANISATIONS MEMORIELLES.
 091 110466 1:1 L'avenir de la Common law en français : un point de vue d'Europe continentale
 092 1109003 1:1 Estimation des quantiles conditionnels par quantification optimale : nouveaux résultats
 093 1108914 1:1 Présentation d'une langue: le hongrois
 094 609991 1:1 Variation du risque de cancer du sein en fonction de la nature de la mutation du
 gène ATM. Étude familiale rétrospective

095 62386 1:1 PRATIQUES ENONCIATIVES HYPERTEXTUELLES : VERS DE NOUVELLES ORGANISATIONS MEMORIELLES.
 096 1015246 1:1 L'impact des enceintes urbaines médiévales sur le territoire et ses limites. L'exemple de la Lorraine et de l'Alsace
 097 1258763 1:1 Phèdre janséniste ? retour sur un lieu commun (2)
 Note 40 : Phèdre n'est pas catégorisée comme un NPP mais comme un NC.

098 1409780 1:1 Développement et politique. Le cas d'une politique de santé en Géorgie.
 099 62382 1:1 Quels modèles pour la publication sur le web? Le cas des contenus informationnels
 et culturels.
 Note 41 : Talismane arrive à scinder le ? du mot web.

100 560355 1:1 Un tournant participatif ? Une mise en perspective historique de la participation
 du public dans les politiques scientifiques américaines
 Note 42 : Ici, mise est bien reconnu comme une nature nominale.

A6. Index des tableaux

Tableau 1: signes de ponctuation segmentants	14
Tableau 2: Distribution des catégories morphosyntaxiques des têtes de segments	19
Tableau 3 : Combinaisons agrégées les plus fréquentes de têtes dans les titres bisegmentaux ..	20
Tableau 4: Distribution des structures des titres selon le type	21
Tableau 5 : Distribution des structures des titres selon le nombre d'auteur	22
Tableau 6 : Distribution des structures selon le domaine	24
Tableau 7 : Corrections opérées sur l'étiquetage et la lemmatisation.....	27
Tableau 8 : Les 10 têtes les plus spécifiques de chaque domaine.....	29
Tableau 9 : Nombre de têtes transdisciplinaires selon le corpus choisi	32
Tableau 10: Présence des constructions spécificationnelles classiques dans notre corpus	55